



太原理工大学学报
Journal of Taiyuan University of Technology
ISSN 1007-9432, CN 14-1220/N

《太原理工大学学报》网络首发论文

题目: 基于表面肌电信号的关节角度预测模型
作者: 赵紫慧, 张绪树, 郭媛, 徐志康, 曹容慧
DOI: 10.16355/j.tyut.1007-9432.20240400
收稿日期: 2024-05-22
网络首发日期: 2024-06-05
引用格式: 赵紫慧, 张绪树, 郭媛, 徐志康, 曹容慧. 基于表面肌电信号的关节角度预测模型[J/OL]. 太原理工大学学报.
<https://doi.org/10.16355/j.tyut.1007-9432.20240400>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于表面肌电信号的关节角度预测模型

赵紫慧, 张绪树*, 郭媛, 徐志康, 曹容慧

(太原理工大学 生物医学工程学院, 山西 晋中 030600)

摘要:【目的】研究利用上肢表面肌电(surface electromyography, sEMG)信号进行关节角度连续预测的方法, 探讨提高 sEMG 信号控制智能假肢的精度。【方法】采集 14 名健康右利手受试者上肢 7 块肌肉的表面肌电信号, 提取 sEMG 信号的时域特征值, 采用 Vicon 运动捕捉系统同步采集受试者上肢的三维运动学数据, 计算肘关节角度。搭建了具有注意力机制和残差模块的长短期记忆网络(Long Short-term Memory with an attention mechanism and residual blocks, AR-LSTM)作为预测模型来连续估计肘关节角度, 并与长短期记忆网络、卷积神经网络、多层感知器等神经网络进行了比较, 并通过计算均方根误差、拟合优度和平均绝对百分比误差来评估每个神经网络预测关节角度序列的准确性。【结果】AR-LSTM 均方根误差、拟合优度和平均绝对百分比误差分别为 7.939°、0.921 和 5.554%, 优于其他常规预测模型。【结论】AR-LSTM 能够有效提高 sEMG 的关节角度连续解码的精度。研究结果表明了本文搭建的基于 sEMG 信号的关节角度预测模型可以应用于智能假肢控制, 并提高角度控制的精度。

关键词: 表面肌电信号; 肘关节角度估计; 长短时记忆网络; 注意力机制; 运动捕捉

中图分类号: R318, TP391 **文献标志码:** A **DOI:** 10.16355/j.tyut.1007-9432.20240400

Joint Angle Prediction Model Based on sEMG Signals

ZHAO Zihui, ZHANG Xushu*, GUO Yuan, XU Zhikang, CAO Ronghui

(College of Biomedical Engineering, Taiyuan University of Technology, Jinzhong 030600, China)

Abstract:【Purposes】To investigate the method of joint angle continuous prediction using surface electromyography (sEMG) signals of the upper limb, and to explore the accuracy of sEMG signals to control intelligent prostheses.【Methods】Surface electromyography signals from 7 muscles of the upper limb of 14 healthy right-handed subjects were collected to extract the time-domain eigenvalues of the sEMG signals, and the three-dimensional kinematic data of the upper limb of the subjects were synchronously collected using the Vicon motion capture system to compute the angle of the elbow joint. Long Short-term Memory with an attention mechanism and residual blocks (AR-LSTM) was constructed as a prediction model to continuously estimate the elbow joint angle, and compared with Long Short-term Memory, Convolutional Neural Network, and Multilayer Perceptron was compared. The root mean square error (RMSE), goodness of fit (R^2) and mean absolute percentage error (MAPE) were calculated to assess the accuracy of each neural network in predicting joint angle sequences.【Findings】The root mean square error, goodness of fit, and mean absolute percentage error of AR-LSTM were 7.939°, 0.921, and 5.554%, respectively, which were better than other conventional prediction models.【Conclusions】AR-LSTM can effectively improve the accuracy of continuous decoding of joint angles for sEMG. The results show that the joint angle prediction model based on sEMG signal built in this paper can be applied to intelligent prosthesis control and improve the accuracy of angle control.

Keywords: surface electromyography signal; elbow joint angle estimation; long short-term memory network; attention mechanism; motion capture

收稿日期: 2024-05-22; 修回日期: 2024-06-03

基金项目: 国家自然科学基金资助项目(11972243)

第一作者: 赵紫慧(1999—), 硕士, (E-mail) 1830766858@qq.com

通讯作者: 张绪树(1976—), 博士, 副教授, 主要从事肌骨系统生物力学和康复领域等方面的研究, (E-mail) zhangxushu@tyut.edu.cn

假肢作为一种能够弥补肢体缺失并恢复功能的康复辅助器具^[1],对于残障人士而言具有不可估量的意义。通过使用假肢,残障人士得以重塑自我形象,使自身形态与健康人无异。更为重要的是,智能假肢的引入进一步提升了残障人士的生活自理能力,显著减少了他们在运动方面的障碍^[2,3]。目前,控制假肢的技术手段多种多样,主要信号源包括身体的机械运动、声音、脑电信号以及肌电信号等^[4-6]。在这些信号源中,表面肌电信号(sEMG)因其富含神经肌肉信息而备受关注。通过sEMG信号,能够提取出有用的运动学特征,从而更准确地识别运动意图,减少信息延迟^[7,8]。此外,与其他生理信号相比,肌电接口在外观上更易被残障者接受,使得肌电假肢的使用更为自然^[9]。因此,sEMG信号在智能假肢领域具有广泛的应用前景,其能够为身体障碍者带来更多的生活便利和新的希望。这一技术的应用不仅提升了假肢的实用性和灵活性,也为残障人士的日常生活质量带来了显著的提升。

基于表面肌电信号的运动意图识别通常划分为离散运动分类与连续运动估计两大类。早期的探索主要聚焦于离散运动分类,然而,此方法仅能辨识有限数量的离散动作^[10,11]。一旦出现未定义的运动类型,便会出现分类困难的情况,从而无法适用于机器人的连续控制。相较于离散运动分类,连续运动估计能够自表面肌电信号中提取连续的运动意图信息,展现出更为自然与精确的特性,这更加贴近人类手臂在日常活动中的自然运动状态^[12-14]。连续运动估计在实现外骨骼机器人、主动矫形器以及智能假肢等辅助设备的柔顺与协调动作中扮演着至关重要的角色。因此,基于表面肌电信号的连续运动估计已成为当前研究的热点^[15]。

当前研究领域有许多方法被用于实现人体关节角度的连续估计,这对提高假肢控制系统的精度和优化康复训练过程具有重要意义。Zhang等人^[16]开展了一项研究,运用多层感知器直接从sEMG信号中预测肩部和肘部的多个关节角度,包括肩部屈伸、旋转和肘部的屈曲。然而,他们的研究未提供关于预测性能的详细信息。Wang等人^[17]进一步提出了基于长短时记忆网络的抓取动作连续估计方法。然而,该方法在实时性方面的表现仍有待提升。为了优化LSTM的性能,Ma等人^[18]提出了基于SCA-LSTM深度学习的sEMG信号上肢关节角度连续估计方法。通过深度学习技术,该方法在预测精度上实现了进一步的提升。同样地,Tang等人^[19]也提出了基于

PSO-LSTM模型的人体上肢关节角度连续估计方法。该方法通过粒子群优化算法对LSTM进行改进,显著提高了预测准确率。Chai等人^[20]则针对肘关节角度预测问题,提出了基于sEMG信号的LSTM连续估计方法。该方法在肘关节角度预测上表现出较小的偏差,为肘关节运动分析提供了新的手段。

虽然目前可以对关节角度进行连续预测和估计,但当关节角度发生显著变化时,预测的准确性仍需提高。因此,本研究提出了一种基于sEMG的采用具有注意力机制和残差模块的长短期记忆网络(简称为AR-LSTM)预测关节角度的方法。使用具有双向记忆单元的LSTM网络,同时处理来自过去和未来时间背景的表面肌电信号。同时,采用了多头注意力架构,有利于时间序列学习,从而提高了方法的预测准确性,特别是关节角度显著变化的预测精度。为了训练和验证模型,本文同步采集和分析了上肢肘关节屈伸运动和上肢运动主要肌肉的肌电数据。随后,建立了一个将sEMG特征与关节角度联系起来的回归模型。所有基于sEMG信号的估算结果都与视觉测量结果进行了比较,以证明本文方法的有效性。

1 实验和方法

1.1 实验对象

本研究使用的数据集来自14名身体健全的个体,受试者10男4女,平均年龄24.3岁,平均身高172.5cm,身体质量指数(Body Mass Index, BMI)为21.1 kg/m²,均为右撇子。所有参与者都没有任何已知的神经系统疾病。14名受试者从未参加过任何肌电控制实验或使用过任何肌电接口装置。所有受试者的利手性均由爱丁堡利手性量表测定。所有实验方案和方法均按照相关指南和规定执行,并经太原理工大学生物医学伦理委员会批准。本研究的所有目的和程序在实验开始前已向受试者充分说明,且每位受试者均已明确理解实验内容,并签署了知情同意书以确认其自愿参与。

1.2 实验设备和信号处理

实验采用的sEMG信号采集设备是Noraxon Ultium无线肌电设备,其采样频率为2000 Hz。关于电极的贴放位置,本实验选取了七块右侧上肢相关肌肉,包括桡侧腕伸肌、尺侧腕伸肌、桡侧腕屈肌、肱二头肌、肱桡肌、肱三头肌以及肘肌。

实验采用的运动捕捉设备为Vicon运动捕捉系统,其采样频率高达100 Hz。本实验采用自定义模板的方式,采集受试者上肢的三维运动学数据,在受

试者的右上肢放置了 16 个反光标记。标记分布在第七颈椎和第十胸椎、锁骨切口、胸骨、肩胛骨、肩峰、上臂簇、肘关节、前臂簇、第三掌骨根部、第三掌指关节和第四掌指关节。具体的电极及标记放置位置如图 1 所示。




图 1 电极及标记放置位置

Fig.1 Electrode and marker placement

在放置传感器之前，需使用酒精棉片对采集区域的皮肤表面进行清洁，以确保与手臂肌肉下方形成良好的接触。当参与者皮肤过于干燥时，应通过医用胶带轻轻去除该部位的皮肤细胞，以优化电极与皮肤的接触效果，从而提升信号采集的质量。在实验过程中受试者坐在椅子上，右小臂平放于测试台，右手部处于放松位置，左手自然下垂，身体放松，自然完成动作。所有动作都是从手臂自然垂下的位置开始的，然后在完成动作后返回到这个初始位置。在数据收集中，参与者被要求在连续的循环试验后进行肘关节屈曲/伸展：肘部从中立位置旋转到屈曲方向，然后移动到伸展方向，最后回到中立位置。每次试验持续约 60 秒，受试者被要求完成 3 秒一次的快速肘关节屈伸运动及 5 秒一次的慢速肘关节屈伸运动，分别在三个平面进行，每个参与者记录 6 次试验。

1.3 sEMG 信号预处理与特征提取

对收集的肘部运动相关的七通道 sEMG 信号进行预处理。选取 20-500 Hz 的带通滤波器进行滤波，对滤波后的信号进行了全波整流处理，最后采用了 50 ms 的均方根平滑滤波器对信号进行平滑处理。

在确定运动周期后，对每个周期内的 sEMG 信号进行了特征值提取。本文提取的时域特征主要包括：积分肌电值（Integral Electromyographic, iEMG）、波形长度（Waveform length, WL）和均方根（Root Mean Square, RMS），以下为他们对应的计算公式：

$$IEMG = \sum_{i=1}^N |x_i| \quad (1)$$

$$WL = \sum_{i=1}^{N-1} |x_{i+1} - x_i| \quad (2)$$

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \quad (3)$$

在上述式中，其中 x_i 是时间窗口内第 i 个采样点的 sEMG 的大小， N 是时间窗口的长度。由于 sEMG 是时间序列，因此使用滑动窗口方法提取时域特征以确保其连续性。同时，利用重叠窗口技术对时间窗口进行处理，以减少延迟，提高系统的实时性，同时提取更多的特征信息。因此，当提取上述时域特征时，时间窗口长度被设置为 10 ms。以这种方式，肌电特征的采样频率被降低到 100 Hz，这与关节角的采样频率相同，方便后续的回归模型计算和分析。图 2 为某个受试者在做肘部屈伸动作时尺侧腕伸肌的 3 种特征曲线。




图 2 肌电信号特征对比

Fig.2 Comparison of electromyographic signal characteristics

2 算法介绍

2.1 AR-LSTM 神经网络

注意力机制在基于深度学习的自然语言处理任务中，已经得到广泛应用。该机制能够引导模型对输入的不同部分进行差异化的权重分配，从而更有效地提取出关键且重要的信息。值得注意的是，这种机制的引入并不会显著增加模型的计算负担和存储开销，因此在实际应用中具有显著的优势。

本研究中注意力机制的功能是间接为表现出强通道相关性的肌电信号分配更高的权重。该研究的网络架构旨在利用肌电信号的时间序列数据预测关节角度。这项任务是典型的生物信号处理挑战。在这

项工作中,深度学习模型必须从信号中准确提取重要特征,并根据这些要素预测肢体的动态运动。网络架构包含长短期记忆(LSTM)单元、注意力机制模块和残差连接,以期从时间序列数据中全面捕捉局部特征和长期时间依赖性。数据输入层最初接收由多通道电极采集的 sEMG 信号计算出的特征。随后被输入到 Bi-LSTM 层,这是一种专为捕捉时间序列数据中的长期依赖关系而设计的递归神经网络变体。Bi-LSTM 包括前向路径和后向路径,从根本上扩大了 sEMG 的信息接收范围。利用这种结构,Bi-LSTM 可以获得 sEMG 的全面、全局特征信息。整合 sEMG

两个方向的时间序列信息可解决输入和输出之间不完全同步的问题,从而提高回归模型的准确性。随后加入了多头注意机制,赋予模型处理输入序列中不同部位之间相关性的能力,这对于解析复杂的肘关节运动尤为重要。本文引入了残差模块,将 Bi-LSTM 层的输出直接连接到多头注意力层,确保了深度网络中信息的顺利传递,并促进了训练过程中梯度的有效反向传播。这种设计大大提高了模型训练的效率 and 性能。引入 Dropout 层有助于稳定训练过程和避免过拟合。网络末端的全连接层将提取的特征映射到目标空间。网络结构框架如图 3 所示。

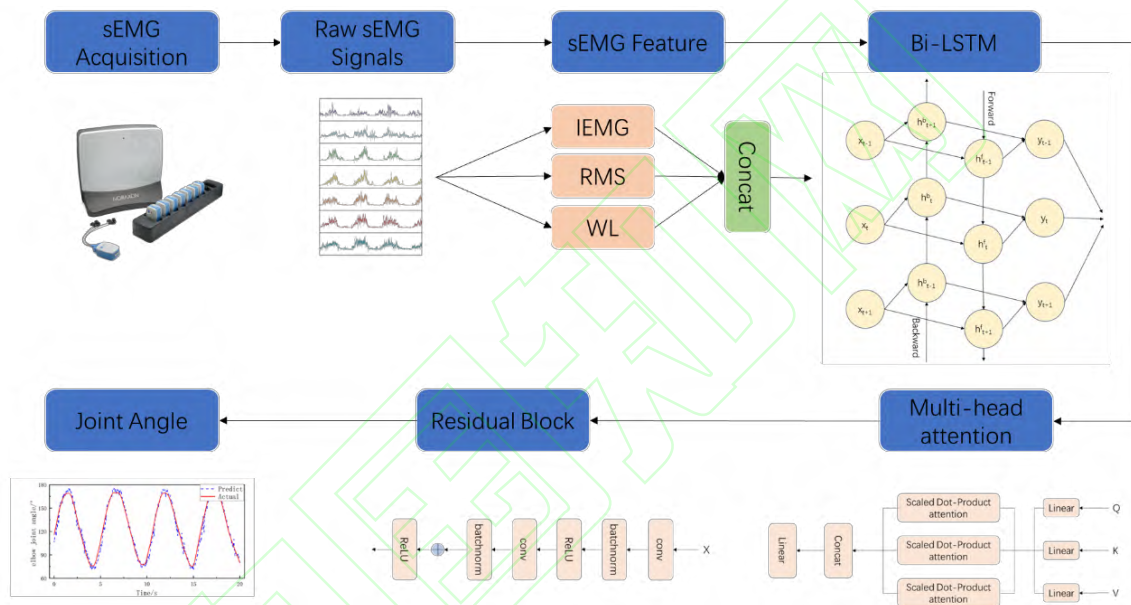


图 3 AR-LSTM 网络结构
Fig.3 AR-LSTM network structure

2.2 评价指标

在本文算法模型搭建中,采用 python 软件编写程序对比分析了不同算法模型的预测结果。为了定量评估模型在肘关节屈伸过程中的上肢角度运动估计性能,使用了三种常用的统计指标:均方根误差(RMSE)、平均绝对百分比误差(MAPE)和拟合优度(R^2)。拟合优度(R^2)是评估模型预测准确性的指标。公式如下:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y'_i - y_i)^2} \quad (4)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - y'_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5)$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y'_i - y_i}{y_i} \right| \quad (6)$$

其中, n 表示关节角度数据的长度, y_i 表示关节角度的实际值, y'_i 表示关节角度的估计值。 R^2 越大,表示回归平方和占总平方和的比例越大,因此回归线越接近真实值,从而使回归的拟合度越高。相反, RMSE 和 MAPE 值越小,说明估计效果越好。

在进行实验之前,必须确定所使用的参数。AR-LSTM 网络回归模型在训练过程中采用了反向传播算法。每个隐藏层包含 128 个隐藏单元,为防止过度拟合,还加入了一个 dropout 层,丢弃率设定为 0.5。采用的损失函数是关节角度预测值与实际值之间的均方误差。使用 Adam 优化器进行优化。不同用户执行相同动作时,肌电信号会存在一定程度的差异,为了客观评估结果,本文每次选取 1 名受试者数据充当训练集,将剩余受试者数据轮流作为测试集。这个过程重复 14 次,直到每个受试者数据都完成训练,且被测试 13 次。

3 结果

3.1 不同速度下肘关节角度预测结果

日常生活中，肘关节运动的速度是不断变化的，当运动节奏不一致时，手臂肌肉也会引起不同程度的收缩，改变同一名测试人员的运动周期，让其分别以 3 秒一次进行快速肘关节屈伸动作、5 秒一次进行慢速肘关节屈伸动作，模型的拟合结果如表 1 所示。3 秒一次的快速屈肘运动的三项指标在多数受试者的测试数据中优于 5 秒一次的慢速屈肘运动，在某几位受试者的训练中，慢速运动时预测效果略优，但

整体来看，在 3 秒一次的快速肘关节屈伸过程中，预测模型的预测角度能够较好的反应实际肘关节角度，角度偏差不大，均方根误差为 7.481°。当受试者放慢速度，以 5 秒一次完成慢速肘关节屈伸运动时，预测曲线能够大致的反应实际角度曲线，但是存在较大的偏差，均方根误差为 8.326°。这可能是由于肌电信号的产生与肌肉收缩的幅值以及速度相关，在慢速下肌电信号比较微弱且变化缓慢，这会导致角度的估计结果较差。

表 1 肘关节屈伸快速和慢速的关节角度预测回归模型的 RMSE、R²、MAPE

Tab. 1 RMSE, R², and MAPE of joint angle prediction regression models for fast and slow elbow flexion and extension

受试者	快速运动			慢速运动		
	RMSE	R ²	MAPE	RMSE	R ²	MAPE
1	8.153	0.902	5.277	9.667	0.864	6.640
2	7.877	0.918	5.072	6.640	0.819	7.789
3	6.442	0.967	4.621	5.592	0.977	3.799
4	4.621	0.969	3.510	4.462	0.982	3.375
5	5.810	0.964	3.740	8.649	0.908	6.277
6	6.646	0.965	4.705	3.565	0.991	0.991
7	11.953	0.723	7.831	16.900	0.208	10.510
8	10.225	0.819	6.505	12.610	0.735	8.187
9	5.797	0.946	4.573	7.815	0.925	5.682
10	4.573	0.955	4.514	7.205	0.951	5.145
11	9.085	0.938	6.816	5.199	0.984	3.988

续表 1 肘关节屈伸快速和慢速的关节角度预测回归模型的 RMSE、R²、MAPE

Tab. 1 RMSE, R², and MAPE of joint angle prediction regression models for fast and slow elbow flexion and extension

受试者	快速运动			慢速运动		
	RMSE	R ²	MAPE	RMSE	R ²	MAPE
12	5.610	0.967	3.554	7.469	0.938	5.312
13	10.462	0.802	6.545	12.460	0.735	7.920
平均值	7.481	0.910	5.174	8.326	0.848	5.817

3.2 不同模型性能比较

图 4 显示了各模型在肘关节屈伸过程中角度连续预测的结果，红色曲线为实际肘关节角度曲线，蓝色曲线为模型预测曲线。本文所提方法 AR-LSTM 拟合的关节运动轨迹（蓝色虚线）更接近实际值。通过比较本文提出的 AR-LSTM 与 MLP^[21]、CNN^[22]、LSTM^[23]等模型的预测结果，具体曲线如图 4 所示。MLP 模型在整个过程中波动很大，无法稳定地识别关节角度。CNN 模型表现相对较好，但在关节角度发生显著变化时变得不稳定。LSTM 在估计肘关节角

度平面方面的表现明显更好，但无法准确识别拐点处的变化幅度。不过，与其他模型相比，AR-LSTM 弥补了 LSTM 和 CNN 的不足，取得了更优的性能。AR-LSTM 模型不仅在整体趋势上表现出色，而且在肘关节屈伸瞬间也有较好的表现。

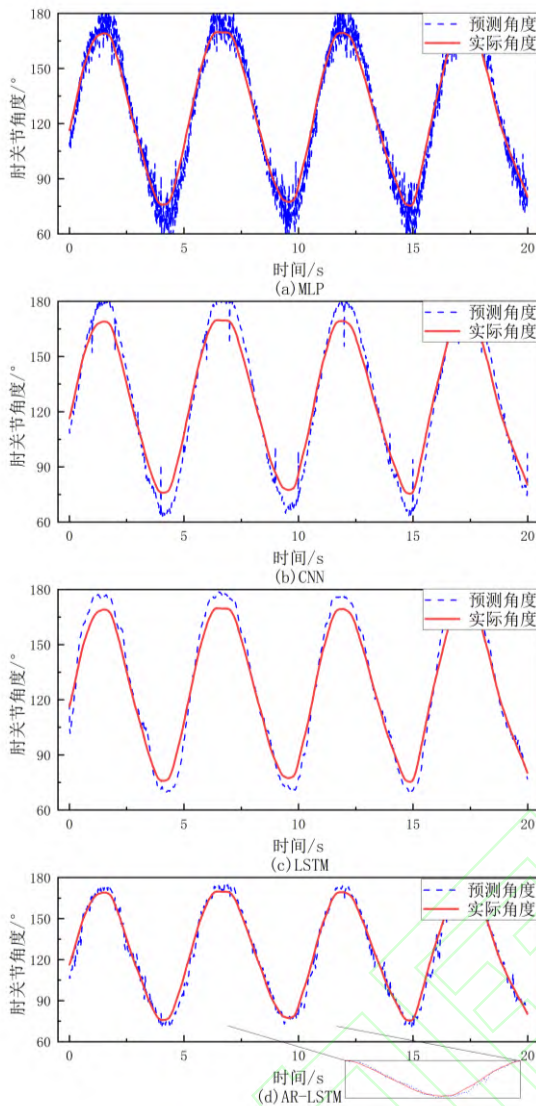


图 4 模型在肘部运动学估计方面的性能
(a)MLP; (b)CNN; (c)LSTM; (d)AR-LSTM
Fig.4 Model performance in elbow kinematics estimation (a)MLP;(b)CNN;(c)LSTM;(d)AR-LSTM

表 2 显示了受试者在不同测试集中使用不同预测模型的 RMSE、 R^2 和 MAPE。与 LSTM 模型相比, AR-LSTM 模型的平均 RMSE 减少了 1.604° , 平均 R^2 提高了 3.8%, 平均 MAPE 减少了 0.771%。与 CNN 模型相比, AR-LSTM 模型的平均 RMSE 减少了 1.978° , 平均 R^2 提高了 4.4%, 平均 MAPE 减少了 1.214%。

为了对估计性能进行定量比较, 图 5 显示了四种方法在所有受试者中的 RMSE 和 R^2 值。LSTM、CNN、MLP 和 AR-LSTM 的平均 RMSE 分别为 8.815 ± 0.944 、 9.042 ± 1.177 、 9.952 ± 1.226 和 7.939 ± 0.787 。LSTM、CNN、MLP 和 AR-LSTM 的 R^2 值分别为 0.905 ± 0.023 、 0.898 ± 0.029 、 0.882 ± 0.031 和 0.921 ± 0.016 。从平均性能来看, AR-LSTM 的结果优于其他技术, 因为它获得了更大的 R^2 和更小的 RMSE。

表 2 实际关节角和估计关节角之间不同预测模型的 RMSE、 R^2 、MAPE

Tab.2 RMSE, R^2 and MAPE of different regression models between actual and estimated joint angles

受试者	LSTM			CNN			MLP			AR-LSTM		
	RMSE	R^2	MAPE	RMSE	R^2	MAPE	RMSE	R^2	MAPE	RMSE	R^2	MAPE
1	10.937	0.823	7.136	10.699	0.830	6.999	10.840	0.826	6.627	8.153	0.902	5.277
2	9.643	0.877	6.530	8.933	0.895	6.069	9.261	0.887	5.812	7.877	0.918	5.072
3	5.791	0.973	3.757	7.474	0.956	5.047	8.676	0.940	6.000	6.442	0.967	4.621
4	6.592	0.954	4.461	7.650	0.938	5.556	7.842	0.935	5.349	4.621	0.969	3.510
5	7.411	0.941	4.769	7.952	0.933	5.609	8.629	0.921	5.767	5.810	0.964	3.740
6	5.860	0.973	3.656	6.370	0.968	4.529	8.289	0.945	5.971	6.646	0.965	4.705
7	13.653	0.639	8.558	13.889	0.626	8.894	13.823	0.630	8.506	11.953	0.723	7.831
8	13.342	0.691	8.668	13.504	0.684	8.799	13.565	0.681	8.511	10.225	0.819	6.505
9	8.491	0.919	5.797	8.537	0.918	5.884	9.381	0.901	6.114	5.797	0.946	4.573
10	8.109	0.941	4.843	8.263	0.939	5.717	9.009	0.927	6.277	4.573	0.955	4.514
11	8.119	0.951	6.070	9.518	0.932	6.700	10.891	0.911	8.124	9.085	0.938	6.816
12	7.263	0.945	4.854	7.126	0.947	5.017	7.650	0.939	5.032	5.610	0.967	3.554
13	12.902	0.700	8.183	13.053	0.692	8.220	13.073	0.692	7.845	10.462	0.802	6.545
平均值	9.086	0.871	5.945	9.459	0.866	6.388	10.072	0.856	6.610	7.481	0.910	5.174

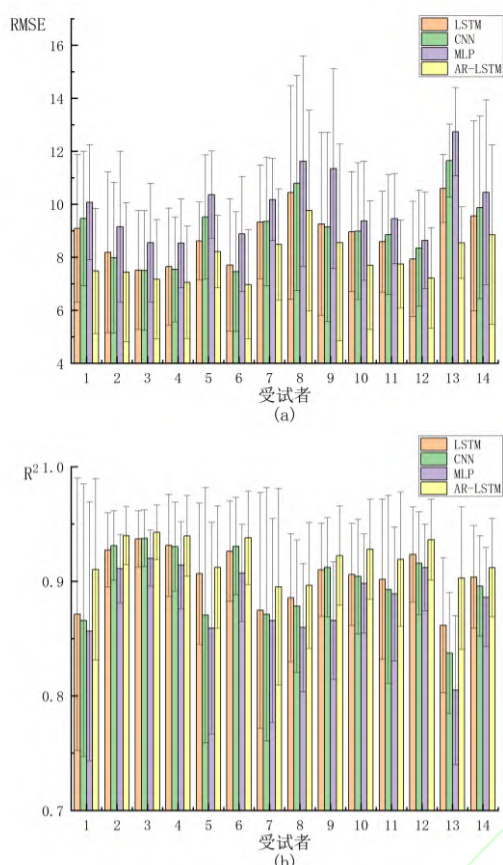


图5 当使用不同的回归模型时,每个受试者的(a) RMSE; (b) R^2

Fig.5 When different regression models were used, each subject's (a) RMSE; (b) R^2

4 讨论

本文通过采集14名成年健康受试者肘关节屈伸时上肢相关肌肉的表面肌电信号及运动学数据,进行特征提取及角度计算,探讨基于表面肌电信号的关节角度连续估计方法。在本研究中,开发并提出了一种创新的改良长短期记忆(AR-LSTM)算法,专门设计用于提升基于sEMG信号的上肢运动关节角度的估计精确度。本算法的开发是基于对现有模型的深入分析,旨在解决传统LSTM在处理复杂sEMG信号时遇到的性能瓶颈。为了准确描述每种算法的性能,本文计算了实际关节角度和预测关节角度之间的RMSE、 R^2 和MAPE等指标。LSTM由于能在其存储单元中结合先前信息,因此能提供平滑、更准确的关节角度曲线。然而,关节角度突然变化点的难题依然存在。AR-LSTM利用其双向记忆单元和注意力机制弥补了这一不足,获得了最佳的估计结果。AR-LSTM模型的估计曲线与实际曲线趋势一致,偏差或抖动极小。这表明该模型的双向记忆单元有效

缓解了输入和输出之间的不同步,从而获得了出色的拟合能力和稳定性。对于通过sEMG对上肢关节角度进行持续评估,本文提出的方法利用AR-LSTM模型的多头注意力机制和双向机制,准确、高效地估算了关节角度,并取得了优异的结果。相较于国内外现有的关节角度识别结果^[17-20],本文每次仅选择1名受试者数据作为训练集,剩余受试者数据轮流充当测试集,AR-LSTM模型的平均值 R^2 为0.921。本文的研究结果验证了基于表面肌电信号进行关节角度连续估计的可行性,实际应用时只需要新用户做少量的调整即可进行关节角度估计,简化了智能假肢控制系统的运算复杂度,提高了关节角度连续预测的精度。更有利于发展符合人体自然运动的控制方式,为可穿戴肌电设备的普及提供了可行的参考方案。此外,肌电信号是肌肉收缩时产生的电信号,其幅值和频率特征与肌肉的收缩活动密切相关^[24]。相对于先前研究中对速度因素的忽略^[17-20],本文还对比了不同速度下的肘关节屈伸运动,慢速运动模式下,模型性能略有降低,但仍可以比较准确反映实际角度曲线。

然而,尽管模型整体表现优异,仍存在若干局限性和挑战。首先,尽管模型能够较好地拟合实际关节角度曲线,但预测误差主要集中在运动的拐点处,表明模型对关节运动速度或方向急剧变化的捕捉能力尚有待提升。这可能需要进一步改进模型结构或调整训练策略,以更有效处理这类快速变化。此外,当前研究使用的数据集受限于特定的实验设置和受试者群体,可能制约了模型泛化能力的全面评估。因此,在更多样化的环境和更广泛的用户群体中验证模型的通用性是未来研究的关键方向。未来的研究方向将聚焦引入其他信息进行多模态深度学习,以进一步提高估计性能,使得该技术更易于应用于移动设备和实时处理场景。

5 结论

本文提出了基于深度学习的AR-LSTM预测模型,旨在从sEMG信号中连续且准确地估计上肢运动的肘关节角度。与其他现有的关节角度预测模型进行了比较,结果显示,该模型在上肢肘关节角度的估计精度上有显著提高,尤其在动态运动的预测上表现突出。这种高精度的预测模型为未来开发直观、灵巧的多自由度机械臂控制系统提供了技术支持,有助于实现更为精确和自然的同步及比例控制,这对于提升肢体残障患者的生活质量和促进人机交互的发展具有重要意义。在后续的工作中,将采用多模

态技术构建关节角度预测模型, 将 Vicon 运动捕捉系统采集的视觉模态信息与表面肌电信号、关节角度信号进行融合, 减小关节角度连续解码的误差。

参考文献:

- [1] Williams H E, Chapman C S, Pilarski P M, et al. Myoelectric prosthesis users and non-disabled individuals wearing a simulated prosthesis exhibit similar compensatory movement strategies[J]. *Journal of NeuroEngineering and Rehabilitation*, 2021, 18(1): 72. <https://doi.org/10.1186/s12984-021-00855-x>.
- [2] Chen X, Zhang D, Zhu X. Application of a self-enhancing classification method to electromyography pattern recognition for multifunctional prosthesis control[J]. *Journal of neuroengineering and rehabilitation*, 2013, 10: 1-13. <https://doi.org/10.1186/1743-0003-10-44>.
- [3] Segas E, Mick S, Leconte V, et al. Intuitive movement-based prosthesis control enables arm amputees to reach naturally in virtual reality[J]. *Elife*, 2023, 12: RP87317. <https://doi.org/10.7554/eLife.87317>.
- [4] Shehata A W, Scheme E J, Sensinger J W. Evaluating internal model strength and performance of myoelectric prosthesis control strategies[J]. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2018, 26(5): 1046-1055. <https://doi.org/10.1109/TNSRE.2018.2826981>.
- [5] Cutipa-Puma D R, Coaguila-Quispe C G, Yanyachi P R. A low-cost robotic hand prosthesis with apparent haptic sense controlled by electroencephalographic signals[J]. *HardwareX*, 2023, 14: e00439. <https://doi.org/10.1016/j.ohx.2023.e00439>.
- [6] Cheng S, Laubscher C A, Gregg R D. Automatic Stub Avoidance for a Powered Prosthetic Leg over Stairs and Obstacles[J]. *IEEE Transactions on Biomedical Engineering*, 2023, 71(5), 1499-1510. <https://doi.org/10.1109/TBME.2023.3340628>.
- [7] Chen C, Guo W, Ma C, et al. sEMG-based continuous estimation of finger kinematics via large-scale temporal convolutional network[J]. *Applied Sciences*, 2021, 11(10): 4678. <https://doi.org/10.3390/app11104678>.
- [8] 张腾宇, 樊瑜波. 大腿截肢患者的残肢肌电运动识别[J]. *医用生物力学*, 2016, 31(6): 478-482+494. doi:10.3871/j.1004-7220.2016.06.478.
ZHANG Tengyu, FAN Yubo. Motion recognition based on EMG signals of residual limb in transfemoral amputee [J]. *Journal of Medical Biomechanics*, 2016, 31(6): 478-482+494.
- [9] Fougner A, Stavdahl Ø, Kyberd P J, et al. Control of upper limb prostheses: Terminology and proportional myoelectric control – A review[J]. *IEEE Transactions on neural systems and rehabilitation engineering*, 2012, 20(5): 663-677. <https://doi.org/10.1109/TNSRE.2012.2196711>.
- [10] Yang J, He Y, Shi P, et al. A review on human intent understanding and compliance control strategies for lower limb exoskeletons[J]. *Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering*, 2022, 236(6): 1067-1086. <https://doi.org/10.1177/09596518221085793>.
- [11] 张瑞轩, 张绪树, 郭媛, 等. 基于表面肌电信号的手势识别与分析[J]. *医用生物力学*, 2022, 37(5): 818-825. doi:10.16156/j.1004-7220.2022.05.008
ZHANG Ruixuan, ZHANG Xushu, GUO Yuan, et al. Recognition and Analysis of Hand Gesture Based on sEMG Signals, 2022, 37(5): 818-825.
- [12] Phinyomark A, Scheme E. EMG pattern recognition in the era of big data and deep learning[J]. *Big Data and Cognitive Computing*, 2018, 2(3): 21. <https://doi.org/10.3390/bdcc2030021>.
- [13] Guo W, Ma C, Wang Z, et al. Long exposure convolutional memory network for accurate estimation of finger kinematics from surface electromyographic signals[J]. *Journal of Neural Engineering*, 2021, 18(2): 026027. <https://doi.org/10.1088/1741-2552/abd461>.
- [14] Kapelner T, Vujaklija I, Jiang N, et al. Predicting wrist kinematics from motor unit discharge timings for the control of active prostheses[J]. *Journal of neuroengineering and rehabilitation*, 2019, 16: 1-11. <https://doi.org/10.1186/s12984-019-0516-x>.
- [15] Liu J, Kang S H, Xu D, et al. EMG-based continuous and simultaneous estimation of arm kinematics in

- able-bodied individuals and stroke survivors[J]. *Frontiers in neuroscience*, 2017, 11: 480. <https://doi.org/10.3389/fnins.2017.00480>.
- [16] Zhang Q, Liu R, Chen W, et al. Simultaneous and continuous estimation of shoulder and elbow kinematics from surface EMG signals[J]. *Frontiers in neuroscience*, 2017, 11: 280. <https://doi.org/10.3389/fnins.2017.00280>
- [17] Wang C, Guo W, Zhang H, et al. sEMG-based continuous estimation of grasp movements by long-short term memory network[J]. *Biomedical Signal Processing and Control*, 2020, 59: 101774. <https://doi.org/10.1016/j.bspc.2019.101774>
- [18] Ma C, Lin C, Samuel O W, et al. Continuous estimation of upper limb joint angle from sEMG signals based on SCA-LSTM deep learning approach[J]. *Biomedical Signal Processing and Control*, 2020, 61: 102024. <https://doi.org/10.1016/j.bspc.2020.102024>.
- [19] Tang G, Sheng J, Wang D, et al. Continuous estimation of human upper limb joint angles by using PSO-LSTM model[J]. *IEEE Access*, 2020, 9: 17986-17997. <https://doi.org/10.1109/ACCESS.2020.3047828>.
- [20] Chai Y, Liu K, Sun Z, et al. A long short term memory network based on surface electromyography for continuous estimation of elbow joint angle[C]//2020 IEEE 9th Data Driven Control and Learning Systems Conference (DDCLS). IEEE, 2020: 522-527. <https://doi.org/10.1109/DDCLS49620.2020.9275122>
- [21] Jiang N, Englehart K B, Parker P A. Extracting simultaneous and proportional neural control information for multiple-DOF prostheses from the surface electromyographic signal[J]. *IEEE transactions on Biomedical Engineering*, 2008, 56(4): 1070-1080. <https://doi.org/10.1109/TBME.2008.2007967>
- [22] Shrirao N A, Reddy N P, Kosuri D R. Neural network committees for finger joint angle estimation from surface EMG signals[J]. *Biomedical engineering online*, 2009, 8: 1-11. <https://doi.org/10.1186/1475-925X-8-2>
- [23] Wang C, Guo W, Zhang H, et al. sEMG-based continuous estimation of grasp movements by long-short term memory network[J]. *Biomedical Signal Processing and Control*, 2020, 59: 101774. <https://doi.org/10.1016/j.bspc.2019.101774>
- [24] Wang L, Buchanan T S. Prediction of joint moments using a neural network model of muscle activations from EMG signals[J]. *IEEE transactions on neural systems and rehabilitation engineering*, 2002, 10(1): 30-37. <https://doi.org/10.1109/TNSRE.2002.1021584>

本文创新点：搭建了具有注意力机制和残差模块的长短期记忆网络（Long Short-term Memory with an attention mechanism and residual blocks, AR-LSTM）作为预测模型来估计肘关节角度，所提出方法有更高的预测精度，研究结果表明了本文搭建的基于 sEMG 信号的关节角度预测模型可以应用于智能假肢控制，可以提高假肢关节角度控制精度。