

学校代码 10702

密级 公 开

中图分类号 TP242.6

学号 2104210510



西安工业大学
Xi'an Technological University

硕士学位论文

基于表面肌电的上肢外骨骼控制方法研究

学位申请人: 赵恒阳

指导教师: 廖福元 副教授

学科名称: 检测技术与自动化装置

学位门类: 工 学

2024 年 5 月



西安工业大学
Xi'an Technological University

硕士学位论文

题目：基于表面肌电的上肢外骨骼
控制方法研究

作者 赵恒阳

指导教师 廖福元 专业技术职务 副教授
学科 检测技术与自动化装置

西安工业大学

2024 年 5 月 中国.西安

**Upper Limb Exoskeleton Control Methods Based on
Surface Electromyographic Signals**

by

Zhao Hengyang

Thesis Submitted to the faculty of the Xi'an Technological University in

Partial Fulfillment of

the Requirements for the Degree of

MASTER

in

Measurement Technology and Automation Devices

Supervisor: Prof. Liao Fuyuan

Xi'an Technological University

May 2024

Xi'an, Shaanxi, P.R.China

摘要

基于表面肌电信号（Surface Electromyography, sEMG）控制的上肢外骨骼在康复医学、工业及军事等领域有广阔的应用前景。表面肌电反映神经肌肉活动，其产生早于实际的肢体运动，因而可预测肢体的运动意图。目前，基于表面肌电控制的上肢外骨骼存在以下问题：多数基于传统特征和其他多种信息源的融合方法中传统特征的提取较为复杂繁琐；连续运动估计中常用的循环神经网络（Recurrent Neural Network, RNN）及其变体模型会存在梯度爆炸和无法并行处理等问题；基于传统离散控制的外骨骼灵活度和鲁棒性较差。

本课题针对上述问题提供了适当的解决方案，内容如下：

（1）提出一种直接使用 sEMG 信号作为输入的关节角度预测模型，去除对传统特征繁琐的提取流程，提升了外骨骼机器人控制的柔顺度和灵活度，实现了肩肘关节三自由度的关节角度同步连续预测。与目前已有的模型相比，本研究提出的算法在预测肩肘关节三个自由度的角度时表现更优。

（2）提出一种基于多输入时间卷积注意力的网络来连续识别关节角度。避免了梯度爆炸和无法并行处理等问题。借助开源数据集中的肌电信号和关节角度，本研究成功地实现了手指关节角度的预测。此外，本文还进行了与长短时记忆网络（Long short-term memory networks, LSTM）和反向传播网络（Backpropagation Neural Network, BPNN）两种方法的比较，并对模型的拟合效果进行了评价。

（3）提出一种基于表面肌电的手部动作识别方法。根据肌肉运动和其所引发的肌电信号之间的联系推测，设计了一种针对肌电手势辨识的多流集成深层次学习策略。该方案利用前臂多通道 sEMG 产生的肌电图形来实现多流表示，然后将其分解为若干个小图像并逐一输入到多流卷积神经网络各部分以建立模型。最后，在特征维度实现了多流的整合，从而使每个部分学得的深度特性得以综合起来。实验结果显示，在前臂各种肌肉群体的肌电信号被纳入多流集成深层次学习架构后，能够显著提升肌电手势辨识的精确度。

（4）综合手部动作识别和关节角度预测结果，提出一种基于双模型交叉验证的上肢外骨骼模糊控制方法。首先将手部关节角度预测和手部动作识别结果进行交叉验证，消除模型预测误差。采用模糊控制对上肢外骨骼的指令进行优化，该方法对外骨骼控制命令的准确度有明显提升。

关键词：表面肌电信号；上肢外骨骼控制；深度学习；动作识别；关节角度估计；

Abstract

Based on Surface Electromyography (sEMG) control, intelligent exoskeletons hold substantial research significance and practical value in areas such as rehabilitation medicine and the control of intelligent exoskeletons. sEMG can reflect the functional status of nerves and muscles, and it precedes the generation of human movements. The basis for achieving control is the recognition of motion intent, which is divided into discrete motion recognition and continuous motion estimation. In the past few years, as artificial intelligence has gained prominence, the field has seen new methods emerge through the advancements in deep learning. However, there are still some problems that need to be addressed. Most fusion techniques for surface electromyography control rely on traditional features and various sources of data, which can lead to the same complexities associated with traditional feature extraction. Recurrent Neural Networks (RNN) and similar models are often utilized for continuous motion prediction but may face challenges like gradient explosion and lack of parallel processing capabilities. The flexibility of exoskeletons based on traditional discrete control is poor, and the robustness of most exoskeleton robots is poor.

This study proposes corresponding solutions to the above problems, as follows:

(1) Proposing an end-to-end continuous motion estimation model to eliminate the cumbersome process of traditional feature extraction, improve the flexibility, conformity, and flexibility of exoskeleton robot control. This study's algorithm, a synchronous continuous estimation model of the shoulder and elbow joint angles, outperforms other models in the three degrees of freedom angle prediction results when compared.

(2) Using deep learning algorithms, this paper proposes a network based on multi-input time convolution attention to continuously recognize joint angles, avoiding problems such as gradient explosion and inability to be parallel processed. By using electromyographic signals and joint angles from the NinaPro open dataset DB2, precise estimation of the angles of 20 finger joints was achieved. In addition, the experiment also compared two algorithms, LSTM and BP, and parameterized evaluation of the model's fitting performance.

(3) To improve the robustness of the entire control method by verifying the results of continuous motion estimation and then improving the discrete action classification model. The research paper presents the idea that there is a connection between movements made with the hands and arms and the electrical signals produced by muscle groups, and suggests a complex deep learning approach involving the integration of multiple data streams for recognizing gestures based on electromyographic signals. The electromyographic images generated by the forearm sEMG are represented by multiple streams, and the obtained multiple sub-images are

input into various branches of the multi-stream convolutional neural network for modeling. Then, through the feature-layer multi-stream fusion, the deep features learned by multiple branches are fused together. The outcomes demonstrated on the public dataset NinaPro indicate that integrating the relationship among electromyographic signals from various muscle areas in the forearm within the multi-stream fusion deep learning approach is successful in enhancing the precision of electromyographic gesture identification.

(4) To improve the robustness of the entire control method, this study integrates hand action classification, joint angle prediction models, and fuzzy control methods to design a fusion control method. Firstly, mutual verification is conducted based on the prediction results of the model itself to eliminate partial errors. Furthermore, fuzzy control is implemented to enhance the commands of the upper limb exoskeleton based on the real angles of movement for each joint beyond the model. Through the verification of relevant data collected, the control method proposed in this paper significantly improves the accuracy of exoskeleton control commands.

Key Words: Surface EMG Signal; EMG Control; Deep Learning; Gesture Classification; Continuous Estimation; Multi-stream Fusion Learning

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	3
1.2.1 表面肌电产生的机理.....	3
1.2.2 基于表面肌电的动作识别.....	4
1.2.3 基于表面肌电的关节角度预测.....	8
1.2.4 基于表面肌电的外骨骼控制方法.....	10
1.3 总结及分析.....	11
1.4 本文结构.....	12
2 基于表面肌电的肩肘关节角度预测方法	14
2.1 引言.....	14
2.2 实验设计及数据采集.....	14
2.2.1 实验设计及数据采集.....	14
2.2.2 数据预处理.....	15
2.3 肩肘关节角度预测模型.....	15
2.3.1 卷积模块.....	16
2.3.2 Tnsformer 编码器.....	16
2.3.3 Transformer 解码器.....	20
2.4 肩肘关节角度预测性能评价	20
2.4.1 预测性能评价流程.....	20
2.4.2 评价指标.....	21
2.4.3 评价结果.....	21
2.5 本章小结.....	25
3 基于表面肌电的手部关节角度预测方法	26
3.1 引言.....	26
3.2 数据描述.....	26
3.2.1 实验设计.....	26
3.2.2 数据预处理.....	27
3.3 手部关节角度预测模型.....	27
3.3.1 模型结构.....	27
3.3.2 联合决策机制.....	30
3.4 手部关节角度预测性能评价	31
3.4.1 预测性能评价流程.....	31
3.4.2 评价结果.....	31

3.5 本章小结.....	34
4 基于表面肌电的手部动作识别	35
4.1 引言.....	35
4.2 数据描述.....	35
4.2.1 数据预处理.....	35
4.2.2 时频转换.....	35
4.3 手部动作识别模型.....	36
4.3.1 表面肌电信号的多流表征.....	37
4.3.2 多流卷积神经网络结构.....	38
4.3.3 特征融合网络结构.....	41
4.4 手部动作识别性能评价.....	42
4.4.1 评价流程.....	42
4.4.2 评价结果.....	43
4.5 本章小结.....	46
5 基于表面肌电的外骨骼控制方法	47
5.1 引言.....	47
5.2 数据描述.....	47
5.2.1 实验设计.....	47
5.2.2 数据预处理.....	48
5.3 外骨骼控制方法.....	49
5.3.1 外骨骼控制流程.....	49
5.3.2 基于关节角度误差的模糊控制方法.....	50
5.4 外骨骼控制性能评价.....	54
5.5 本章小结.....	57
6 总结与展望.....	58
6.1 总结.....	58
6.2 展望.....	59
参考文献.....	60

1 绪 论

1.1 研究背景和意义

近年来,随着机器人技术的不断进步,以外骨骼机器人为代表的智能化机器人,已广泛应用于搬运、康复、辅助和军事等领域^[1]。外骨骼机器人的独特之处在于,它们能够附着在人体上,并且通过人类发出的命令来进行基础的互动。随着计算机的计算能力大幅增强,深度学习的进步得以推动并产生了各种新型的人机互动模式,例如计算机图像识别、自然的语言处理和生理信号处理等等。其中一种重要的新兴趋势是利用人类肌肉运动产生的生物信息来驱动电子产品或其他相关装置^[1]。这种基于人的身体活动的信息可以用来调节一些复杂的技术装备或者提供更高级别的智能化服务^[2],比如使用它来远程执行某些危险任务以降低意外发生的风险,也可以用作改善工作流程中的一些关键环节而使其更加高效且稳定。

智能控制的外骨骼与人体之间的交互至关重要,而准确判断出人体的意图是交互中最重要的研究问题^[3]。其核心挑战在于对肢体的运动行为进行辨识与预判,这实际上是一种模式分类的问题^[4]。通过从中提取有用的特征,以识别出肢体的动作并且推断出关节的角度。依据所使用信息采集设备的种类,可以将其划分为两种:一种是以图像为基础的技术,另一种则是通过传感器设备实现的识别及预判^[5]。而基于传感器的识别预测又可分为基于非生理信号的识别预测技术和基于生理信号的识别预测技术。运用生理信号来完成识别与预判任务的方式则可细分为两种:一种是依赖于脑电波的识别与预测技术^[6];另一种则是借助 sEMG 技术的识别与预测技术。

作为一种从皮肤表面收集到的生物数据, sEMG 因其无需手术介入、无痛感及易操作的特点而被广泛应用于人类肌肉活动检测中^[7]。相较于其它可以用来预测动作行为的信号,肌电信号具备更早地预示出身体活动的优势,这使得 sEMG 成为研究者们探索人类行为意图的重要工具^[8]。通过使用肌电信号来推动人和机器之间的互动,需要关注的是能否有效并稳定地运用合适的算法去精确捕捉和理解这些信号所传达出的信息,这也是构建高效的人机协作系统的核心问题之一^[9]。

sEMG 的收集通过一系列位于身体表面的电极来获取。Englehart 等人创建了一款名为 BioPatRec 的肌电控制应用程序,并配有相应的稀疏多通道肌电数据集,其中包括来自 17 位健康的实验者手臂部位的 8 路肌电信号^[10]。此外,成立于多个研究所的研究小组——非侵入式的自我调整假肢 (Non Invasive Adaptive Prosthetics, NinaPro) 自 2012 年开始建立了一个七组稀疏的多通道肌电数据集,这个数据集涵盖了十到十六个电极从不同健康受试者和截肢患者的手臂位置获得的稀疏多通道肌电信号^[11-14]。

因为 sEMG 在识别人体运动意图方面具有良好的稳定性, 所以 sEMG 是适合用来解码人体运动模式的生物信号^[15,16]。人体 sEMG 以及相关的技术, 有着以下的足以实现人机交互的特性: 1) sEMG 源自人体肌肉的收缩, 可以直接从皮肤表面进行收集, 获取相对简单, 并且具有成熟的肌电信号传感器^[17]。2) sEMG 的产生会提前于肢体运动发生, 利用该特点可对人体运动意图进行预测^[18]。3) sEMG 本身携带了比较丰富的人体运动信息, 使用合适的特征提取算法能有效评估人体运动意图^[19,20]。

肌电控制是一种利用肌肉电信号来控制外部设备或系统的技术, 其在商业用途的外骨骼系统中具有竞争优势, 这种技术也被广泛运用于各种领域, 如多功能假体^[21]、轮椅^[22]以及步态识别^[23]等。有研究涉及到对肌肉活动信号的捕捉及分析以达到操控的目的^[24], 另一项研究则关注于通过模拟的方式来操作电子设备^[25]。相比起其他的控制方式, 例如基于开关驱动机制的机械装置, 肌电控制具有更强的优势它可以把人类的行为控制从被动的状态转变为主动状态, 并且可以让用户根据自己的意愿做出决策, 这有助于提升人机互动的效果。肌电控制除了能够区分肢体的不同动作之外, 还可以预测连续性的运动情况, 进而增强智能外骨骼系统的可变性和适应性。当前, 大部分关于肌电控制的研究都是采用模式识别技术来处理少数几种动作类型。然而, 在外骨骼设备的设计过程中, 我们不仅仅希望它们能在残疾人士的生活中发挥作用, 还要尽量模仿健康人群的手臂功能, 包括执行多种任务、保持稳定的运行状态以及自然流畅地操作。

基于 sEMG 控制的智能外骨骼是一种可穿戴的机器人装置, 通过检测和分析用户肌肉活动产生的表面肌电信号, 提供辅助或增强运动功能的设备。其在康复医学和智能外骨骼控制等应用领域具有重要的研究意义和使用价值。sEMG 能反应神经和肌肉运动的功能状态, 且超前于人体动作的产生。而实现控制的基础是对运动意图的识别, 这一过程分为离散运动识别和连续运动估计。近年来, 随着人工智能兴起, 深度学习为该领域提供了新途径。然而, 目前仍有一些问题亟待解决。对基于 sEMG 的控制技术而言, 多数基于传统特征和其他多种信息源的融合方法中传统特征的提取较为复杂繁琐, 连续运动估计中常用的循环神经网络 (Recurrent Neural Network, RNN) 及其变体模型会存在梯度爆炸和无法并行处理等问题, 基于传统离散控制的外骨骼灵活度较差, 多数外骨骼机器人的鲁棒性较差。

综上所述, 基于 sEMG 的运动意图识别是实现表面肌电控制技术在在外骨骼、康复机器人等领域应用的关键技术之一。现有的算法在上述 3 个方面均存在不足。在研究以上 3 方面的内容时, 均需要重点考虑如何构建具有鲁棒性、实时性和准确率高等特点的识别方法。本研究拟根据 sEMG 身的数据特点, 设计端到端且更关注时序信息的模型。本论文的研究将为基于 sEMG 控制的智能外骨骼发展提供新的研究思路, 具有一定的意义。

1.2 国内外研究现状

sEMG 作为一种能够直观反映人类活动过程的生物信号, 经过其收集、预先处理之后, 可以借助相应的算法解读为与之相对应的动作类型, 从而实现人机间的互动交流。肌肉神经元活动的调控不仅仅适用于工业制造领域的操作管理, 更为关键的是在外骨骼设备上的运用。对于智能外骨骼而言, 肌肉神经元的精确操控将会促进人机协作和人机一体化的进一步发展。

1.2.1 表面肌电产生的机理

人类身体的神经系统负责调控肌肉活动的基本单元称为动作单位 (motor unit, MU), 它一般包括每根脊柱神经元、它的神经束 (轴突终端) 和它们管理的骨骼肌纤维构成。在肌肉未受刺激的状态下, 骨骼肌细胞内部的钾离子含量超过外部, 反之亦然, 这导致了细胞膜内的电压低于外部且后者大于前者, 从而产生了一个介于 -80mV 至 -90mV 之间的大约 10mV 的电势差距, 这个差别常被称为静态电位。然而, 如果肌肉受到刺激并开始收缩, 脊髓 α 型运动神经元的前部细胞就会被激发, 进而引发从神经向肌肉传递的信息。当神经兴奋的指示性信号导致肌体末端神经释放一种称作乙酰胆碱的神经递质时, 它引发了骨骼肌纤维的膜渗透性变化。这一变化触发外部钠离子进入细胞和内部钾离子离开细胞的运动, 导致细胞内部电位升高、外部电位降低, 产生去极化现象。当去极化达到特定阈值, 离子泵开始工作, 将细胞内的钠离子排出并使外面的钾离子进入, 由此导致内部电位降低、外部电位升高, 即细胞经历了复极化过程, 这种电位差的复原持续至静止电位恢复^[26]。这样在脱极化和复极化期间形成的电位波动是神经信号传递过程中的核心机制。一般称之为动作电位 (action potential, AP), 而一组运动单元所指挥的全体骨骼肌纤维生成的电位总和, 被定义作运动单位生成的动作电位 (Motor unit action potential, MUAP)。采集 MUAP 信号主要有两项技术^[27]: 其一是借助类似针筒或纤细的电极直接刺入肌肉内部, 有效捕获特定区域的 MUAP 信号。这类刺入法虽能获得较高精度的信息, 但因其具有较强的侵入性, 可能对身体造成一定伤害, 因此, 该方法多在临床研究试验时应用。其二是利用放置在外部肌肤上的传感器来收集 EMG 数据, 这可以捕捉到整个被刺激部位的所有活动单元的活动模式总和^[28]。相较于传统的植入型肌电记录仪而言, 这种方式无法排除由皮下结构产生的干扰因素如呼吸和心脏跳动引起的干扰, 此外也会受到环境中的高功率设备或者其他电气设备的影响而产生额外的背景干扰, 这些都使得它的信噪比较低。然而, 这个方法最大的优势在于无需手术即可完成操作并且不会造成任何身体伤害, 因此具有更大的实用性和灵活度^[29]。基于此项技术的进一步研究表明, 可以通过对其深入剖析预测出人类行为的目的, 以便更好地融入外部机械臂的设计中使其更加人性化。

在前臂区域, 共有六组肌肉负责执行各种手指活动^[30]。这表明, 每个手指运动可

能与多块肌肉有关联，其中大多数手指操作是通过前臂的多组肌肉协同工作来实现的。图 1.1 展示了一系列主要由前臂肌肉驱动的手势图像，从中可以看到这些手势一般都是由前臂肌肉推动的。在 6 个肌肉群体中，只有 1-3 个参与了手部动作^[31]，这表明在每一次手部动作中，只有前臂的部分肌肉群发挥主导性作用。




图 1.1 不同手势中起主导作用的前臂肌群示意图^[31]

sEMG 的独特优势在人机交互领域得到了广泛应用，因此国内外对其的研究也在逐渐增多。这种基于 sEMG 的控制技术已经被广泛运用于智能外骨骼运动恢复、手术后康复训练以及临床医学和神经科学等各个领域。特别是在生命科技及医疗器械行业内，其关键在于运用此种方法来从 sEMG 信号里提取特征和编译以达到精确且稳定的动作辨识的目的。

sEMG 应用于肌肉活动控制的关键是能够精确解析人类的运动意图信息，这种方式可以被划为两个主要类别：第一种是以 sEMG 为基础，识别身体部位的活动，例如手的动作、步伐分析等^[32]；第二种则是利用 sEMG 预测人体的持续运动数据，比如关节的角度、力和角速度等变量，从而达到更高级别的四肢操控能力^[19,20]。接下来本课题将对这两种肌电控制技术的方法进行详细阐述。

1.2.2 基于表面肌电的动作识别

在当前的肌电控制机器人中，动作分类是一种常见的技术手段，特别是在智能外骨骼产品上得到大量运用。通常，该过程包括收集和过滤 sEMG 以获取特征，接着使用分类器算法解读人类的运动目标，并以此操控机械装置。现阶段，动作分类的主要实施方法可以概括为基于模式识别的肌电控制策略和采用深度学习的肌电控制策略两类。由

于深度学习具有强大的数据匹配和特征自动提取能力，能够挖掘肌肉活动中的潜在特性，因此它逐渐成为肌电控制领域的焦点问题^[33]。

1) 基于模式识别的肌电控制方法

在上肢外骨控制系统中，模式识别技术被广泛用于肌电控制，其操作步骤如下：首先，收集并分析不同运动状态下特定的肌肉 sEMG 数据；然后，通过预处理来分离有效的部分，提取信号特征；接着，建立分类器的模型，把获取到的肌电样本分为训练集与测试集；最后，选定表现最优的模型进行实际运用，具体的流程如图 1.2 所示。

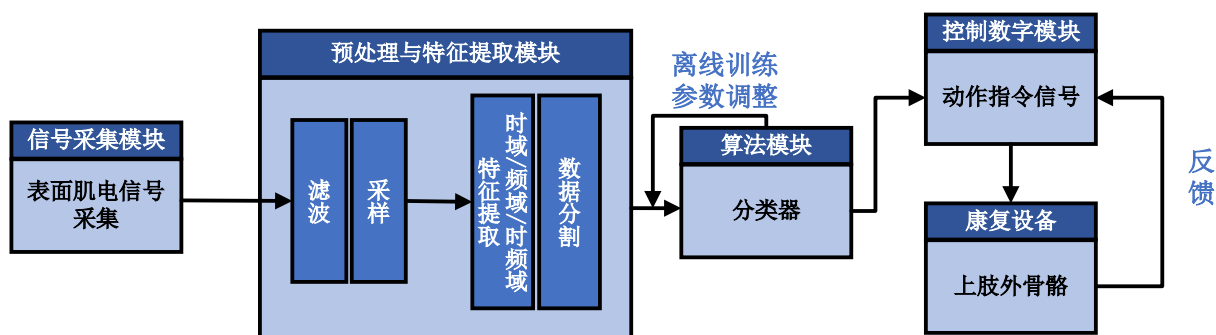


图 1.2 基于模式识别方法的肌电控制方案示意图

在这种控制方式中，提取肌电特征和建立分类器模型是确保精确且稳定控制的重要环节。sEMG 的特性很难通过数学公式精确表达，现有的高效特征提取方法尚无法完整地捕捉其全部有用信息^[34]。所以，许多基于模式识别的控制研究更侧重于从 sEMG 中获取特定的特征，这些特征可以用来描绘不同的运动模式下的肌电信号，而特征的质量高低极大地影响着模型识别的正确率。接下来，将详细讨论特征提取方式、特征降维方法及分类器模型的相关进展与现有成果。

a) 特征提取方法

肌肉活动产生的 sEMG 特征可划归为三个类别：时间域包括平均数、标准偏差及幅度总量等等以波动强度作为基础的信息获取方式；频率域的特点是利用快速傅里叶变换来捕捉来自神经活动的特定模式信息；最后一种则是结合了离散小波变换和小波分解技术的综合应用所获得的时频域^[35]。

初始阶段，运动的生物电信号辨识工作，通常仅采用独立的特征作为分析判断模型的输入^[36,37]。为了确保精准辨识手势动作，该领域内的权威人士常常基于各种信号属性进行手势动作的鉴别效果评估，并人工选出若干高效辨识手势动作的信号属性构成特征用来进行手势辨识，这些建立的信号属性集合俗称为“特征集”。近些年来，相关研究在这一领域提出并实践了不同的肌电信号特征集进行手势动作辨识，并验证了它们在识别肌电手势动作中的效果。举例来说，一项研究报告针对 NinaPro 数据库的三个子集进行了研究，探讨了肌电信号的不同特征，证实了七种特征组合可以达到最高 75.32% 的手势识别精度^[38]。

b) 特征降维方法

sEMG 中的多个通道所产生的信号特性常常拥有较高的维数，这会带来极大的计算难度并且影响到分类器的泛化能力^[39]。为了避免这种情况的发生，一般会在使用这些特征来训练分类器模型前采用特征降维技术对它们进行压缩。常用的特征降维策略有两种，分别是特征提取和特征筛选。

特征提取是指利用特定的映射或融合方法，将高度复杂的特征域转换至较低维度的特征域的技术。有研究在基于 sEMG 的手势辨识过程中应用了主成分分析（Principal component analysis, PCA）法来实现对原始特征领域的 48 维向量降低至 8 维的过程^[40]。此外，有研究提出了一种结合 PCA 和自组织特征映射（Self-organizing feature mapping, SOFM）的特征提取策略，该方案能使经过 PCA 处理后的肌肉活动信号特征域被进一步映射到一种具备更高类别区分能力的空间内^[41]。

特性筛选也被称为特征集合挑选，其核心是利用各种寻优策略和评价指标来选取与特定类别的关联程度高、信息量少的特殊特征替代原本的所有特征和它们所代表的信息内容，以此减少数据模型中的变量数量并提高分类精确度。

c) 分类器模型

在手势分类技术中普遍采用的几种模型涵盖了线性鉴别分析（Linear discriminatory analysis, LDA）、支撑向量机（Support vector machine, SVM）以及隐形马尔可夫模型（Hidden Markov Model, HMM）等。线性判别分析是由 Fisher 提出的一种线性分类模型^[42]，其优化目标是“最大化类内散度矩阵和类间散度矩阵的广义瑞利商”。在基于 sEMG 的手部动作识别中，研究者们倾向于使用线性判别分析，因为它具有高性能和较低的计算负载。有研究表明，通过从 sEMG 中提取特征并输入线性判别分析，可以识别出 26 种手部动作，准确率达到 92.9%^[43]。而有研究也表明，使用线性判别分析对 sEMG 进行分析，可以取得不错的结果^[44]。

2) 基于深度学习的肌电控制方式

近些年，深度学习的进步使得它在各个科学分支的研究上得到广泛关注。从最初被文献^[45]提出的深度学习，已经在如计算机视觉^[46]、语音辨识^[47]及自然语言理解^[48]等方面取得重大突破，这为人机交互、人脸识别、无人驾驶汽车以及机器人操作等商业化项目的迅速实施提供了支持。为了提高肌电图在离散的手势识别中的分类效果，研究人员已经将其用于肌电图特征提取和动作识别分类的过程，从而实现了更稳定的和精准的肌电控制^[49,50]。相较于传统的模式识别方法，当面临复杂任务和多种手势识别时，利用深度学习是更好的选择，可以提高识别的准确性和表现。随着卷积神经网络和循环神经网络的逐步成熟，它们在肌电控制领域也开始被应用于动作识别。其流程如图 1.3 所示。

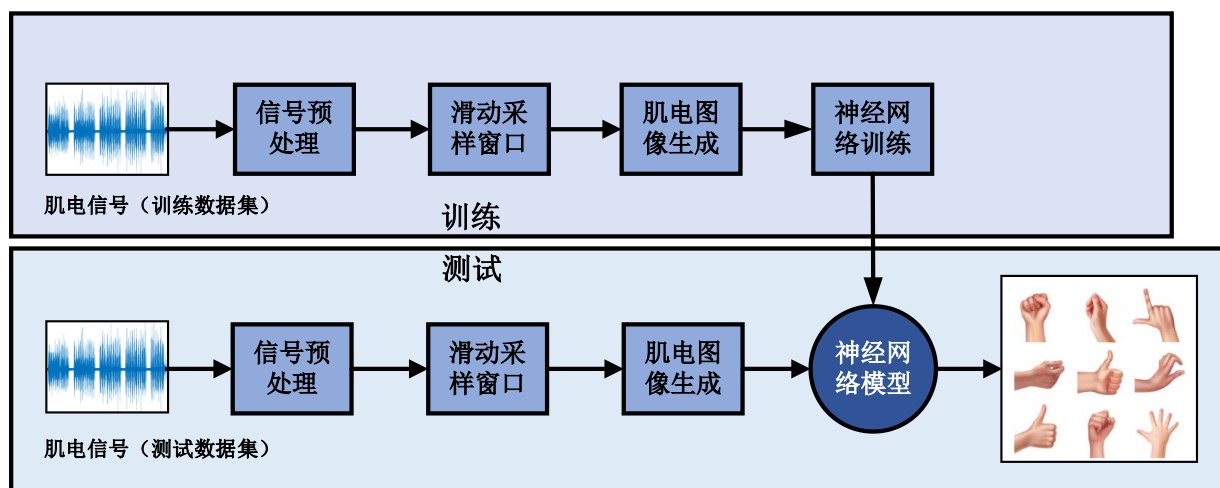


图 1.3 基于传统机器学习的肌电手势识别框架

有研究提出了针对肌肉运动神经元信号的新型手部动作模拟策略，该方法采用的是持续的小波变换（Continuous Wavelet Transform, CWT）来处理 sEMG 产生的图像并将其作为卷积神经网络（Convolutional neural networks, CNN）和 LSTM 的训练样本，实验结果表明其机器人学数据库上的精确度高达 99.72%，这进一步证实深层的学习模式也能在大规模开放式测试平台获得不错的结果^[51]。

当手部动作类别的数量增多时，利用模式识别的手势识别系统的稳定性和精确度的可能会受到影响，这主要是因为任务变得更加复杂了。然而，如果识别的目标仅为少数类别并且它们之间存在高度相似性的话，该系统还是可以胜任工作的。在 sEMG 信号进行手势识别的过程中，关键在于如何挑选合适的特征，优秀的特征设计往往依赖于领域内的先验信息。另一方面，深度学习也被称作特征学习，它能够在大量数据的基础上提高模型的通用性和稳定性。通过使用神经网络层层学习的方式，模型可以从各种手部运动中获取深层次的相关特性。这一由数据驱动的方法有助于解决基于模式识别的肌肉活动检测中的特征选择问题，进而优化识别系统的性能。在上述分类算法的应用中，神经网络算法通常取得了更好的分类效果。相关分类工作较多，表 1.1 总结了近年来神经网络算法在上肢运动意图分类中的典型应用。

表 1.1 上肢运动意图分类算法总结

时间	神经网络算法及其结构	sEMG	动作	分类精度
2021 ^[52]	包含 3 个隐层的深度前馈神经网络算法	16 通道, 选用 6 个时域特征	NinaPro 数据集中的 DB5 数据集和 DB7 数据集中记录的 41 种手部动作	对 DB5 数据集的总体准确率为 $93.87\% \pm 1.49\%$, 全类平均准确率为 $84.00\% \pm 3.40\%$; 对 DB7 数据集的总体准确率为 $91.69\% \pm 4.68\%$, 全类平均准确率 $84.66\% \pm 4.78\%$
2021 ^[53]	结合 TL 的 CNN 以及 CNN+LSTM 算法, 其中 CNN 具有 2 个卷积块和 1 个全连接层; CNN+LSTM 算法有 2 个卷积块、1 个全连接层和 1 个 LSTM 层	使用 4 个 sEMG 电极阵列采集 128 通道肌电信号	源手部动作集有 30 类手部动作, 3 个不同的目标手部动作数据集分别包含 30 类手部动作、10 类手部动作、8 类手部动作	结合 TL 的 CNN 在 3 个目标手部动作集中分类精度分别为 $92.13\% \pm 4.5\%$, $93.32\% \pm 3.9\%$ 和 $91.18\% \pm 6.25\%$; 结合 TL 的 CNN+LSTM 模型的分类精度分别为 $93.73\% \pm 7.03\%$, $97.34\% \pm 3.79\%$ 和 $94.57\% \pm 6.77\%$
2021 ^[54]	基于自组织映射的径向基神经网络算法	8 通道, 6 个时域频域特征	8 类手部动作	平均准确率为 $96.88\% \pm 2.73\%$
2021 ^[55]	单隐藏层 BP 神经网络算法	2 通道, 选用 2 个时域特征	6 类手部动作	尝试用更少的机电通道和特征进行分类, 平均分类精度为 95.46%
2021 ^[56]	单隐层神经网络、三隐层深度神经网络	7 通道, 提出高阶统计量—频域特征集	5 个上肢位置的 8 类手部动作	深度神经网络具有最高的准确率, $97.84\% \pm 0.22\%$, 单隐层神经网络的准确率为 $94.11\% \pm 1.63\%$
2020 ^[57]	CNN 算法, 包含 2 个卷积块和 2 个全连接层	12 通道, 肌电信号滤波后直接使用	肩部 4 类动作 (放松、喝水、前后运动、外展运动)	测试跨个体、速度变化以及机电传感器型号对 CNN 模型的影响, 预测精度范围 $69.96\% - 97.57\%$

1.2.3 基于表面肌电的关节角度预测

机电控制的核心诉求是能够自然、连续且平滑地完成操作, 可通过关节角度预测模型来估计和分析人体动作的变化情况并将其转化为外骨骼实际操作过程中的有效信息。依据 sEMG 进行关节活动持续预测的策略包含三种类型, 分别为建立在肌肉生理知识上的模型、利用经典算法构建的回归模型和应用深度学习技术的回归模型。

1) 基于肌肉生理学的模型

Hill 模型是一种用于描述肌肉收缩力的经验性数学模型，由 Archibald Vivian Hill 于 1938 年提出。该模型将肌肉收缩力分解为主动张力和被动张力两个组成部分，其中主动张力是由肌肉主动收缩产生的力量，而被动张力则涉及肌肉的弹性特性和与关节及组织连接相关的力量。该模型的核心方程式包含激活函数和阻抗函数，用来描述肌肉在不同激活水平和速度下的力学行为。Hill 模型的参数通常通过实验测量获得，并且可以调整以模拟不同类型的肌肉收缩情况，例如等速、等长和等力收缩。然而要获取人体的肌肉模型是一项非常复杂的工作，因此该模型在工程领域的应用较少。其结构如图 1.4 所示。




图 1.4 Hill 模型的结构图

2) 基于传统算法的回归模型

采用回归分析的方法涉及构造电生理信号与动作一致性量化关系的数学模型，该方法依靠搜集信息来训练模型，形成了复杂的输入与预期输出之间的相互映射。其核心思想是选用合适的模型进行数据解译，且在这个过程中不必涉及生理学理论或复杂的运算过程。在深度学习技术还未广泛推广之前，经典回归分析技术主要涵盖了线性空间模型、复杂多项式模型及非负矩阵分解等。已有研究通过空间模型完成对手指的精确比例控制任务，评估了手指关节的活动情况，并在实验中实现了对 10 个自由度的手指关节以及电生理信号的配准。在仅用 8 个信号通道的实验中，取得了平均反应时长仅为 0.824 秒且 R2 值达到 0.924 的同步效果^[58]。

3) 基于深度学习的回归模型

随着深层神经网络特别是循环神经网络在时间序列分析中取得显著成效，不少研究也开始探索深度学习在肌电图信号关联的持续性动作估测领域的应用潜力。考虑到肌电信号本身的非稳态特性以及人体动态的复杂多变，开发 sEMG 与身体关节转角对应的准确数据模型颇具挑战。然而，依靠深度学习框架下的神经网络，通过层叠的神经元实现级联式的学习过程，有可能克服这些障碍。

通过实现复杂映射机制,连续动作预测中预期角度与实际角度偏差得以减少,从而提升控制过程的准确性。应用深度学习技术对连续动作进行估计,研究焦点通常集中在肩部、肘部或者手部抓握动作。有学者研究中搭建了一个人工神经网络模型用以测算手部运动中的五个指关节的弯曲角度,该网络模型通过摄取肌肉电信号中的平均绝对值(Mean Absolute Value, MAV)、波形长度(Waveform Length, WL)以及波形幅度比(Waveform Amplitude Ratio, WAR)等特征作为输入训练而成,实现了在 15% 以内的真实角度与预估角度之间的相对误差^[59]。另一项研究运用了 BPNN 对四种肩关节运动包括屈曲/伸展和外展/内收进行了预测分析,采集 sEMG 的均方根作为时域特性输入这一网络进行学习训练,并且构建了虚拟仿生人模型以模拟出推算得到的关节角度,研究成果印证了运用深度学习进行关节动作预估的实际可行性^[60]。在一项研究中,研发者开发了一种准确度约为 80% 的基于气体动力的上肢助力外骨骼装置,利用 BPNN 模型来预测肢体动作的关节角度,从而使得用户能够通过意念即时操纵外骨骼^[61]。而另一项研究^[62]则介绍了一个应用 sEMG 的时延递归神经网络(Time-delay Recurrent Neural Network, TDRNN),用于预测手及腕部的多自由度运动,包括腕部的屈曲/伸展、尺侧外展/内收以及手的开合,其离线测试的 R^2 值介于 0.81 与 0.94 之间,该成果展示了 TDRNN 在控制上肢外骨骼手臂动作方面的快速响应性,并证明了深度学习技术在外骨骼操控领域具有的实用性与高效率。

深度学习技术之所以有优势,在于它能够自动挖掘数据内的深层次特性,有效规避手工特性提取带有的主观性与局限性,并且充分利用个体间数据的不同,以增加算法的泛化能力。所以,在智能外骨骼控制领域,利用深度学习进行肌电信号控制,将成为研究领域内的一个新焦点。

1.2.4 基于表面肌电的外骨骼控制方法

通过诠释 sEMG 所展现出来的肌肉收缩和关节活动状况,将其转化为对应人体意图的操作指令,并用以激活智能设备的技术被称作肌电控制。该技术在最近几年内受到了广泛关注,它作为新型的人机互动方式,在助力外骨骼、医疗康复设施等众多应用领域中得到推广,并在电子产品消费等方面展现了极具前景的市场潜力。详细而言,肌电外骨骼依据分析截肢患者遗留部位肌肉的 sEMG 来断定其行动意图,并据此指挥外骨骼的运动,协助他们在日常生活中恢复行动自如。

在消费性电子产品领域内,利用肌电信号进行的手势识别与操纵技术已逐渐成为近几年研究的焦点。传统上,人们通过运用计算机视觉技术或数码手套来识别手部动态。然而相较于计算机视觉手势识别方法,肌电信号控制技术不仅成本更低,可携带性更高,且不会受到周围噪声、光照条件及遮挡物的干扰。此外,与数据手套技术相比,肌电信号手部动态捕捉装置可佩戴在前臂,形似手表,免去了直接装备在手上的需求,这一点可大幅提升与机器互动时的用户感受。

远在 20 世纪五十年代前期, 研究者们已初探肌电控制技术的基础。1948 年, 来自德国的专家 Reinhold Reiter 开发了依托单一肌电信号驱动的机电式外骨骼装置, 预示着全球首款肌电驱动外骨骼的诞生^[63]。1960 年, 前苏联科学家第一次将肌电外骨骼应用于临床, 打造出首个具备实际应用价值的前臂肌电外骨骼, 该外骨骼借助上臂发出的生物电信号实施单一自由度的操控^[64]。自 20 世纪 70 年代起, 研究人员逐步推进具有多个自由度的肌电外骨骼技术研究。几十年的不懈努力使得肌电操控技术向着模仿真实人体肢体功能的控制方向稳步发展, 形成了以阈值控制、比例控制和模式辨识控制为三大核心的控制方法。其中, 阈值控制是基于比较生物电信号的幅度与事先设定标准的决定性控制策略, 能实时调节操控, 当生物电信号的幅度超过预设置阈值, 系统便会按照指定速率或力度启动并操纵机电设备^[65]。这类策略亦即“开/关”控制, 它仅仅响应“启动”和“停止”两种状态的指令。由于其响应迅速和较强的稳定性, 这种策略已广泛应用并达到商业化^[66]。而比例控制方法则根据 sEMG 的幅度变化成比例分配至肌电驱动设备的反应强度, 如调节速率或力度等^[67]。由于此法具备操纵多自由度的可能性, 比例控制被广泛认为具有更大的潜力。

模式识别控制是针对多外骨骼多自由度控制中的一个高效的方法, 其核心是以肌电信号作为最终控制决策的输入。该技术的标准流程包含以下环节: 首先, 从诸多 sEMG 采集通道中提炼出能够反映动态模式的数量特质。然后, 创建一个分类器以辨识特殊的活动模式。最终, 将识辨的结果转换为操控信号。该技术的基础依据在于, 相同动作模式的 sEMG 特性间具有一定的共性, 而不同动态模式的 sEMG 特性则存在明显的区别。近年来, 研究开始倾向于使用同步辨识的方式实施基于模式识别的控制。采用同步辨识机制的策略在于对每个独立运动自由度设立各自的鉴别系统, 随后集合这些系统的判断作出最终策略, 目的在于提升操控的响应速度与顺畅度。遵循此方法, 已经衍生出多样的解决方案^[68-70]。有研究采用层级式线性判别分类模型, 实现了 2 个自由度的同步操控技术使得四种手腕和肘关节动作的平均鉴别效率达到 85%^[71]。另一项研究采纳了基于特定任务肌肉共同活动的多维度同步操控方法, 实践了 5 个自由度、依赖精密手指动态的同步操控。针对 36 种手部动作, 正常测试人群的平均辨认成功率超过了 90%, 而中风病患者的识别成功率也超过 80%^[72]。综合来看, 目前的研究主要集中于手腕和肘部关节相关的宏观动作领域。动作主要不包括那些需要用到手指和掌关节进行精密操作的细微动作^[72]。

1.3 总结及分析

相较于传统的模式识别技术, 深度学习能够自主地从大量的输入数据中提取到更深层的表征, 无需通过复杂的选择流程来确定特征。同时也拥有较好的性能, 但基于深度学习的肌电手部动作识别方法依然面临以下问题:

(1) 基于 sEMG 的非端到端运动意图识别过程繁琐实时性低。多数基于传统特征和其他多种信息源的融合方法中传统特征的提取较为复杂繁琐，需要人工选择适合不同任务的传统特征，计算时还需要考虑多特征融合的问题，这使得在进行连续运动估计时产生一定的时延导致控制很难保证实时性。

(2) 经典的时序模型会产生梯度爆炸且无法并行计算。循环神经网络的每个时间步都依赖于前一个时间步的输出，因此在正向传播和反向传播过程中无法直接进行并行计算。这使得训练过程变得相对较慢，尤其是对于较长的序列数据，训练时间会更长。并且在进行反向传播时，可能会遇到梯度爆炸等相关的困难。

(3) 对于每个手部动作，仅特定的前臂肌肉群承担主要功能，而且这些肌肉群因动作而异。尽管如此，大多数采用深度学习技术进行手势识别的方案仍然没有考虑到这个因素。

(4) 基于 sEMG 的上肢外骨骼控制方法鲁棒性较差。由于模型本身和使用过程中的一些客观因素（电极错位和皮肤汗液等）导致模型接收到的信号质量差同时模型本身的性能问题，限制了对外骨骼的准确控制。

1.4 本文结构

针对上述四个问题，本文在深度学习的框架内探讨了多流融合学习、transformer 变体结构以及深度学习结合模糊控制的双层控制结构，在上肢外骨骼控制系统中的应用进行了探索和尝试。主要研究内容分别用 4 个章节进行介绍，每个章节在研究问题和研究方法上的展示如图 1.5 所示。

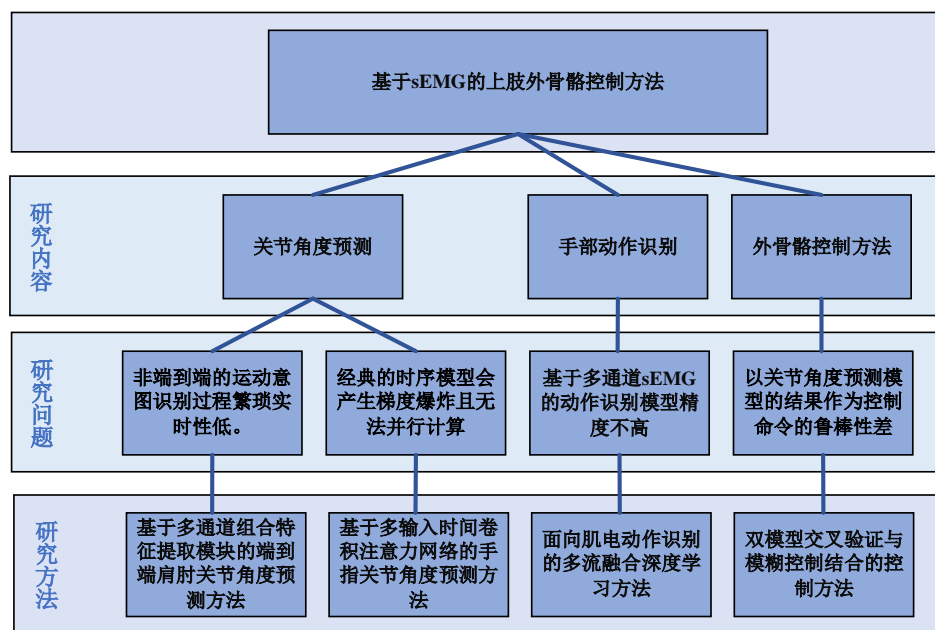


图 1.5 本文的组织结构和各章节关系

第 2 章提出一种直接将 sEMG 信号作为神经网络的输入预测关节角度的模型。为减小传统特征提取对实时性的影响,探究了直接利用经过初步处理的 sEMG 作为输入进行回归预测,减少了数据的前期处理步骤使其更适合应用在外骨骼控制领域。同时针对数据特点设计了模型特征提取层,进而能根据多通道 sEMG 提取到更多的信息,为后续的回归预测任务提供足够的支持。并将该模型应用在肩肘关节角度预测的任务中,通过基于实验采集相应关节的角度信息以及 sEMG,将其在该任务上的性能与卷积神经网络和多层感知机进行了对比,结果表明该模型在较少的复杂度下也能有优于其他模型的性能。

第 3 章,为了避免连续运动估计任务中的主流算法(循环神经网络及其变体)引入的梯度爆炸和无法并行计算导致的性能下降,本课题提出了一种基于多输入的时间卷积注意力网络(multi-input temporal convolutional attention-based network, MITCAN)来估计关节角。这种新颖的预后结构能够从时间序列数据中学习时间依赖性,并获得不同时刻的特征贡献,从而有效地将 sEMG 信号映射到肢体的关节角度。同时构建了一种联合训练机制,将 MITCAN 与 K-最近邻回归和支持向量回归等传统统计算法相结合。这种集成克服了循环神经网络和传统统计算法的固有局限性,有利于减少评估误差,提高预测效果。在公开数据集 NinaPro 上对其进行了性能验证,通过对比同一数据集上 LSTM 和 BPNN 的表现,可以发现 MITCAN 能有更出色的表现。

第 4 章,本课题利用前臂不同肌肉对不同动作的影响,提出一种基于多通道输入的多流融合模型,该方法首先将各通道进行多流表征并将采集的 sEMG 进行小波变换得到时频矩阵作为模型输入,然后建立基于前臂环绕电极分布的特点的特征提取模块,按照电极分布实现不同肌肉在动作识别时的影响权重,最后通过特征层多流融合并进行最终的动作分类。综合多种模型在公开数据集 NinaPro 上进行了模型在不同输入尺寸下的性能对比,以及在最优输入尺寸下主流网络与该模型的对比,得出结论是在最有输入尺寸(140ms)下多流融合模型有良好的表现。

第 5 章,针对依靠单一模型对外骨骼进行控制所产生的鲁棒性差的问题,提出一种根据手部关节角度变化的特点,针对手部关节角度预测的修正方法。首先,将手部单关节的结果对比同一手指的其他关节角度预测结果,再将其与手部动作识别的结果进行对比综合得出输出结果。同时针对外骨骼本身的误差以及信号采集部分的误差,引入模糊控制方法对最终的控制指令进行修正,以达到更好的控制效果。通过设计的实验对该方法进行了验证,结果表明在引入该方法后整体的预测精度有明显提升。

2 基于表面肌电的肩肘关节角度预测方法

2.1 引言

通过表层肌电信号捕捉丰富肌肉活跃的重要信息，分析这类信号有助于辨认人体的预期动态，并为控制上肢外骨骼提供了理论支撑。传统上，基于固定动作类别进行肌电波动的操控仍旧存在数量有限与一定限制的问题。一个理想状态下的先进仿生外骨骼应当和真实的人体运动一样，能够自由且灵活地完成各种活动。本章聚焦于应用深度学习技术，实现对基于 sEMG 的肩和肘关节角度的精确预测。该方向的相关研究主要集中在使用非端到端的模式识别技术来分辨不同自由度动作，但本质上这种方法仍然停留在对动作种类进行归类上，对连续运动估计的效果并不理想，同时引入人工进行特征提取内容繁琐。因此，本章尝试引入端到端的多输入 Transformer 模型对肩部和肘关节的角度进行角度预测，并使用多层感知机（Multilayer Perceptron, MLP）与 Resnet50 网络对本章提出的算法进行比较。

2.2 实验设计及数据采集

2.2.1 实验设计及数据采集

实验招募了 10 名没有上肢疾病的健康男性受试者，年龄在 23-28 岁之间，每个受试者都接受了实验动作的训练，并且所有人都被告知在实验前一天要充分休息。

实验在一个安静、封闭的房间，温度为 $26^{\circ}\text{C} \pm 2^{\circ}\text{C}$ ，以减少外界因素的干扰。实验前受试者将肱二头肌、肱三头肌、三角肌前、三角肌后和胸大肌附近皮肤剃光毛发并用酒精擦拭。将五对一次性 Ag/AgCl 差分电极（直径 5 mm）放置在肌肉腹部上方，电极间距离为 2 cm。测量关节角度的传感器放置在三角肌中束的下缘以及肘关节外侧的前臂上距离肘关节 5cm。本课题设计了不同肌肉优势下的运动实验，包括肘关节屈曲、肩关节前屈、肩关节后伸和肩外展。不同速度下的肌肉运动状态也会受到影响，每个动作都使用三种不同的速度完成：慢速（ $15^{\circ}/\text{s}$ ）、正常（ $30^{\circ}/\text{s}$ ）和快速（ $45^{\circ}/\text{s}$ ）。在每个实验中，受试者分别保持起始和关节限制位置 2 秒，并被要求完成 20 次肌肉收缩。此外，每个受试者被要求休息 10 分钟，以防止每次实验之间的疲劳。

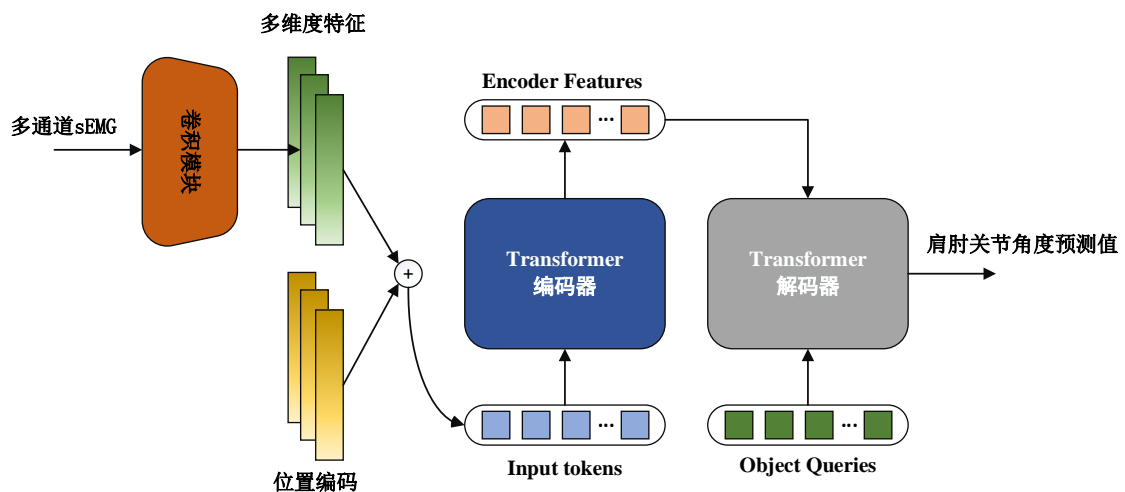
sEMG 信号是使用生理信号测量系统是 Delsys 生产的 Trigno™无线肌电记录系统采集的，采样频率为 2000 Hz。关节角度测量采用了 Delsys 提供的角度传感器，采样频率为 100 Hz。

2.2.2 数据预处理

原始 sEMG 信号在记录系统中通过 1 - 500 Hz 的 5 阶巴特沃斯滤波器进行处理，以消除高频噪声和直流分量，并使用 50 Hz 陷波滤波器消除电源线干扰。为了保证肌电信号与关节角度的同步，分别使用降采样和重采样将 sEMG 和关节角度都调整到 1000Hz。为了通过 sEMG 充分表示人体的运动意图信息，本章实验采用 147.2 ms 为滑动窗长对信号进行截取，每次截取完成当前窗口后，以 75% 的重叠向后滑动，即增量窗长为 25%。然后，将关节的角度与 sEMG 进行归一化处理，关节角度的值为 0~1 之间。最终将截取好的 147.2 ms 段的 5 通道 sEMG 按通道拼接成尺寸为 1472×5 的输入。之所以选择 147.2 ms 作为时间窗的大小，是因为在能保证实时性的前提下尽可能捕捉更多的信息，由于预处理中的滤波环节将信号截取为 1-500 Hz 之间的信号，故时间窗分割在时间维度上至少包含最低频率（1 Hz）的一个周期（1 s）对应到 sEMG 上应该包含（1000 点），而本课题所选择的所有滑动窗口大小均在时间维度上包含至少一个完整的周期。

2.3 肩肘关节角度预测模型

图 2.1 展示了所提出的多输入 Transformer 模型（Multi-Stream Transformer, MST）的结构。首先，频率为 f 的 sEMG 数据被归一化，并切分为固定时长 t 的段落。之后，被分段的 sEMG 数据样本被输入到基于 CNN 的主干网络中以提取特征。接着，结合位置编码，提取出的特征依次通过 Transformer 的编码器部分和解码器部分。最终，预测出相应关节的运动角度，这些预测是通过共享的预测头得出的。在训练过程中，根据最佳二部匹配计算一组损失，以此来对应真实值和预测值。



2.3.1 卷积模块

该模型的 CNN 主干网络接受分段的一维 sEMG 序列 $x_{sEMG} \in \mathbb{R}^{L_0 \times 5}$ 作为输入，其中输入长度 $L_0 = t \times f$ 。然后，一系列一维卷积层被应用于输入上，以生成更低分辨率的特征 $F \in \mathbb{R}^{L \times d_{model}}$ 。在这项工作中，特征长度 $L = L_0/64$ ，而 d_{model} 是模型的一个超参数。本课题构建了基于一维反向残差块的主干 CNN，这是从 MobileNetV2 中提出的反向残差块进行改编的。此外，在每个反向残差块的末尾使用了挤压和激励（Squeeze-and-Excitation module, SE）模块，以进一步提升主干的表示能力。

每个反向残差块的详细结构如图 2.2 所示，每层的配置在表 2.1 中呈现。所有的卷积层后都附带着批量一致性层和 RELU 激活层，唯独 Bottleneck 的最后一个卷积层仅与批量归一化相关。每个 Bottleneck 的第一个和最后一个卷积层使用的核大小为 1（逐点卷积），而深度卷积层使用的核大小为 3。使用宽度乘数 ϕ 来控制每个块的通道数，这有助于在计算需求和性能之间找到平衡。

表 2.1 卷积模块的参数配置

输入	结构	k	c	n	s
1472×5	Conv 1d	-	5	1	2
$736 \times [8 * \phi]$	Bottleneck	6	8	1	2
$368 \times [8 * \phi]$	Bottleneck	6	16	2	2
$184 \times [16 * \phi]$	Bottleneck	6	32	2	2
$92 \times [32 * \phi]$	Bottleneck	6	64	2	2
$46 \times [64 * \phi]$	Bottleneck	6	128	2	2
$23 \times [128 * \phi]$	Bottleneck	6	256	1	1
$23 \times [256 * \phi]$	Conv 1d	-	64	1	1

说明：其中 k 为特征扩展倍数，c 为通道数，n 为 Bottleneck 的个数，s 为 Bottleneck 第一层卷积的步长（除第一层外其他层均使用步长为 1 的卷积）。

2.3.2 Tnsformer 编码器

Transformer 的编码部分是通过重复相同结构的编码层构建，如图 2.3 所示。每个编码层都包括一个多头自注意力模块和一个只有一个隐藏层的前馈网络。这两个子层后面都跟有一个层归一化模块，并且这两个子层周围都有残差连接。

1) 缩放点积注意力：

利用 sEMG 之间的依赖关系构建的一种模型，其结构如图 2.4（a）所示。如前文所述，卷积模块的输出是一个张量 $F \in \mathbb{R}^{L \times d_{model}}$ ，其中 L 是特征长度。特征的每个通道被映射到三种信息源，即查询（query）、键（key）和值（value），大小分别为 d_q 、 d_k 和 d_v 。目标是将查询和键得到的权重应用到值上，从而更多地关注激活较高的位置。为

了获得这些权重，首先计算查询与所有键的点积，然后对每个值除以 $\sqrt{d_k}$ ，并进行 softmax 处理。 $\sqrt{d_k}$ 这个缩放因子也被称为温度参数，它有助于产生更平滑的 softmax 输出。最后，将权重通过向量的内积应用于值。在实际中，同时对所有通道执行上述计算。为了实现这一点，查询、键和值被打包进矩阵 $Q \in \mathbb{R}^{L \times d_q}$ ， $K \in \mathbb{R}^{L \times d_k}$ 和 $V \in \mathbb{R}^{L \times d_v}$ 中。缩放点积注意力的函数可以表达为：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2.1)$$

自注意力模块可以以恒定成本访问任何位置的特征，因此该模型可以捕捉同一段中不同 sEMG 之间的依赖关系，以生成更具代表性的特征。

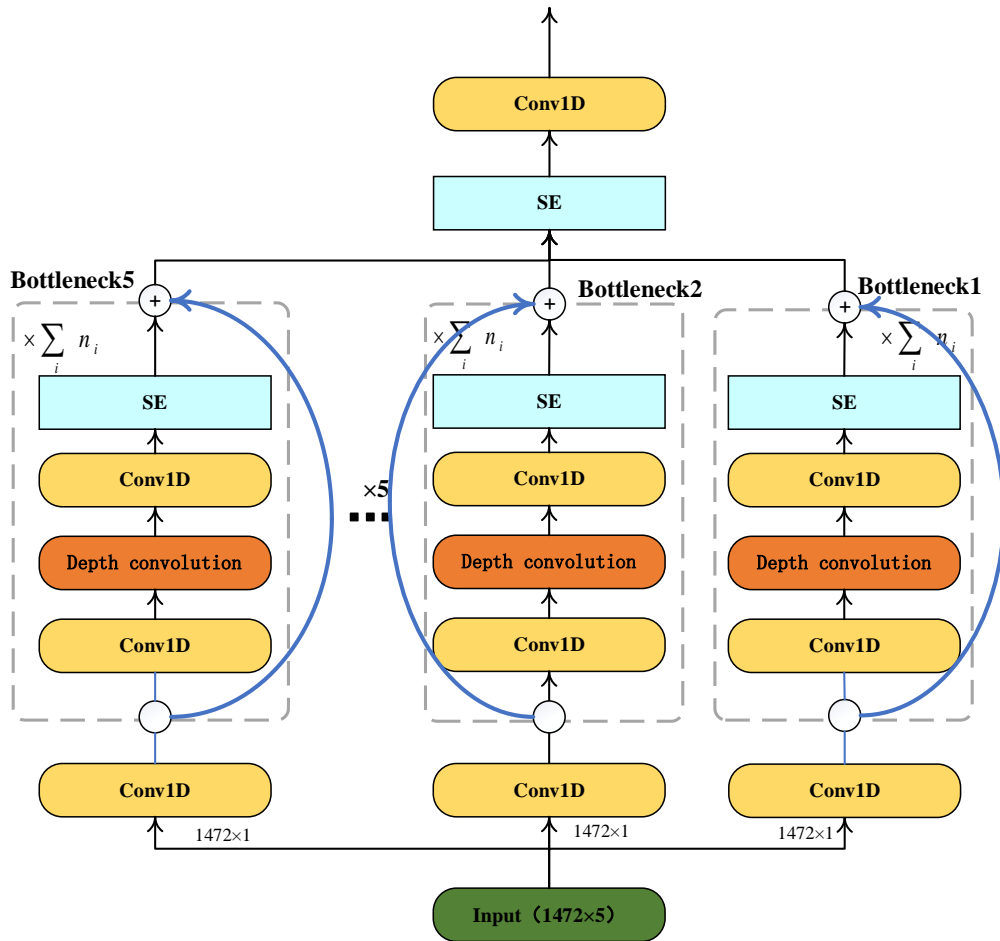


图 2.2 MST 卷积模块的结构

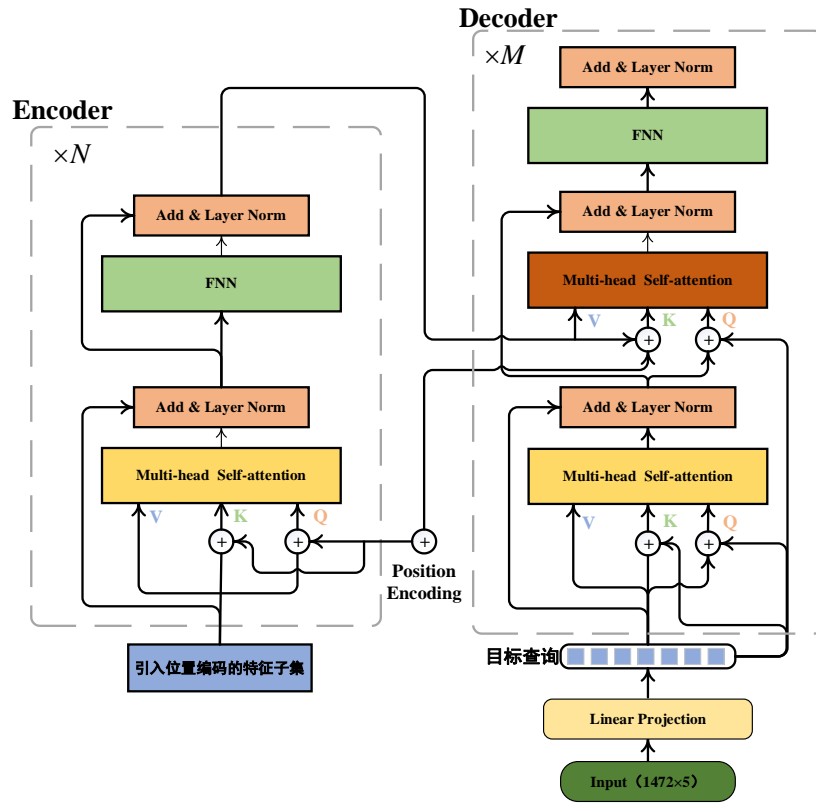


图 2.3 Transformer 结构

2) 多头注意力机制:

在图 2.4(b)中所展示的, 通过多头注意力机制可以进一步细化缩放点积注意力模块。输入特征被线性投影 h 次, 以获得 d_q 、 d_k 、 d_v 维度的 h 组 Q 、 K 、 V 。每一个头是一个缩放点积注意力模块, 所有的 Q 、 K 、 V 组分别独立地通过相应的注意力头运行, 其中 h 是头的数量。所有头的输出被串联起来, 然后送入一个线性层以产生最终输出。多头注意力的功能可以表达为:

$$\begin{aligned} \text{MultiHead}(F) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \\ \text{head}_i &= \text{Attention}(Q_i, K_i, V_i) \\ Q_i &= PE_1(F) W_i^Q \quad K_i = PE_2(F) W_i^K \quad V = F W_i^V \end{aligned} \quad (2.2)$$

线性投影矩阵 $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_q}$ 、 $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ 、 $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ 以及 $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ 是可学习参数的一部分。在公式 (2.2) 中的 PE_1 和 PE_2 是两个位置编码函数。在这项工作中, 一个典型的设定是 $d_q = d_k = d_v = d_{\text{model}}/h$ 。与单头注意力模块相比, 多头注意力因为能够集成不同头的信息而受益, 且在此设定下不需要额外的计算。多头注意力机制使得模型可以同时在不同位置关注多种表示子空间的信息。这个模块具有高度的并行性, 通过并行计算和高度优化的矩阵乘法代码, 其效率可以进一步提升。

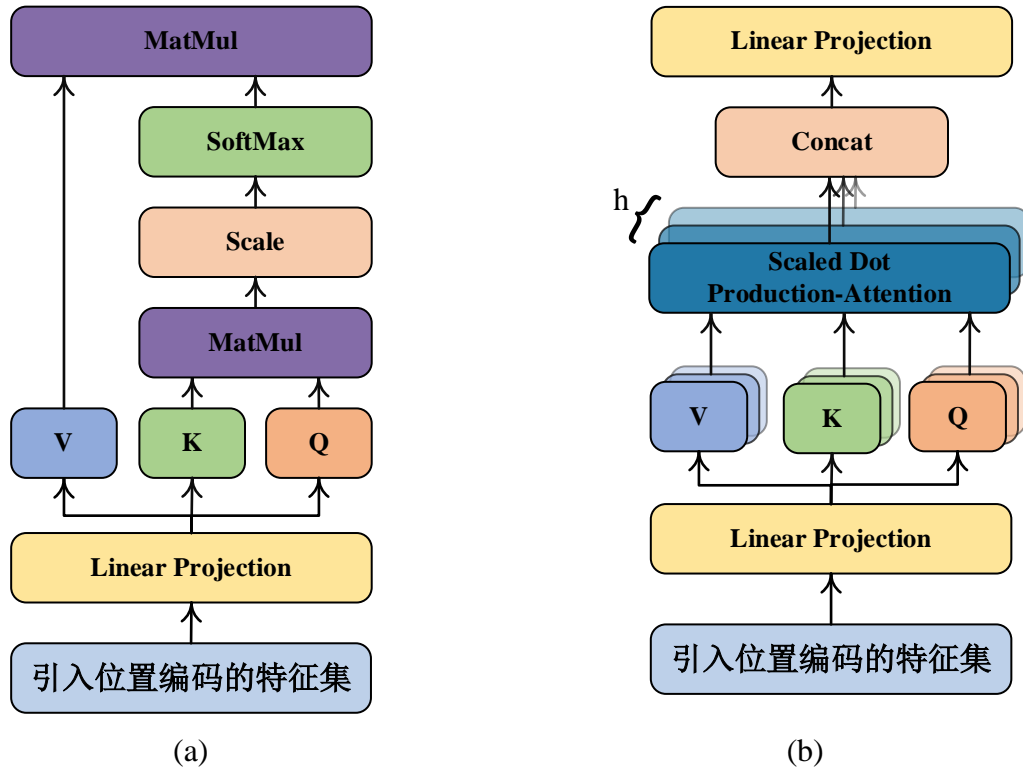


图 2.4 (a)缩放点积注意力; (b)多头注意力机制

3) 位置编码

排列不变性是 Transformer 的一个重要特征,为了在保持排列不变性的同时捕捉 sEMG 间的依赖关系引入位置编码。位置编码为每个数据点添加额外的信息,表明它在序列中的位置。这样,尽管模型的基础架构对输入顺序不敏感,位置编码可以让模型了解并使用 sEMG 在序列中的相对位置。上文提到的两个位置编码函数 PE_1 和 PE_2 (见公式 2.2) 被用来将相对或绝对位置信息注入序列的特征中。在位置编码函数中,位置嵌入被添加到输入特征 F 中。 PE_1 和 PE_2 在编码器和解码器的自注意层中共享相同的位置嵌入,如图 2.3 所示。然而,在解码器的交叉注意层中,它们来自不同的源。这种位置嵌入可以是可学习的,也可以是预定义的。由于这两种方法表现同样良好,其可以表示为:

$$PE(pos, 2i) = \sin(pos / 10000^{2i/d_{model}}) \quad (2.3)$$

$$PE(pos, 2i+1) = \cos(pos / 10000^{2i/d_{model}}) \quad (2.4)$$

● 前馈网络

每个编码器层的另一个子层是一个前馈网络,它由两个完全连接的层组成。除了多头注意力的输出外,还有一个残差连接将输入特征 F 输入到前馈网络中。这个子层的功能可以总结为:

$$\begin{aligned} FFN(F') &= ReLU(F'W_{ff}^1 + b_{ff}^1)W_{ff}^2 + b_{ff}^2 \\ F' &= F + MultiHead(F) \end{aligned} \quad (2.5)$$

其中 $W_{ff}^1 \in \mathbb{R}^{d_{model} \times d_{ff}}$, $W_{ff}^2 \in \mathbb{R}^{d_{ff} \times d_{model}}$ 是可训练参数的一部分。

2.3.3 Transformer 解码器

Transformer 的解码器部分是通过重复相同结构的解码器层构成的，如图 2.3 所示。与编码器层相比，有一个额外的多头注意力子层位于自注意力子层和前馈子层之间。这个子层被称为交叉注意力子层，因为它期望从编码器的输出中得到 K 和 V ，以及从前一个自注意力子层中得到 Q 。解码器的输入嵌入被称为对象查询 (*object queries* $\in \mathbb{R}^{N_q \times d_{model}}$)，其中 N_q 是查询的数量。对象查询是可学习的参数，也被用作自注意力子层中的位置嵌入和交叉注意力子层中的 PE_1 。对于交叉注意力子层的 PE_2 ，使用与编码器中相同的固定位置嵌入，如图 2.3 所示。

2.4 肩肘关节角度预测性能评价

2.4.1 预测性能评价流程

为充分探究各模型之间的性能差异，实验统一各模型的输入，各模型的输出目标为三通道的关节角度。采用 10 折交叉验证来评估三通道关节角度预测任务上的性能。具体地说，数据集将使用分层抽样策略分成 10 个子集。在每次训练中，将其中一个数据集作为测试集，剩余的数据集则被用作训练。对于该任务，两个模型都是从头开始训练的，并使用 Xavier 初始化进行初始化。在训练过程中，优化器选择自适应矩估计算法 (Adam)，以 η_{base} 的基本学习率训练模型。我们应用相关研究提出的 10 个周期渐进热身训练策略，这意味着学习率将从前 10 个周期的一个小值开始逐渐接近 η_{base} 。此外，学习率将根据以下公式衰减：

$$\eta_{cur} = \frac{\eta_{base}}{2} \left(1 + \cos \left(\frac{T_{cur}}{T_{max}} \right) \right) \quad (2.6)$$

其中， T_{cur} 是当前的 epoch， T_{max} 是最大训练 epoch 数。但是，当发生过拟合时，训练过程可能会提前停止。 η_{base} 是基础学习率， η_{cur} 是当前更新的学习率。训练的其他超参数如表 2.2 所示

本实验选择 MLP 与 Resnet50 作为对照组，Resnet50 是主流的深度学习结构之一拥有极强的特征提取能力，其独特的跨层信息交互结构（残差结构）解决了深度神经网络训练中的梯度问题。它作为分类和回归模型同样都有出色的表现，在进行实验前对其输入模块和输出层进行了修改，使其能接收不规则输入并给出相应的输出。而 MLP 作为经典的基础前馈神经网络，其特点是模型中所有的节点之间都是全连接且隐藏层与输出

层的节点上都有不同的激活函数，这使得 MLP 拥有较强的表达能力。本实验基于实际的任务设计了适配的 MLP，其中间隐藏层设计了 60 个节点，输出节点有 3 个。本次实验为了保证结果的准确性和可比性，统一了三个模型的输入（尺寸为 1472×5），以及超参数设置。且三个模型的所有参数学习均在实验所采集的数据上进行。

表 2.2 训练超参数

名称	参数
mini batchsize	128
初始学习率	0.01
学习率衰减因子	0.001
学习率衰减节点	10 epoch
训练轮数	200
损失函数	交叉熵损失函数
优化器	Adam

2.4.2 评价指标

针对模型训练完成后的性能评估，本研究采用了相关系数和均方根误差两种方法来综合评价不同模型在关节角度预测问题上的表现。下面将详细介绍计算公式。

1) 均方根误差（Root mean square error, RMSE）是一种常用的指标，能清楚地反应两组数据的拟合程度，其计算方式如下。

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (\theta - \bar{\theta})^2}{N}} \quad (2.7)$$

其中， θ 表示真实值， $\bar{\theta}$ 表示预测值； N 表示数据的个数。预测时，RMSE 的值越小，表示预测值和真实值越接近，拟合估计精度越高。

2) 相关系数

我们选用相关系数（Correlation coefficient, CC）作为精确性的标准。相关系数的计算公式如下：

$$CC(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var[X]Var[Y]}} \quad (2.8)$$

其中， $Cov(X, Y)$ 表示 X, Y 的协方差； Var 表示 X, Y 的标准差； $CC(X, Y)$ 描述了两个序列的线性接近程度。从数学角度看 $CC(X, Y)$ 越接近 1，表示模型的拟合性能越好。

2.4.3 评价结果

1) 相关系数（CC）的分析

分别将 10 名受试者的 2 个关节上 4 种动作的 CC 值进行平均，其结果如表 2.3 所

示,在不同个体中,MST、Resnet50 以及 MLP 的 CC 值均高于 0.75 说明通过深度学习的方法对肩肘关节的角度预测是可行的。从表 2.3 可以看出不论哪种模型本身对三个自由度的角度预测性能不相上下。从模型之间的性能来看 MST 在不同受试者中不同的自由度上对 MLP 有明显的优势,与 Resnet50 相比的优势没有非常明显。将每一个自由度下的所有受试者结果的 CC 进行平均后能更直观地发现,MST 不论是在肘关节屈伸、肩关节屈伸还是上举/下降,中都具有一定的优势。如图 2.5 所示,能更直观地看到不同自由度下每个模型的表现。单从 CC 这个指标来看,MST 模型为关节角度的预测提供了一个更好的方法。而图 2.6 详细展示了各模型在不同受试者上的效果,同样表明 MST 有更好的效果。

表 2.3 各受试者不同自由度下的各模型关节相关系数

受试者	MST			Resnet50			MLP		
	肘屈伸	肩屈伸	肩上举/下降	肘屈伸	肩屈伸	肩上举/下降	肘屈伸	肩屈伸	肩上举/下降
1	0.9133	0.9103	0.8611	0.9101	0.9071	0.8527	0.8541	0.8869	0.8233
2	0.8803	0.8107	0.8716	0.8415	0.8627	0.9041	0.8234	0.8544	0.8535
3	0.8914	0.9505	0.8308	0.9026	0.9109	0.8025	0.8513	0.8912	0.8145
4	0.8712	0.8466	0.9008	0.8298	0.9006	0.8814	0.8551	0.7903	0.8255
5	0.9218	0.8914	0.9116	0.8314	0.9080	0.8761	0.8995	0.8221	0.8124
6	0.9613	0.9317	0.9312	0.8732	0.8841	0.8936	0.8345	0.8513	0.8571
7	0.8807	0.9408	0.8802	0.8476	0.7031	0.8799	0.8421	0.8045	0.8646
8	0.8504	0.9008	0.8707	0.9321	0.8461	0.9106	0.8337	0.7992	0.7604
9	0.8916	0.9015	0.8403	0.8891	0.9021	0.8312	0.8345	0.8531	0.8663
10	0.8914	0.9104	0.9110	0.8617	0.9445	0.8543	0.8715	0.8774	0.8329
MEAN	0.895	0.899	0.881	0.871	0.876	0.868	0.849	0.843	0.831
±SD	±0.028	±0.042	±0.031	±0.034	±0.063	±0.032	±0.021	±0.035	±0.031

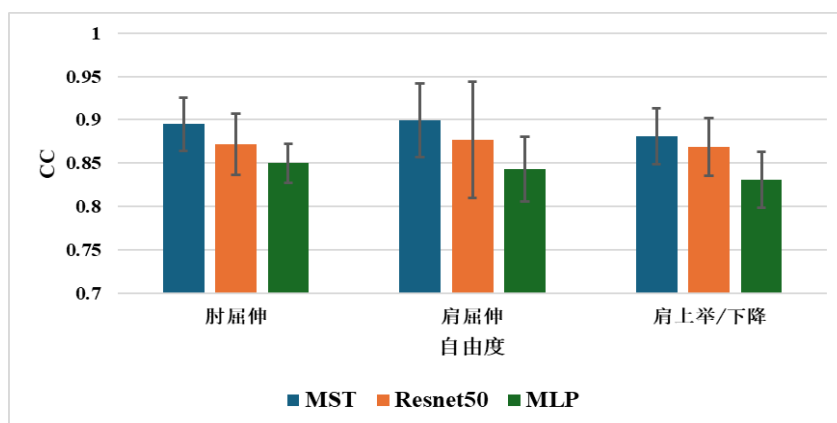


图 2.5 各模型在不同自由度上的相关系数 (按受试者平均)

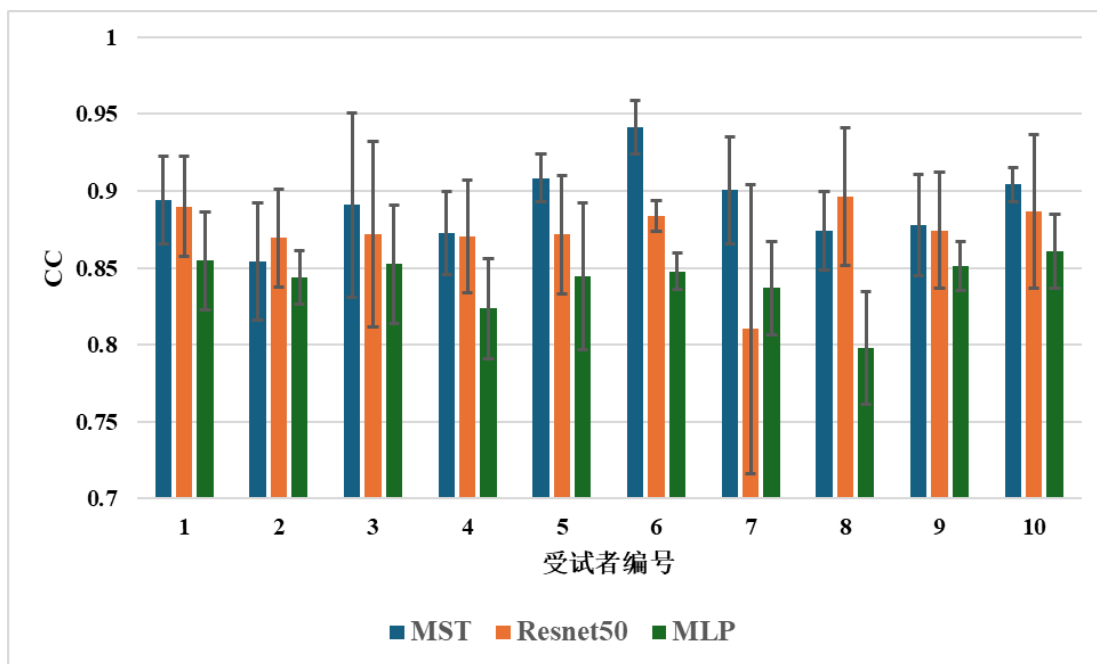


图 2.6 各模型在不同受试者上的相关系数（按自由度平均）

2) 均方根误差 (RMSE) 的分析

同样，实验分析了每种抓握动作中 RMSE 的测量精度，分别将 10 名受试者的 2 个关节上几种动作的 RMSE 值进行展示，结果如表 2.4 所示。在不同个体中，本文提出的 MST 模型的 RMSE 值均低于 4.0 且误差分布较集中（均小于 1）说明在不同的受试者之间该方法能平衡其中的差异。对 10 名受试者的 2 个关节角度预测值的 RMSE 平均值做了分析，如图 2.7 所示，采 MST 方法的受试者的预测结果都是最接近真实值的，其结果明显高于 MLP。同样的按照不同受试者进行平均，每个自由度下模型之间的性能差异非常大，同样的 MST 与 Resnet50 的表现好于 MLP。而图 2.8 详细展示了各模型在不同受试者上的效果，同样表明 MST 有更好的效果综上所述本章提出的方法，具有一定的效果。针对相应的问题能发挥本身的优势，模型的性能达到预期。




图 2.7 各模型在不同自由度上的均方根误差（按受试者平均）

表 2.4 引入控制系统后不同受试者不同关节的均方根误差

受试者	MST			Resnet50			MLP		
	肘屈伸	肩屈伸	肩上举/下降	肘屈伸	肩屈伸	肩上举/下降	肘屈伸	肩屈伸	肩上举/下降
1	3.51	3.48	2.988	4.473	4.443	3.899	5.592	5.92	5.284
2	3.18	2.484	3.093	3.787	3.999	4.413	5.285	5.595	5.586
3	3.291	3.882	2.685	4.398	4.481	3.397	5.564	5.963	5.196
4	3.089	3.843	3.385	3.67	3.378	4.186	5.602	4.954	5.306
5	3.595	3.291	3.493	3.686	4.452	4.133	6.046	5.272	5.175
6	3.99	3.694	3.689	4.104	4.213	4.308	5.396	5.564	5.622
7	3.184	3.785	3.179	3.848	2.403	4.171	5.472	5.096	5.697
8	2.881	3.385	3.084	4.693	3.833	4.478	5.388	5.043	4.655
9	3.293	3.392	2.78	4.263	4.393	3.684	5.396	5.582	5.714
10	3.291	3.481	3.487	3.989	4.817	3.915	5.766	5.825	5.38
MEAN	3.33	3.37	3.186	4.091	4.141	4.058	5.550	5.481	5.361
±SD	±0.307	±0.426	±0.325	±0.355	±0.668	±0.337	±0.222	±0.371	±0.321




图 2.8 各模型在不同受试者上的均方根误差（按自由度平均）

2.5 本章小结

肌电控制中，肩肘关节的稳定控制对智能外骨骼实现前臂动作非常重要。本部分内容通过对深度学习法与模式辨识法的功效进行比较分析，分别运用了协方差系数（CC）和均方根误差（RMSE）这两种统计评估手段，量化评估了针对 10 名健康人士肩膀和肘部三个自由度动态的逼真度。研究成果揭示，在估测不同受试者间的关节动作角度方面，MST 模型因其能长期跟踪关联性能，展现出更超群的一致性。同时，MST 模型能精确模拟真实的角动态曲线，有效降低了由于受试者个别差异引起的数据震荡。

3 基于表面肌电的手部关节角度预测方法

3.1 引言

手部关节角度预测对于上肢外骨骼而言至关重要，能为后者提供更丰富的应用场景同时面向更多的用户群体。而手部关节角度预测涉及多关节同步预测，为避免过于依赖先验知识采用与第 2 章相同的策略使用 sEMG 直接作为输入。sEMG 本身为一个时间序列其不同时刻之间的联系非常值得发掘，但传统的时间序列预测模型会引入梯度爆炸和无法并行计算等问题。针对上述情况本章提出一种基于多输入时间卷积注意力的网络（multi-input temporal convolutional attention-based network, MITCAN）来连续识别手部关节角度。并对 sEMG 信号进行分析，成功预测了手指各个关节的连续动作，采用了 NinaPro 公开数据库中 DB2 部分的肌电信号与关节角度数据，实现了对 20 个手指关节角度的高精度预测。另外，针对 MITCAN、LSTM 与 BP 这三种模型进行了比对研究，并对它们的模型拟合效果给予了参数化的评价。

3.2 数据描述

3.2.1 实验设计

在本章的实验部分，采用 NinaPro 上的 DB2 数据库，其中包含了来自 40 名健康参与者的 50 项手部动作的数据。这些参与者的年龄介于 23 至 45 岁之间。这 50 项动作被划分为三个类别：E1：包括八种等距等张的手部运动和九种基本的腕部动作；E2：包括了 23 类不同形状的握持动作；E3：涵盖了 9 种压力模式下的指尖按压行为。为确保研究结果具有代表性和多样性，本实验在五名年龄、性别和惯用手不同的 s 受试者身上进行了试验。他们的年龄跨度从 25 至 31 岁不等。此外，选择了六种活动范围和物品形状各异的抓握动作作为测试样本，它们分别是 M1（宽握）、M2（窄握）、M3（中握）、M4（细棒式抓握）、M5（圆形抓握）和 M6（盘状抓握），如图 3.1(a)所示。肌肉电信号是由 Delsys Trigno 无线肌电传感器收集并记录（共有十二路输入），采样频率设定为 2000Hz。前臂和上臂部位的皮肤表面安置有 8 个等距离排列的电极，另外两个分别位于肱二头肌和肱三头肌处，最后的两个则是置于拇指弯曲肌群与食指伸展肌群之上。由于本实验着重考虑手指关节角度的预测，所以只选择和手指动作相关的关节角度，所采集到的关节角度采样率为 20Hz。采集设备如图 3.1(b)所示，涉及的关节为 1-20 号。

整个实验过程包括两个阶段：训练阶段和验证阶段。参与者佩戴上数据手套并放置好 sEMG 传感器后，按照计算机显示的手势来模拟执行相应的动作，每种动作执行 6 次，每次时长为 5s，中间会有 3s 的休息时间，防止肌肉过度劳累。

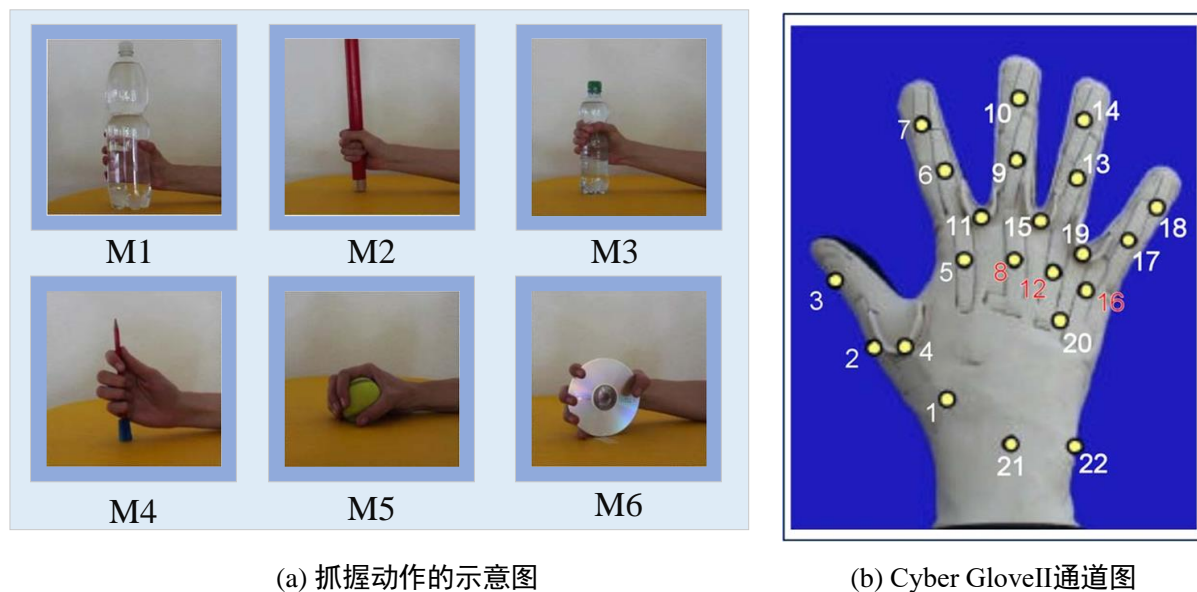


图 3.1 实验相关信息

3.2.2 数据预处理

该数据集中的已经进行了 sEMG 与关节角度的采样率同步，以及动作标签数据的校准。根据频率的分布，选用 4 阶 5-450 Hz 的巴特沃斯滤波器对信号滤波。使用线性插值的方式，让 sEMG 和关节角度信号在时间维度上匹配。将 sEMG 和关节角度归一化到 $[-1,1]$ 之间。其余预处理流程和模型的输入大小与第 2 章相同，故不再赘述。

针对基于 sEMG 的关节角度的估计，对比了 MITCAN、长短时记忆网络和 BPNN 这三种模型。它们的输入均是经过初步滤波的 sEMG，而输出的目标是 20 个通道的关节角度。此外，为了证明模型的广泛适用性和保证结果的准确性，采用了三折段交叉验证的方法。

3.3 手部关节角度预测模型

利用 sEMG 信号构建适用于运动估计的正确模型时，必须考虑到序列尺度和时间依赖性。同时，结合不同特征的复合信息能够显著增强模型的性能，并且更具解释性。第二章的对比试验中发现，基于单通道的多流表征方法在手部动作分类中的表现最佳。本章按照前文结果，将每个通道所采集的 sEMG 设置为手部关节角度预测模型的输入，单独送入每个支路。

3.3.1 模型结构

该模型的结构如图 3.2 所示，接下来将分别介绍其中的具体模块。

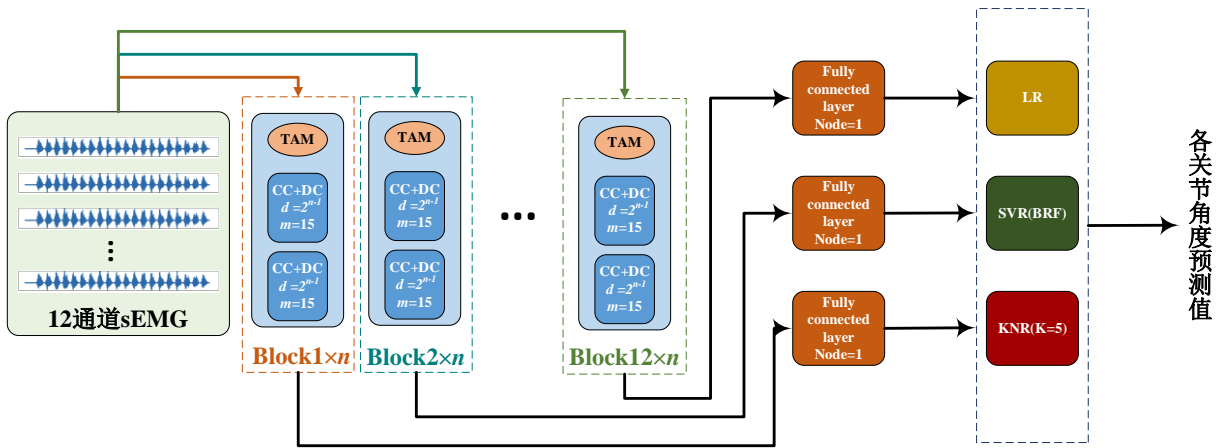


图 3.2 MITCAN 结构示意图

1) 因果卷积

因果卷积（Causal Convolution，CC）是指卷积运算下数据的输入和输出之间存在因果关系。给定当前时间 t ， t 之后的输入数据此时不会影响输出。换言之，假设输入序列是 $\{f_0, f_1, \dots, f_T\}$ ，预期输出为 $\{y_0, y_1, \dots, y_T\}$ ，CC保证输出值 y_t 仅由这一时刻的 $\{f_0, f_1, \dots, f_t\}$ 决定，不受 $\{f_{t+1}, f_{t+2}, \dots, f_T\}$ 的影响。建立时间卷积层应考虑两个主要原则。首先，需要构建一个与输入序列长度相等的输出序列，以便可以保留整个输入序列中包含的信息，从而促进长期记忆的构建。第二，不能有从未来到过去的泄漏。因此，零填充操作和因果卷积有助于实现这种序列建模。然而，为了充分利用输入数据的历史信息，必须部署极深的网络或巨大的卷积核。

2) 膨胀卷积

膨胀卷积（Dilated Convolution, DC）是解决因果卷积局部视场小的问题的一个很好的解决方案。这种技术能够有序地定期对输入数据进行采样。对于一维序列 $f \in \mathbb{R}^n$ 和卷积核 $g: \{0, 1, \dots, m-1\} \rightarrow \mathbb{R}$ ，序列 f 的元素 f_s 上的膨胀卷积运算 F 为：

$$F(f_s) = \sum_{i=0}^{m-1} g_i \cdot f_{s-d \cdot i} \quad (3.1)$$

其中 m 是核大小， g_i 是核 g 中的第 i 个元素。 $d \in \mathbb{N}^*$ 是膨胀因子， $s-d \cdot i$ 考虑过去的元素。特别的当 $d=1$ 时，膨胀卷积可以恢复为规则卷积。从(3.1)可以看出，无论是增大膨胀因子还是卷积核尺寸，都能有效地扩展卷积运算的感知场，特别是在输入和输出层中间叠加几个隐藏层后，输出值可以由大范围的输入序列确定，如图3.3(a)所示。

3) 时间注意力机制

时间注意力机制（Temporal Attention Mechanism, TAM）是一种动态地关注和利用与当前任务相关的时间步，以提高模型的性能和泛化能力的。它的核心在于调节注意力分配，以高效地抽取有用的特征，强化目标内容，同时减弱无关的信息干扰。与常规注意力机制不同，时间注意力机制考虑了内部因果关系，具体实现过程如图3.3(b)所示，

计算步骤如下。

我们使用 1×1 的三个正则卷积将输入序列 $f_{0:T}$ 映射到三个不同的向量。向量键 ($k_{0:T}$) 和查询 ($q_{0:T}$) 的维度为 d_b ，向量值 ($v_{0:T}$) 的维度与 $f_{0:T}$ 相同。为了得到权重矩阵 W ，计算 $q_{0:T}$ 的数量积和 $k_{0:T}$ 的转置，然后将每个结果除以 d_b ，如下所示：

$$W_{i,j} = \frac{k_i^T \cdot q_j}{\sqrt{d_b}} \quad (3.2)$$

其中， $i, j = 0, 1, 2, \dots, T$ 。之后， W 的下三角形部分提取如下：

$$W_{i,j}^l = \begin{cases} W_{i,j}, & \text{if } i \geq j \\ 0, & \text{if } i < j \end{cases} \quad (3.3)$$

其中， $i, j = 0, 1, 2, \dots, T$ 。此提取操作可保证将来无法使用信息。然后，应用 Softmax 函数对 W^l 进行归一化以获得 M^l 。最后，输出时间注意力向量 ($a_t, t \in [0, T]$) 的计算如下：

$$a_t = \sum_{i=0}^t M_i^l \cdot v_i \quad (3.4)$$

4) 增强残差连接

规则残差模块首次出现在 Resnet 中，通过输入和输出的快捷连接跳过中间堆叠卷积层，避免梯度爆炸和消失，从而有助于构建更深、性能更好的神经网络结构。与其相同，我们将重要信息的三个部分集成到一个残差块中。模块的输出可以计算如下：

$$o = A(f_{0:T} + C(a_{0:T}) + ER(f_{0:T}, M^l)) \quad (3.5)$$

其中 $C(\bullet)$ 是积分卷积运算， $ER(\bullet)$ 是增强残差运算， $A(\bullet)$ 表示激活函数。

增强的残差信息可以从注意力权重矩阵 M^l 中获得。本课题以 M^l 为单位取每行的总和得到权重向量 $V_{0:T}^l$ ，该向量表示每个时间步长的重要性水平。 $V_{0:T}^l$ 的计算公式如下：

$$V_t^l = \sum_{i=0}^t M_i^l \quad (3.6)$$

其中 $i, j = 0, 1, 2, \dots, T$ 和 V_t^l 表示时间 t 的重要性程度。最后，通过计算 $V_{0:T}^l$ 和 $f_{0:T}$ 的 Hadamard 积，可以得到增强残差的输出。

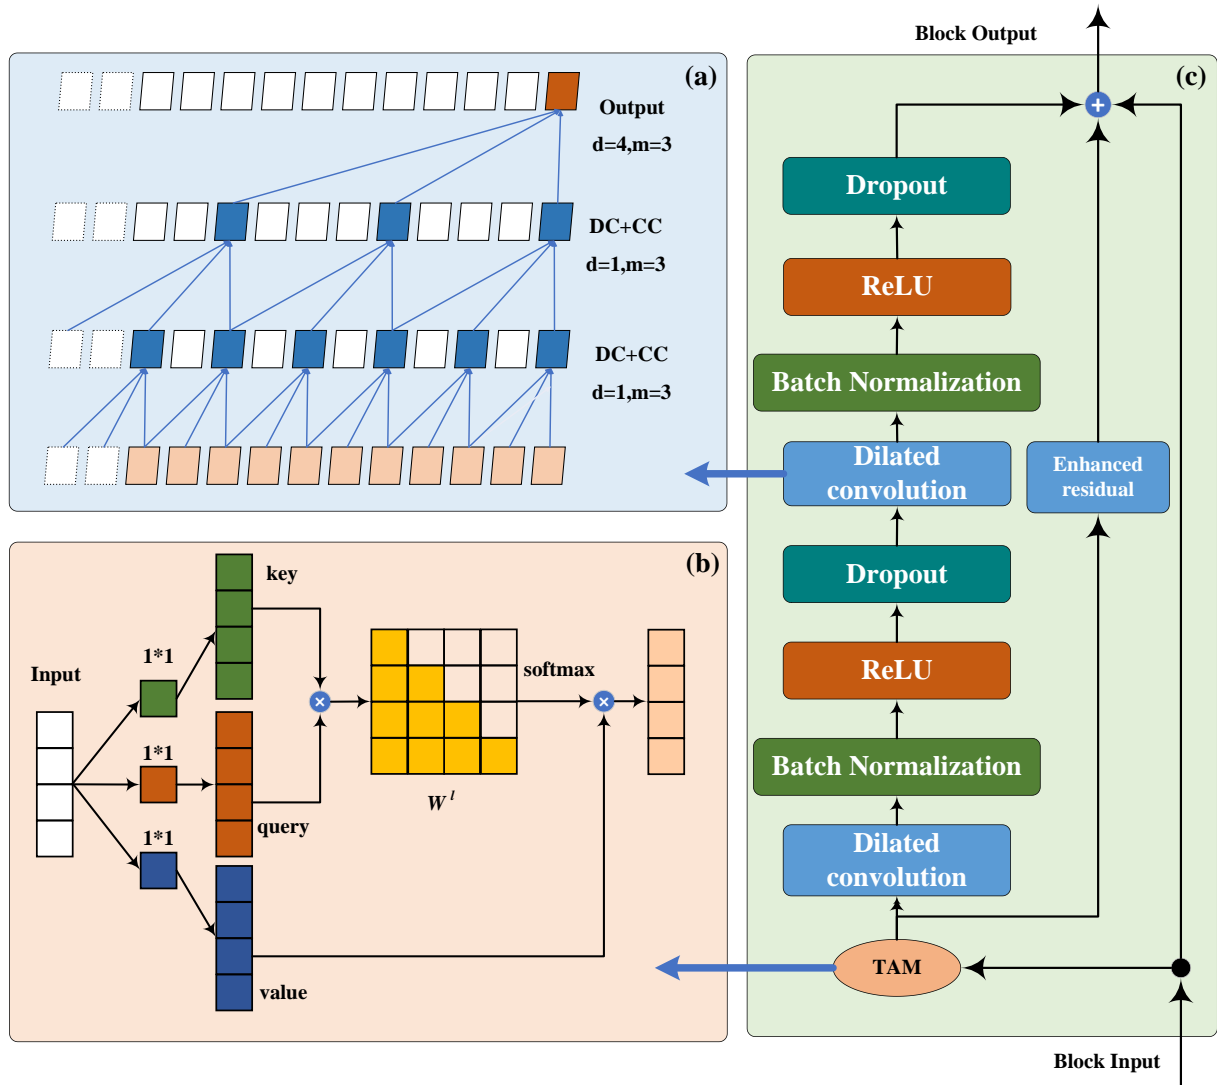


图 3.3 MITCAN 结构中的组件(a)DC 和 CC 的组合; (b)TAM 的结构; (c)MITCAN 中模块的详情。

3.3.2 联合决策机制

1) K-最近邻回归

K-最近邻回归 (K-Nearest Neighbor Regression, KNR) 作为一种基于距离度量的非参数回归算法, 可以在给定测试实例的训练集中找到 K 个最近的实例点, 并根据 K 个最近邻的信息进行预测。对于常见的复杂时间序列, KNR 是一种能够充分利用历史数据相似性的优秀算法, 并且已被证明具有预测可靠性高、适用数据类型范围广等优良特性。

2) 支持向量回归

支持向量机是基于统计学习理论的监督学习方法的集合, 它通常有两大类应用。一个是分类任务, 另一个是回归任务。后者通常被称为支持向量回归, 基于使用非线性映射进行数据训练的统计理论。支持向量回归 (Support vector regression, SVR) 可以利

用结构风险最小化诱导原理，在有限数据的基础上将预期风险降至最低。同时，求解非线性问题必须选择合适的核函数，而核函数的选择取决于特征向量的维度。

3) 线性回归

线性回归 (Linear Regression, LR) 是一种线性方法，用以探索标准响应与单个或多个解释变量间的联系。LR 比 KNR/SVR 需要更少的计算资源，并且在实际应用中被广泛使用。

分别赋予三个决策模块输出结果一个可学习权重，按照权重计算最终的输出结果。

3.4 手部关节角度预测性能评价

3.4.1 预测性能评价流程

如图 3.3(c)所示，网络块中有两个膨胀卷积。卷积后和在 ReLU 激活函数之前，本实验选择批量归一化来降低内部协变量偏移，从而增强网络的泛化性能。采用 Dropout 层来降低过拟合的风险，每次训练迭代随机激活一半的神经元。图 3.2 显示了 MFTCA 和统计算法集成的具体网络架构。在原始数据集上进行评估时。第一步是将 12 通道 sEMG 按通道拆分成 12 个支路。第二步是使用 12 个支路序列作为网络的输入，每个支路序列将分别通过三个块层。最后是将网络的输出与运动角度相匹配。输入数据的尺寸与本文第二章相同。

MITCAN 的超参数设置如下。三个块层的膨胀因子依次为 1、2 和 4。每个块中的核大小设置为 15，卷积通道设置为 25。在时态注意力图层中，向量键和查询维度设置为 25。根据 Xavier 方法初始化权重，并将偏移值设置为 0。此外，我们将每个样本集的 80% 指定为训练集（训练和验证），将 20% 指定为测试集。在预训练阶段优化器选择 Adam 并对模型进行总共 10 个周期的训练，学习率为 0.01，批量大小为 128。同时，使用均方误差目标函数作为损失函数。对于统计算法，根据最优实验结果，选择 SVR 的核函数作为径向基函数 (RBF)，选择 KNR 的邻数为 5。LSTM 和 BP 是估计关节角的常用网络。为了全面评估不同网络在运动估计任务中的性能，本实验分别精心设计了 LSTM 和 BP 的结构。网络输入为单特征序列，LSTM 的中间层分别包含 50、25、10 个节点，BP 的中间层分别包含 64、32、16 个节点。

在完成模型训练后，我们对拟合的结果进行了参数化评估，采用了 CC 和 RMSE 两种指标来定量评估真实关节角度值和预测角度值之间的差异或相关性，最终包括了对 6 种动作的分析结果。

3.4.2 评价结果

在这一部分的实验中，对三种算法在各种动作下的拟合效果进行了结果分析，总共有 40 位参与者对 6 种动作做出了参数化评估。

1) CC 分析

对 40 位受试者的 6 种抓握动作测试的输出值进行 CC 计算，其中对每一位受试者的 20 个关节角度在一组动作种的所有时刻的预测结果计算 CC，然后将这 20 个结果进行平均，再对六种动作进行上述操作得到最终的针对受试个体的 CC 结果如表 3.1 所示。从图 3.4 可以看出，在每个个体上，MITCAN 的估计结果均高于 74% 以上。此外，MITCAN 的 CC 值（对所有受试者的 CC 做平均 0.84 ± 0.05 ）要显著高于另外两种算法（LSTM（对所有受试者的 CC 做平均 0.77 ± 0.07 ），BP（对所有受试者的 CC 做平均 0.78 ± 0.06 ））。通过 CC 计算（针对 40 名参与者与 20 个关节的角度进行平均处理），我们观察了 6 项手部抓取任务的结果。如图 3.4 所示，无论是在何种类型的抓取操作下，MITCAN 的表现都超过了 80% 以上的标准，特别是在柱形抓取方面更为出色。值得注意的是，MITCAN 的 CC 得分（ 0.84 ± 0.01 ）明显优于其他两款算法（LSTM 为 0.77 ± 0.01 ，BP 为 0.78 ± 0.01 ）。这个结果说明，MITCAN 在保持高性能的同时，也能降低不同个体和动作间差异的影响。

表 3.1 三种方法在不同受试者上的相关系数 (CC) (按 6 个动作平均)

受试者	MITCAN	LSTM	BP	受试者	MITCAN	LSTM	BP
1	0.82 ± 0.02	0.74 ± 0.01	0.71 ± 0.04	21	0.86 ± 0.04	0.72 ± 0.03	0.82 ± 0.05
2	0.86 ± 0.07	0.75 ± 0.02	0.77 ± 0.02	22	0.74 ± 0.04	0.68 ± 0.03	0.68 ± 0.03
3	0.81 ± 0.04	0.71 ± 0.01	0.76 ± 0.04	23	0.90 ± 0.01	0.83 ± 0.02	0.87 ± 0.04
4	0.79 ± 0.01	0.78 ± 0.05	0.77 ± 0.03	24	0.79 ± 0.02	0.75 ± 0.03	0.79 ± 0.03
5	0.88 ± 0.05	0.79 ± 0.03	0.81 ± 0.04	25	0.84 ± 0.02	0.76 ± 0.02	0.75 ± 0.03
6	0.92 ± 0.01	0.80 ± 0.02	0.84 ± 0.01	26	0.88 ± 0.03	0.78 ± 0.03	0.79 ± 0.04
7	0.77 ± 0.02	0.66 ± 0.01	0.79 ± 0.02	27	0.89 ± 0.04	0.66 ± 0.03	0.67 ± 0.05
8	0.81 ± 0.03	0.55 ± 0.01	0.61 ± 0.04	28	0.88 ± 0.02	0.80 ± 0.03	0.86 ± 0.05
9	0.82 ± 0.03	0.72 ± 0.02	0.76 ± 0.03	29	0.85 ± 0.04	0.85 ± 0.04	0.85 ± 0.01
10	0.85 ± 0.01	0.79 ± 0.03	0.78 ± 0.05	30	0.86 ± 0.05	0.87 ± 0.04	0.86 ± 0.05
11	0.87 ± 0.02	0.78 ± 0.04	0.79 ± 0.02	31	0.88 ± 0.02	0.86 ± 0.04	0.86 ± 0.02
12	0.86 ± 0.04	0.79 ± 0.02	0.80 ± 0.02	32	0.76 ± 0.03	0.76 ± 0.01	0.76 ± 0.04
13	0.88 ± 0.03	0.77 ± 0.01	0.71 ± 0.04	33	0.91 ± 0.04	0.89 ± 0.03	0.81 ± 0.03
14	0.87 ± 0.01	0.69 ± 0.04	0.70 ± 0.02	34	0.93 ± 0.01	0.88 ± 0.04	0.89 ± 0.03
15	0.89 ± 0.04	0.78 ± 0.05	0.75 ± 0.02	35	0.73 ± 0.04	0.82 ± 0.04	0.86 ± 0.05
16	0.90 ± 0.03	0.81 ± 0.03	0.83 ± 0.03	36	0.86 ± 0.04	0.83 ± 0.01	0.84 ± 0.02
17	0.82 ± 0.02	0.78 ± 0.05	0.71 ± 0.03	37	0.89 ± 0.04	0.81 ± 0.02	0.81 ± 0.03
18	0.79 ± 0.04	0.69 ± 0.04	0.67 ± 0.02	38	0.91 ± 0.01	0.81 ± 0.02	0.83 ± 0.01
19	0.80 ± 0.04	0.77 ± 0.03	0.74 ± 0.05	39	0.74 ± 0.04	0.74 ± 0.02	0.76 ± 0.02
20	0.74 ± 0.03	0.65 ± 0.05	0.63 ± 0.04	40	0.89 ± 0.05	0.87 ± 0.04	0.86 ± 0.01

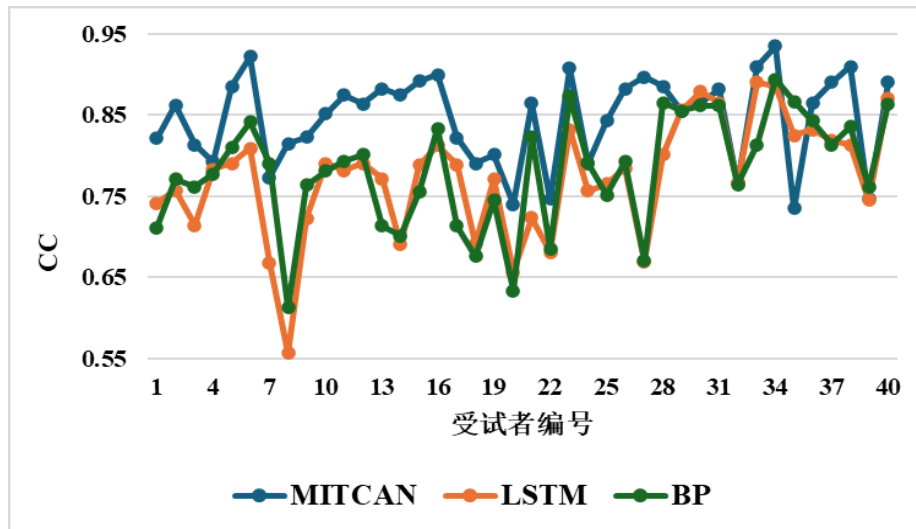


图 3.4 三种方法在不同受试者上的相关系数 (CC)

2) RMSE 分析

同样，实验分析了每位受试者的 6 种抓握动作中 RMSE 的测量精度，其结果如表 3.2 所示。从图 3.5 可以观察到在不同受试者中 MITCAN 的 RMSE 最小，且分布相比其他算法稳定，说明了深度学习算法能平衡不同个体之间的差异，避免了因不同使用者之间的切换而引起拟合中抖动的出现。并且，MITCAN 的 RMSE 值 ($5.89 \pm 0.95^\circ$) 均显著低于其他两种算法。对 6 种抓握测试的输出值进行 RMSE 计算 (对 40 位受试者和 20 个关节角度进行平均)，结果如图 3.5 所示，在 6 种动作中 MITCAN 的 RMSE 最小且分布相比其他算法稳定，说明了该算法能平衡不同类别动作间的差异。




图 3.5 三种方法在不同受试者上的均方根值 (RMSE)

表 3.2 三种方法在不同受试者上的均方根值 (RMSE) (按 6 种动作平均)

受试者	MITCAN	LSTM	BP	受试者	MITCAN	LSTM	BP
1	5.21±1.38	6.51±1.06	5.91±1.10	21	4.55±0.90	8.53±1.42	7.96±1.14
2	5.23±1.33	6.23±0.85	5.87±1.07	22	5.43±1.41	7.21±1.01	7.01±1.22
3	5.01±1.13	6.01±1.09	5.62±0.99	23	5.15±1.10	6.44±1.37	5.94±1.40
4	6.42±1.28	6.42±1.22	6.01±1.35	24	6.31±1.16	7.28±1.25	7.51±0.84
5	5.32±1.37	5.32±0.84	5.01±0.98	25	4.12±0.96	5.43±0.98	5.29±0.87
6	5.98±1.16	5.75±1.34	5.21±1.32	26	5.10±1.44	6.20±1.11	5.81±1.09
7	5.67±1.46	5.78±1.20	5.47±1.28	27	5.82±0.83	6.77±1.30	6.52±1.33
8	4.55±1.01	5.96±1.24	5.88±1.37	28	5.11±1.43	6.43±1.49	6.13±0.85
9	5.41±1.48	6.67±1.45	6.41±1.02	29	6.21±1.03	7.44±0.95	6.91±1.30
10	5.34±1.18	6.98±1.12	6.71±0.87	30	5.13±1.09	6.14±1.46	6.34±1.16
11	6.32±0.81	6.56±1.35	6.42±1.04	31	5.12±0.82	6.45±0.89	6.31±1.26
12	5.99±1.32	6.92±1.49	6.87±0.97	32	3.90±0.83	4.97±1.34	5.04±0.84
13	5.79±1.28	6.71±1.23	6.64±1.09	33	5.21±0.84	6.54±0.94	5.84±1.06
14	5.32±0.92	6.55±1.06	6.41±0.89	34	4.55±0.89	5.33±1.29	5.05±0.91
15	5.22±1.31	5.67±0.94	5.43±1.37	35	5.13±1.07	6.51±1.49	6.34±1.26
16	5.12±0.83	7.56±1.02	7.01±1.35	36	6.43±1.40	7.45±0.81	6.51±1.17
17	5.63±0.84	8.89±0.99	8.41±1.32	37	5.91±1.15	6.04±1.05	5.83±1.24
18	5.32±1.35	7.72±1.14	7.03±1.48	38	6.32±1.40	7.51±0.92	6.88±1.37
19	5.13±1.35	7.93±1.2	7.82±1.24	39	5.20±1.14	6.91±1.34	6.51±1.43
20	5.44±1.18	6.78±1.31	5.99±1.09	40	5.95±0.90	6.03±0.82	5.26±0.83

3.5 本章小结

在本章中，通过对比深度学习算法和模式识别算法的性能，通过两种评价指标：CC 和 RMSE。对实验中 40 位健康受试者进行了六种抓握动作的拟合定量分析。结果显示，MITCAN 具有较高的稳定性，特别是在不同个体之间对关节角度的估计方面。可能是由于其能够学习更长时间序列的依赖关系，所以拥有相对较好的稳定性。与此同时，MITCAN 能够准确地拟合真实的角度曲线，从而减小了因个体差异而引起的抖动。

4 基于表面肌电的手部动作识别

4.1 引言

上一章对手部关节角度预测进行了研究，但手部关节角度预测由于涵盖的指关节较多会对预测精度会有一定的影响。本章根据人手部生理结构的特点，采用手部动作识别的结果对手部关节角度进行修正以提高关节角度的预测准确度，为后续的上肢外骨骼控制方法的研究做铺垫。相关研究表明，不同肌肉在参与不同动作时的贡献不同。基于上述研究成果，本课题提出一种面向肌电手部动作识别的多流融合深度学习方法，将各通道进行多流表征并将采集的 sEMG 进行小波变换得到时频矩阵作为模型输入，然后建立基于前臂环绕电极分布的特点的特征提取模块，按照电极分布实现不同肌肉在动作识别时的影响权重，最后通过特征层多流融合并进行最终的动作分类。本章研究内容手部动作识别是在控制阶段对手部关节角度的修正，作为第 3 章研究内容的补充部分。

4.2 数据描述

本章实验选择与第 3 章相同的数据集 NinaPro DB2，不再对其进行介绍。不同的是本实验选取 20 名受试者的数据，针对 49 种动作进行分类。

4.2.1 数据预处理

原始的 NinaPro 数据集已做过部分预处理，主要包括 50 Hz 工频噪声的滤波处理，以及动作标签数据的校准。虽然通过标准仪器采集到的肌电信号经仪器的工频梳状滤波器已滤除掉 50 Hz 的工频及倍频噪声，但仍存在一定的运动伪迹噪声。此肌电信号也需要经过一定的预处理。首先使用一个 20 Hz 到 450 Hz 的带通滤波器滤除肌电信号的运动伪迹与无用成分，并保留了肌电信号的主要成分。本实验选取 4 阶巴特沃斯滤波器为 20-450 Hz 带通滤波器，对数据进行滤波。

4.2.2 时频转换

本课题通过将预处理后的信号进行小波变换转换为二维时频图并提取其中的相位矩阵和幅度矩阵组合为两个通道的矩阵作为模型的输入进行分类。

小波变换使用一组称为小波基函数的函数来表示信号，这些函数具有时域上的局部性和频域上的可变尺度。通过对信号进行小波变换，可以获得信号在不同尺度和频率上的能量分布，从而更好地理解信号的局部特征，同时小波变换也能够更好地捕捉信号的瞬时特性和局部频率变化。

对进行分段处理后的表面肌电信号 $sEMG_{\text{sec}}(t)$ 进行小波变换，公式如下：

$$w(s, t) = \int_{-\infty}^{+\infty} \psi_{s,t}(u) sEMG_{\text{sec}}(u) du, \quad \psi_{s,t} = \frac{1}{\sqrt{s}} \psi\left(\frac{u-t}{s}\right) \quad (4.1)$$

其中 $\psi(u)$ 是母小波， s 是尺度， t 是时间。当 $\psi(u) = \pi^{-1/4} e^{-i\omega_0 u} e^{-u^2/2}$ ， $\omega_0 = 2\pi$ 时， s 是 $\psi_{s,t}$ 中心频率的倒数。经小波变换后的结果如图 4.1 所示。




图 4.1 小波变换结果示意图

4.3 手部动作识别模型

该模型旨在按照数据集中电极放置位置的特点进行不同输入流的划分，按照划分号的数据流进行特征提取。分流特征提取结束后将特征子集按照特征通道进行拼接融合，并最终进行分类任务。

这种基于深度学习的多流融合策略，用于将肌电信号转换为图像，进而实现端到端的手部动作识别。对于稀疏多通道肌电信号，为了保证手部动作识别精度，本章使用滑动采样窗口肌电信号进行手部动作识别，每个滑动采样窗口内的肌电信号进行时频变换成为一个时频图像： $x \in R^{L \times F \times C}$ ，其中 F 为肌电信号的频率范围， L 为滑动采样窗口的长度， C 为肌电信号的通道数。将原始的肌电信号分解成多个通道的输入，得到 M 个子图像 $\{x_i | x_i \in R^{l_i \times f_i}\}_{i=1}^M$ ，其中 $M > 1$ ， l_i 和 f_i 分别为第 i 个子图像的长和宽。

$$\{x_i\}_{i=1}^M = \text{divide}(x) \quad (4.2)$$

同时将得到的子图像按照频率段划分成三块，分别为 20-450 Hz（全频率段）、20-150 Hz（低频段）和 150-450 Hz（高频段），分别作为每个分支的输入。

$$x_{i,j} = \text{cut}(x_i), \quad i \in M, j=1,2,3 \quad (4.3)$$

其中 $x_{i,1}$ 为第 i 个子图像被分割后的全频段部分, $x_{i,2}$ 为低频段的部分, $x_{i,3}$ 为高频段部分。

在此基础上构建多流多频段神经网络, 其由 M 个网络分支 $\{h_{\omega,j}\}_{j=1}^M$ 构成, 其中每个分支对每个子图像 x_i 进行建模, 学习到特征为 H_i :

$$H_i = h_{\omega,j}(x_{i,j}), \quad i=1,2,\dots,M, j=1,2,3 \quad (4.4)$$

其中 $\{\omega_{i,j}\}_{j=1}^M$ 为子网络的参数。

在多流多频段融合阶段, M 个分支输出的深度特征被输入一个融合网络 h_{ω}^{fusion} 进行特征层的多流融合, 融合网络通过其顶端的 softmax 分类函数进行手部动作分类, 输出手部动作识别结果 y_{out} :

$$y_{out} = h_{\omega}^{fusion}(H_{i,j}), \quad i=1,2,\dots,M, j=1,2,3 \quad (4.5)$$

其中 ω 为融合网络的参数。

该深度学习框架如图 4.2 所示, 该框架由多流表征, 多流多频段残差卷积神经网络和融合分析网络组成。本节将对这三个方面进行介绍。

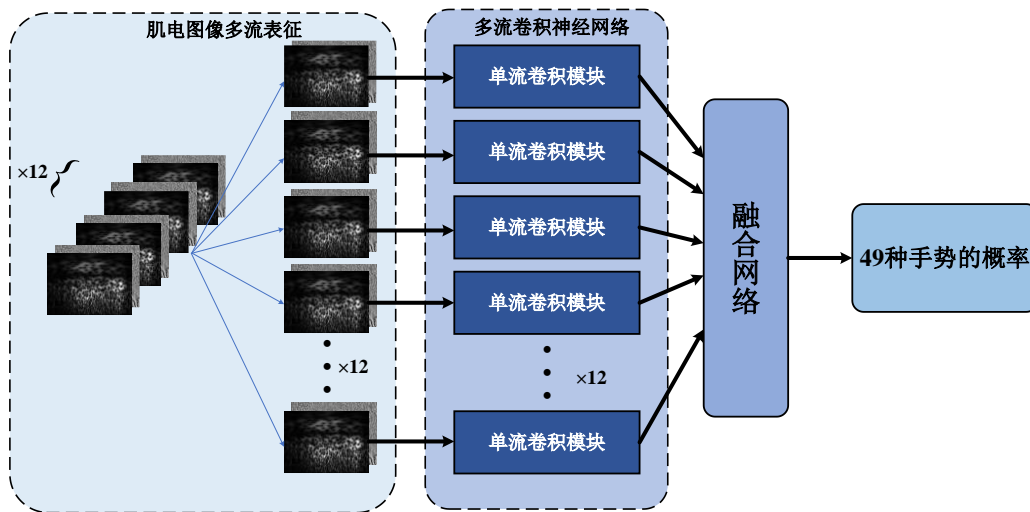


图 4.2 面向肌电手势识别的多流融合深度学习框架

4.3.1 表面肌电信号的多流表征

本研究将对稀疏多通道肌电信号经过时频转换后的结果进行多流表征, 以便残差网络更有效地探索前臂各个肌群产生的肌电信号与手部动作之间的联系。并提出了多种多流肌电图像表征技术, 旨在精确识别不同前臂肌肉群产生的手部动作。由于各种表征方法生成的子图像各有特点, 对特定手部动作的识别能力也各不相同, 因此本研究的目标是找到最佳的肌电图像多流表征方案。这一方案应能生成具有高手部动作识别准确率子图像, 从而优化整体的手部动作识别效果。

对该开放数据集而言, 可用 $x \in R^{L \times F \times C}$ 表示模型的输入, 其中 L 为滑动采样窗口长度 (单位为帧), C 为稀疏多通道肌电信号的通道数。NinaPro DB2 数据集包含 12 通道的稀疏多通道肌电信号, 其中除了 8 个被放置在环绕前臂的位置 (桡肱关节处), 剩下的 2 个电极放置肱二头肌和肱三头肌, 最后 2 个电极放置在拇指屈肌和指伸肌, 采样频率为 2 kHz, 以 140 ms (即 280 帧, $L=280$) 的滑动采样窗口为例, 每个窗口内的肌电信号生成的肌电图像为 $x \in R^{280 \times F \times 12}$ 。本章对 NinaPro DB2 数据集中的肌电信号生成的肌电图像测试以下两种空间多流表征方法:

- 基于单通道的多流表征方法: 该方法属于一种绕前臂的多流表征方法, 其将原始肌电图像 $\{x_i \in R^{280 \times F \times 12}\}_{i=1}^{12}$ 等分成 12 个肌电子图像。每个肌电子图像 x_i 都包含了每个电极获取的肌电信号, 这些信号对应于电极覆盖区域下的前臂肌群产生的肌电信号。随后将每个子图像单独作为一个卷积神经网络分支的输入进行建模, 多流卷积神经网络共包含 12 个分支;

- 基于电极分布的多流表征方法: 该方法属于一种绕前臂的多流表征方法, 根据 NinaPro DB2 数据集的 12 个电极中不同的放置位置将肌电图像 $x \in R^{280 \times F \times 12}$ 分成 5 个肌电子图像 $x_1 \in R^{280 \times F \times 8}$, $x_2 \in R^{280 \times F \times 1}$ 、 $x_3 \in R^{280 \times F \times 1}$ 、 $x_4 \in R^{280 \times F \times 1}$ 和 $x_5 \in R^{280 \times F \times 1}$, 其中 x_1 对应 8 个等距环绕前臂的电极采集的肌电图像, x_2 、 x_3 、 x_4 和 x_5 分别对应其余 4 个电极从对应肌群采集的肌电图像。将每个子图像单独作为一个卷积神经网络分支的输入进行建模, 多流卷积神经网络共包含 5 个分支;

本研究将一个单流卷积神经网络作为对照组进行实验, 采用整个 $200 \times F \times 10$ 原始肌电图像作为输入。

4.3.2 多流卷积神经网络结构

模型分类的整体思路为在模型中将经过小波变换后的 sEMG 的时频矩阵中幅度相位分别提出并将其按通道叠加, 并分割为低频 (20-150 Hz)、高频 (150-450 Hz) 和全频 (20-450 Hz) 三种输入到特征提取的卷积模块, 该模块的输出作为 Encoder 模块的输入进行分类。而根据不同的多流表征方法将这一流程分别导入不同的流, 在基于电极分布的空间多流表征方法中将绕前臂的 8 个电极通道作为一个输入流, 此时将 8 个通道分别计算的小波变换进行权重相加, 也就是将 8 个通道的幅度矩阵和相位矩阵分别与两个相同大小的权重矩阵进行向量积运算, 这些权重矩阵是可学习的参数会随着模型的反向传播进行更新。需要注意的是将八个通道的幅度矩阵相加, 再将相位矩阵进行相加, 最终得到的结果依旧是一个两通道的输入。

针对稀疏多通道肌电信号, 设计了一种卷积神经网络分支。根据滑动采样窗口的大小不同, 对各分支中部分卷积层的卷积核尺寸有所调整。每个分支共分三层将特征维度提升至 768。为了获取更丰富的特征, 以促进分类效果, 每一层采用多尺度卷积核以及残差连接。具体来说多尺度卷积核选择四种尺寸: 7×7 、 5×5 、 3×3 和 1×1 。较小的卷积

核能更好地识别非常小的差异，同时能缓解部分计算压力。

本课题所搭建的网络主要分为卷积模块和注意力机制，采用卷积模块按照不同的频率分为低频段、高频段和全频段进行特征提取并将结果进行融合，将其作为注意力机制的输入进行分类。

1) 卷积神经网络

该模型中的卷积模块主要使用残差结构，该结构的设计基于残差学习的思想，通过引入跳跃连接（Skip Connection）来实现信息的直接传递。跳跃连接允许模型学习恒等映射（identity mapping），即将输入数据直接添加到残差模块的输出上，从而保留原始输入的信息。跳跃连接将原始输入直接与卷积层的输出相加，形成残差（residual）。这种设计使得模型可以通过学习残差来适应更复杂的函数，而不是直接学习整个映射。残差的引入有助于缓解梯度消失问题，并提高网络的优化能力。

2) ViT 模型

Transformer 模型和 ViT（Vision Transformer）是两种在深度学习领域中具有重要影响力的模型。Transformer 模型主要应用于序列建模任务，而 ViT 则是一种用于图像分类的 Transformer 模型的变体。本节将简洁地介绍 ViT 模型。ViT 的原理基于 Transformer 模型的强大建模能力和自注意力机制的优势。自注意力机制能够在序列中建立全局的关联，并且能够灵活地处理长距离依赖关系，使得它能够更好地捕捉图像中的全局特征。完整 ViT 模型结构如图 4.3 所示。

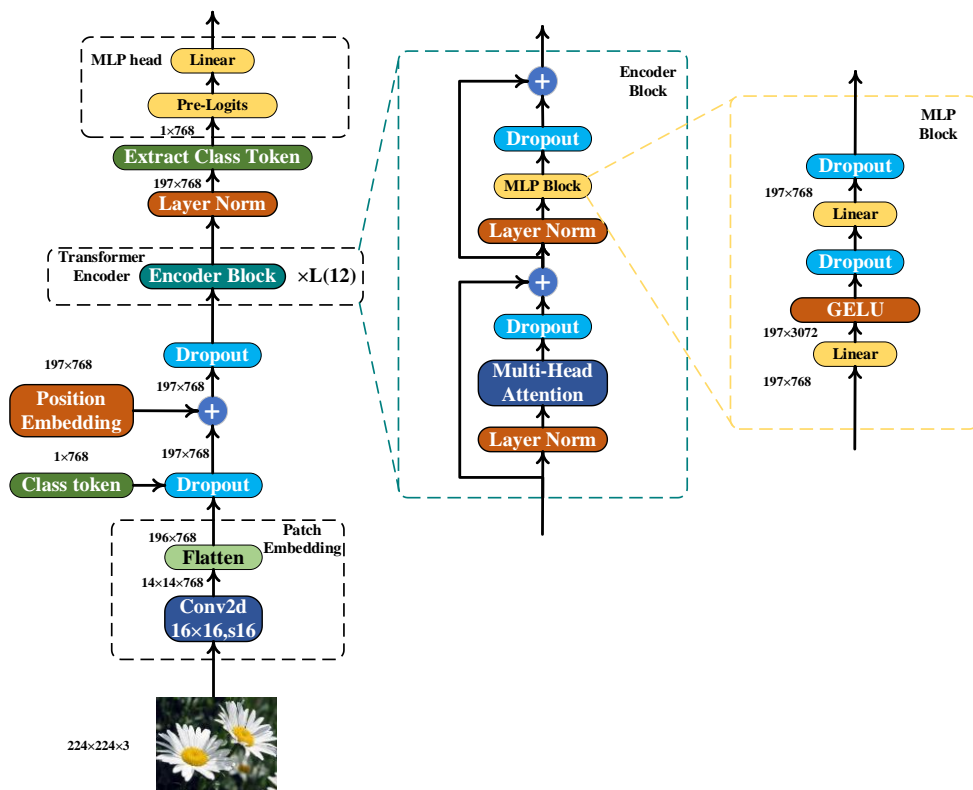


图 4.3 ViT 结构图

针对稀疏多通道肌电信号的卷积网络分支的结构是针对经时频转换的原始肌电信号，在输入神经网络分支前会将其按频率划分为三部分（20-450 Hz 的全频段、20-150 Hz 的低频段和 150-450 Hz 的高频段），并将其分别送入该分支的三个子模块进行建模，最终将三个子模块的输出按特征维度拼接。多流输入的卷积网络分支的结构如图 4.4 所示。

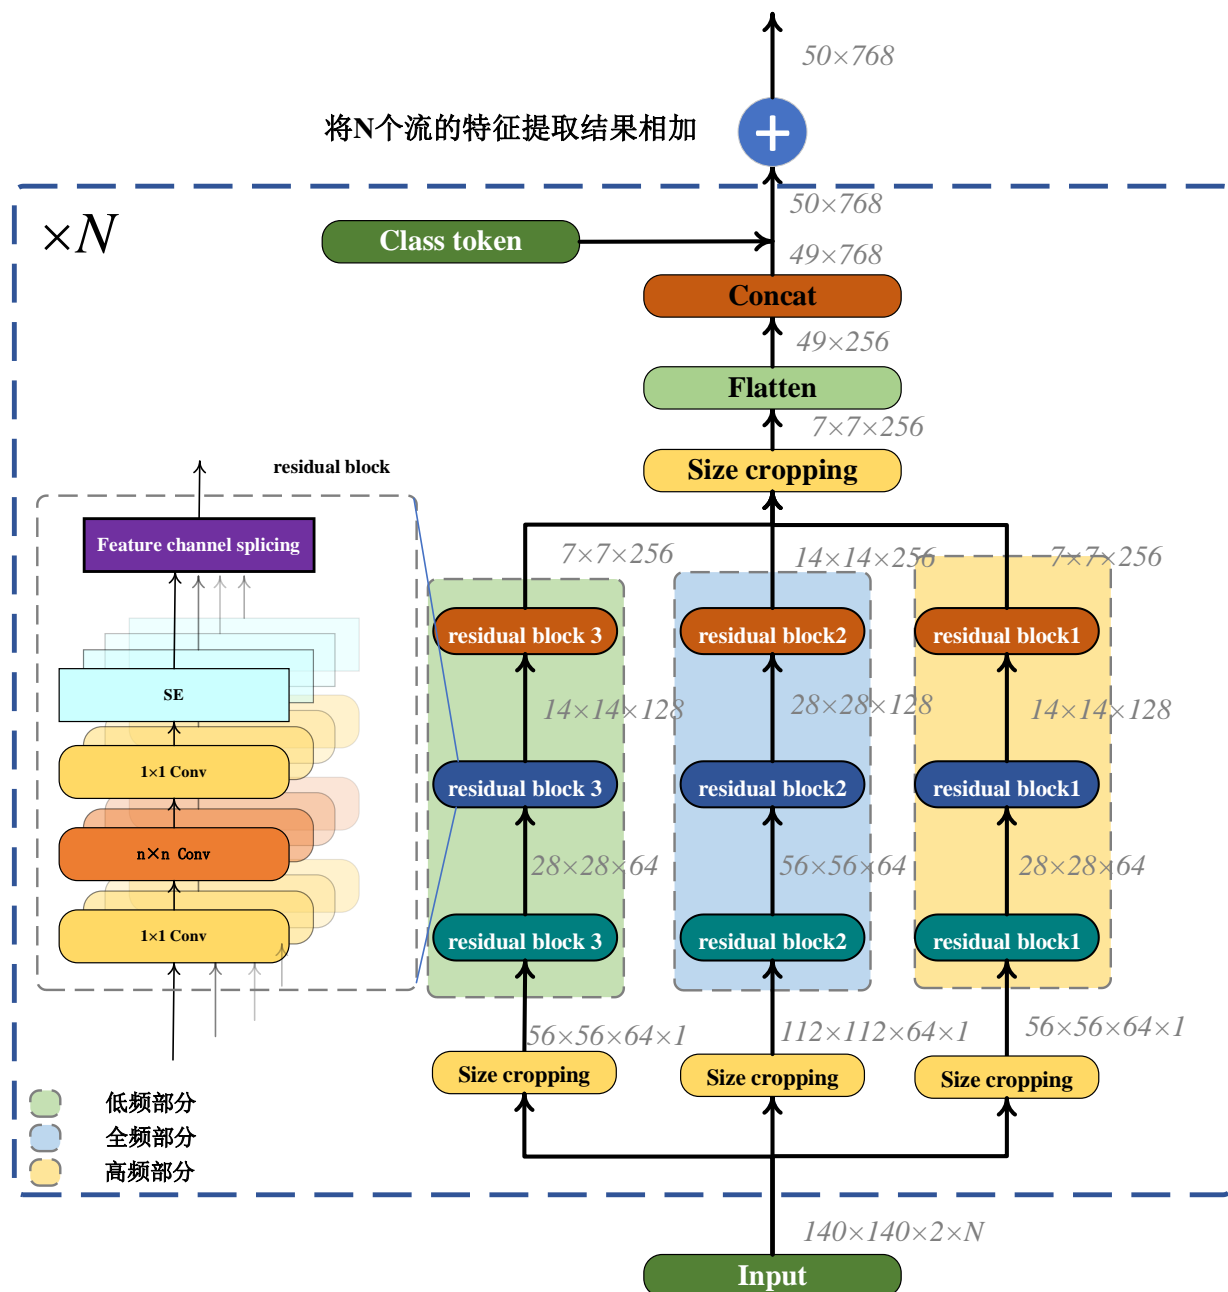


图 4.4 多流融合网络特征提取模块的结构

4.3.3 特征融合网络结构

多流卷积神经网络的输出 ($7 \times 7 \times 768$) 在输入分类模块前进行重构操作并引入 **class token** 和 **position embedding**。在进行重构时将输出按前两个维度进行展平通过将矩阵展平为一个长向量 (49×768)，按行连接起来每个块的特征都被连接在一起，形成一个包含所有块特征的一维向量。目的是将输入的分布特征转换为序列特征，以便输入到后续的编码器中进行处理。编码器是一个基于自注意力机制的模块，它期望输入为序列形式的信息。而加入一个可学习的 **class token** (1×768) 是为了整合展平后向量的信息，因为展平操作是将原始的 $7 \times 7 \times 768$ 的特征图按顺序排列成长度为 768 的 49 个向量。进行分类时很难选择用哪个输出向量进行后续的分类，因此引入可学习的 **class token** 向量进行分类这个向量就代表了 49 个向量的信息。此外 **position embedding** 用于将输入图像的不同位置信息嵌入到模型的表示中。这是因为图像中的像素点没有明确的顺序，所以需要提供一些关于像素位置的信息，以便模型能够理解不同位置之间的关系。模型会生成一个与 **class token** 的输出长度相同的位置编码矩阵 P ，其中每个位置都有一个对应的位置向量。这个位置编码矩阵 P 与 **class token** 的输出进行逐元素的相加，得到融合了位置信息的最终表示。

在进行完上述步骤后 **position embedding** 的输出作为多头注意力模块的输入，注意力机制用于计算输入序列中每个位置与其他位置之间的关联程度，从而加权聚合输入的信息。而多头注意力机制则通过使用多个独立的注意力头来并行地学习多个不同的注意力表示，以更全面地捕捉不同特征和关系。上文提到将不同卷积模块的输出按照维度进行权重拼接，在经过其他步骤处理后维度上的信息依旧分为三部分（高频、低频和全频）此时多头注意力机制按照维度分为三个头，分别生成 **query**、**key** 和 **value** 使得模型能更专注于不同频率分量的信息。

作为多层感知机的输入，多头注意力机制的输出并不适合处理图像中的局部模式。这是因为它是专门针对序列数据设计的。**MLP** 作为补充用于在每个注意力块中对局部特征进行处理。**MLP** 可以捕捉图像的局部细节和空间关系，并提供更丰富的特征表示。还能对特征进行映射和转换，经过注意力块后数据被扁平化输入到 **MLP** 模块将原始特征映射到一个更高维度的隐藏特征空间中，以丰富特征的表达能力和多样性。

上述多头注意力模块和 **MLP** 模块都进行了恒等映射，将这两个模块的输入分别映射到两个模块的输出。将 **MLP** 模块的输出提取预先添加的 **class token** (1×768) 输入到全连接层进行分类。该结构如图 4.5 所示

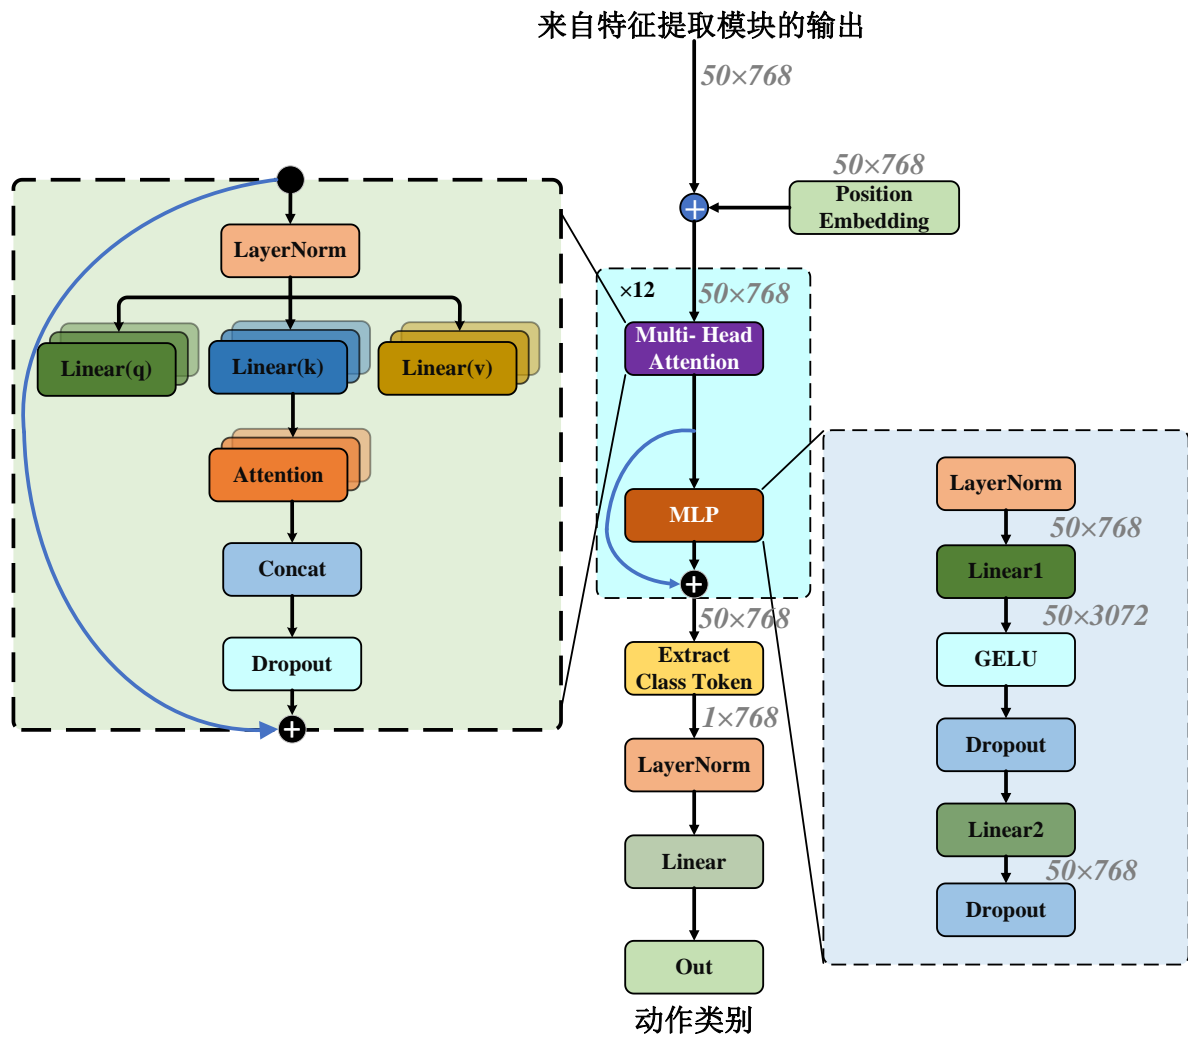


图 4.5 融合网络结构

4.4 手部动作识别性能评价

4.4.1 评价流程

本课题通过将 sEMG 按照不同滑动窗口的大小进行 50%重叠的分割，再将其通过小波变换得到相位幅度双通道矩阵。由于预处理中的滤波环节将信号截取为 20-450 Hz 之间的信号，故在分割矩阵块时单个矩阵块在时间维度上至少包含最低频率（20 Hz）的一个周期（0.05s）对应到时频矩阵上的时间维度上应该包含（50 点），而本课题所选择的所有滑动窗口大小均在时间维度上包含至少一个完整的周期。其结果作为模型的输入，并将所分割的矩阵块组合成模型的训练集、验证集和检验集。本实验基于 Pytorch 实现神经网络，详细超参数参见表 4.1。

表 4.1 训练超参数

名称	参数
mini batchsize	128
初始学习率	0.01
学习率衰减因子	0.001
学习率衰减节点	50 epoch
训练轮数	200
损失函数	交叉熵损失函数
优化器	Adam

4.4.2 评价结果

测试分成三部分对该方法进行了验证：1）不同输入（幅度矩阵单独作为输入和幅度相位双通道矩阵作为输入）之间的性能差异，该部分对经典模型 ResNet50 和 ViT 模型以及多流融合深度学习方法（下文中记作 MSFFusionNet）进行性能对比，这三个模型均采用相同的输入。2）在第一步的验证基础上对不同滑动采样窗口大小对性能的影响进行分析，实验对比依旧采用 ResNet50 和 ViT 模型和 MSFFusionNet。3）最后在上述对比实验的基础上再对不同的多流表征方式的性能进行了对比。

1) 不同输入之间的评测

本文用 NinaPro DB2 数据集对输入的不同形式进行了验证，通过进行单通道的幅度矩阵作为输入和双通道的幅度相位矩阵作为输入对 MSFFusionNet、ViT 和 ResNet50 进行验证，实验进行至少 30 次取两个模型效果最好的一组进行比较。从准确率等分类模型的性能指标来看在使用双通道的输入时模型的表现更好。在其他的实验条件都不变的情况下单独改变模型的输入从而引发了分类效果的变化，可以说明引入相位矩阵在模型的分类表现中起到正向作用。而这种作用对结果的影响比较明显，这组对比实验的结果如表 4.2 所示。

表 4.2 不同输入方式的结果对比

手部动作识别方法	输入方式	滑动采样窗口长度（毫秒）			
		60ms	100ms	140ms	180ms
ResNet50	幅度、相位矩阵双通道	77.8%	78.8%	80.8%	79.8%
ViT		66.6%	67.5%	69.7%	68.2%
MSFFusionNet		85.0%	85.9%	86.5%	85.7%
ResNet50	幅度矩阵单通道	76.4%	77.2%	78.2%	77.3%
ViT		64.0%	65.3%	66.1%	65.6%
MSFFusionNet		83.7%	84.5%	85.2%	84.6%

为了更清楚直观的理解模型在不同输入情况中的表现，对比了随机抽取一个样本放入模型并提取三路卷积特征提取模块的每一个残差块的输出矩阵。选取同一通道的特征

图进行比较如图 4.7 所示:




图 4.6 特征对比图

从特征提取部分的对比图可以看出，全频段的输入更关注于高频部分（图像的下半部分）而对低频的特征进行了淡化同时突出了高频部分的特征，在特征图缩减的过程中依旧明显地看出保留了高频段更突出的部分。而在高频特征提取部分和低频特征提取部分则将原有的输入图像高亮的部分隐去，转而将暗部更突出。单从模型对输入的幅度相位矩阵的特征提取来看，全频特征提取部分更关注原始输入中肉眼可关注的特征（高亮部分），而另外两个特征提取模块能注意到暗部的特点。为了进一步了这三种特征提取模块在分类中所起到的作用，对比了三个模块输出时所乘的权重矩阵归一化后的均值，其中最大的是全频部分（0.735）和低频（0.722）而高频部分（0.62）最低。这与肌电信号能量更集中的频段近似吻合，说明本课题所搭建的模型可以从肉眼无法观察的角度在时频域上对着两组类别进行很好的区分。

2) 不同滑动窗口宽度的测评

为证实 MSFFusionNet 在稀疏多通道肌电数据上的手部动作识别能力，本研究采用 60、100、140 及 180 毫秒四个不同的滑动采样窗口来划分采集到的信号样本，并在这

些条件下评估了该模型对于单一通道信号的多流表示方式下对手部动作识别的效果。同时，也把这个结果与 NinaPro DB2 平台上的一些有关研究成果进行了比较，通过分析表格中的信息，可以发现本研究提出的多流融合深度学习技术相比于 ViT 有 7.2% 的优势，并且也优于 Resnet50，其提升幅度达到了 17.8%。

表 4.3 不同滑动采样窗口的性能对比

手部动作识别方法	滑动采样窗口长度（毫秒）	手部动作识别准确率
ViT	180	76.7%
ViT	140	77.8%
ViT ^l	100	75.9%
ViT	60	75.6%
Resnet50	180	66.3%
Resnet50	140	66.6%
Resnet50	100	65.4%
Resnet50	60	64.9%
MSFFusionNet	180	85.7%
MSFFusionNet	140	86.5%
MSFFusionNet	100	85.9%
MSFFusionNet	60	85.0%

3) 不同多流表征方法的评测

本研究先以不同的滑动窗大小来划分和采集信号样本，然后在 NinaPro DB2 数据集中评估各种多流表达方式的效果，其测试结果详见表 4.4。其中，能达到最佳手指运动辨识精确度的方法被用粗体标出。由表 4.4 可知，利用单一通道信号构建空间多流表达模式能够实现最高的指尖活动识别精确度，而所有采用此种策略并结合深度学习的多流融合方案都能超过 85% 的指尖活动识别精确度，这甚至高于仅依赖于单一通道的卷积神经网络模型的表现。然而，通过考虑电极布局的方式建立起来的多流表达模式并未带来令人满意的结果。表 4.4 展示了在数据集中，不同实验配置下手部动作识别的准确率

表 4.4 数据集上不同实验配置获得的手部动作识别准确率

多流表征方法	多流表征生成的子图像数量	60ms	100ms	140ms	180ms
基于单通道的空间多流表征方法	12	84.9%	88.1%	90.6%	89.0%
基于电极分布的空间多流表征方法	5	83.8%	87.3%	89.6%	88.4%
单流卷积神经网络	1	82.1%	87.1%	88.4%	87.9%

4.5 本章小结

本章采用一种面向肌电手部动作识别的多流融合深度学习框架，并在 NinaPro DB2 上的稀疏多渠道肌肉活动记录的数据集中评估过这个架构的多路表示法。结果表明，在不同类型的输入上幅度相位矩阵的表现优于用幅度矩阵单独作为输入的模型，其次在不同滑动窗口宽度的对比实验中 140 ms 的表象更好，最后提出的基于单通道的空间多流表征方法也有更优的表现。并进一步对比了该模型与其他方法的性能，结果表明本章提出的方法在手部动作识别准确率上均超过了其他方法。

5 基于表面肌电的外骨骼控制方法

5.1 引言

近年来,随着人工智能和生物医学工程领域的快速发展,结合先进的计算方法和生物信号处理技术用于医疗和康复设备的研究引起了广泛关注。特别是,在康复工程、义肢控制和人机交互领域,基于 sEMG 的关节角度预测技术展现了巨大的潜力。在实际使用中基于深度学习的控制方法根据模型性能的高低会产生一定的误差,同时由于基于表面肌电控制的上肢外骨骼在使用过程中会产生电极位移、汗液干扰贴片电极和肌肉疲劳等问题。针对上述情况,本章节从两个方面提出解决方法,首先从模型本身的预测结果出发进行相互验证消除部分误差,另外针对模型以外的影响因素引入模糊控制来根据各关节实际运动的角度对上肢外骨骼的指令进行优化。

5.2 数据描述

5.2.1 实验设计

实验招募了 5 名没有上肢疾病的健康成年受试者,其中 2 位女性和 3 位男性,年龄范围在 23-24 岁之间,每个受试者都接受了实验动作的训练,并且所有人都被告知在实验前一天要充分休息。

实验在一个安静、封闭的房间,温度为 $25^{\circ}\text{C} \pm 2^{\circ}\text{C}$ 进行,将 sEMG 采集区域的毛发剃光并用酒精擦拭,以减少外界因素的干扰。采用了 Thalmic Labs 公司推出的可穿戴式 Myo 肌电臂环作为数据采集设备,如图 5.1(a)所示。为使得该部分实验所采集的 sEMG 通道数与前文所述一致,在此基础上增加七对一次性 Ag/AgCl 差分电极(直径 5 mm)放置在肌肉腹部上方电极间距离为 2 cm,增加的位置分别为肱二头肌、肱三头肌、拇指弯曲肌群、食指伸展肌群、三角肌前、三角肌后和胸大肌。为了建立 sEMG 与关节角度之间的模型,采用了 CyberGlove III 来采集手部关节角度信号,如图 5.1(b)所示。同理增加针对肩肘关节的角度测量,其放置方法与采用的设备与第 2 章相同。肌电信号记录的采样率为 1 kHz,角度信号的采样率为 100 Hz。

实验包含 6 组手部动作,该动作与第 3 章选取的 NinaPro DB2 中六个动作一致,在每组手部动作之下扩展三个肩肘关节动作,该动作与第 2 章相同。具体来说,实验会一次进行一套动作其中包含 1 个手部动作和 3 个肩肘关节动作,这两种动作互不冲突可同时进行。整个实验在一个平面进行(实验台),受试者侧身坐在实验台且旁高度适中

(坐姿时惯用手的前臂平行放置于实验台大臂自然下垂肘关节刚好贴于实验台,且前臂与大臂成 90° 夹角),此时该动作作为基准状态接下来的手部动作和肩肘动作均以此为起点。受试者需要按要求将指定的物品抓握放置在 5 个指定的位置,它们分别对应动作起点(O 点,对应的肩肘关节角度均为 0°)、肩关节前屈位置点(A 点,对应的肩关节角度为前屈 60° 肘关节由于是非主动伸展故记为 0°)、肩关节后伸位置点(B 点,对应的肩关节角度为后伸 60° 肘关节由于是非主动伸展故记为 0°)、肩关节外展位置点(C 点对应的肩关节角度为外展 60° 肘关节记为 0°)和肘关节屈曲位置点(D 点,肩关节记为 0° 肘关节为最大屈曲角度),其中前四个对应的位置均位于实验台面最后一个肘关节屈曲对应的位置点根据每个受试者的生理结构不同设定(不同受试者从动作起点出发固定肘关节位置,握住抓握对象抬起前臂使其与大臂的夹角尽可能小)。其中,A 点和 B 点的连线过 O 点且与 C 点和 O 点的连线垂直,同时 A 点与 B 点的连线垂直于人体解剖学中的冠状面,C 点与 O 点的的连线垂直于 D 点所在的 AOD 平面(与 BOD 为同一平面)。实验要求受试者按指定要求将抓握对象在 O 点与其它点之间往复移动,以 A 点为例一次往复运动的过程如下:

(1) 在 O 点放置抓握对象此时受试者驱动手握住抓握对象(抓握前手部动作为放松状态,参照第三章实验部分)

(2) 握住抓握对象后驱动大臂进行肩关节的前屈动作到达 A 点(这个过程尽可能贴近实验台,且使身体以及抓握对象均与实验台无摩擦),然后松开抓握手将抓握对象放置在 A 点。

(3) 松开抓握对象 3 秒后再次握住抓握对象,并将其移动到 O 点然后再次松开静息 3 秒。

需要注意的是在进行从 O 点到 D 点的移动过程不需要在 D 点松开抓握手,仅需要在 D 点停留 3 秒然后进行后续动作。

实验一套动作持续 104 秒,每一套动作之间休息 5 分钟。

5.2.2 数据预处理

整个实验中的 sEMG 和关节角度采集设备的采样频率不同,分别为除前臂肌群的 sEMG 采集外的其他肌肉由 Trigno™无线肌电记录系统采集其采样频率为 2000Hz,前臂肌群由可穿戴式 Myo 肌电臂环采集其采样频率为 200Hz,角度信息分为肩肘关节角度和手指关节角度,由 Delsys 提供的角度传感器和 CyberGlove III 采集,采样频率分别为 100Hz 和 120Hz。为了保证所有肌电信号与关节角度的同步,分别使用降采样和重采样将 sEMG 和关节角度都调整到 1000Hz。后续处理方式分别按照第 2 章、第 3 章和第 4 章数据预处理部分的方法进行,故不再赘述。



(a)可穿戴式 Myo 肌电臂环



(b) CyberGlove III

图 5.1 信号采集装置

5.3 外骨骼控制方法

5.3.1 外骨骼控制流程

在基于深度学习的上肢外骨骼控制中对关节角度的预测涉及关节繁多，模型性能受限，但是手指在进行抓握动作时每根手指上的不同关节之间的运动趋势是一致的，所以根据这一特性设计了一种指关节间预测结果的交叉验证。

本课题将采集到的 sEMG 进行预处理与分段再输入关节角度预测模型和动作识别模型，得到这个时段的关节角度预测值与动作识别结果，用动作识别结果对关节角度预测的趋势进行修正，再将这个时刻的关节角度预测结果输入到控制器作为下一时段的控制命令，同时采用模糊控制采用下一时刻的关节角度真实值与控制器输入之间的误差，对下一时刻的控制角度进行修正。其流程如图 5.2 所示。

该方法可针对关节角度预测中对预测趋势的误判进行修正，例如若在手指弯曲的动作中某关节的关节角度预测值使得该关节呈张开的趋势（即与手指运动方向相反）则需要对其进行修正，而修正的关键是判断该关节的角度预测值是否与真实的运动趋势冲突。具体的判断方法为，将该关节的角度预测值与该手指上另外三个角度预测值进行比较，若趋势与之不同的个数为 3 则对该关节的角度进行重新预测，若小于 3 则引入手部动作识别的结果进行综合判断，若与动作识别的结果相同则认为该关节角度预测正确否则进行重新预测。按照此方法可将部分错误剔除，能提高控制的精准度，从而优化外骨骼的使用体验。

通过数据手套可以在外骨骼使用过程中检测手指的关节角度，这个角度值作为当前时段的关节角度真实值。而关节角度预测模型根据上一时段的 sEMG 估计出的当前时段的关节角度预测值作为控制器的输入对外骨骼进行控制，而外骨骼按照命令驱动时根据控制器收到的角度信息和测得的关节角度真实值之间的误差，再将误差送入模糊控制

器，最终得到修正后的关节角度。

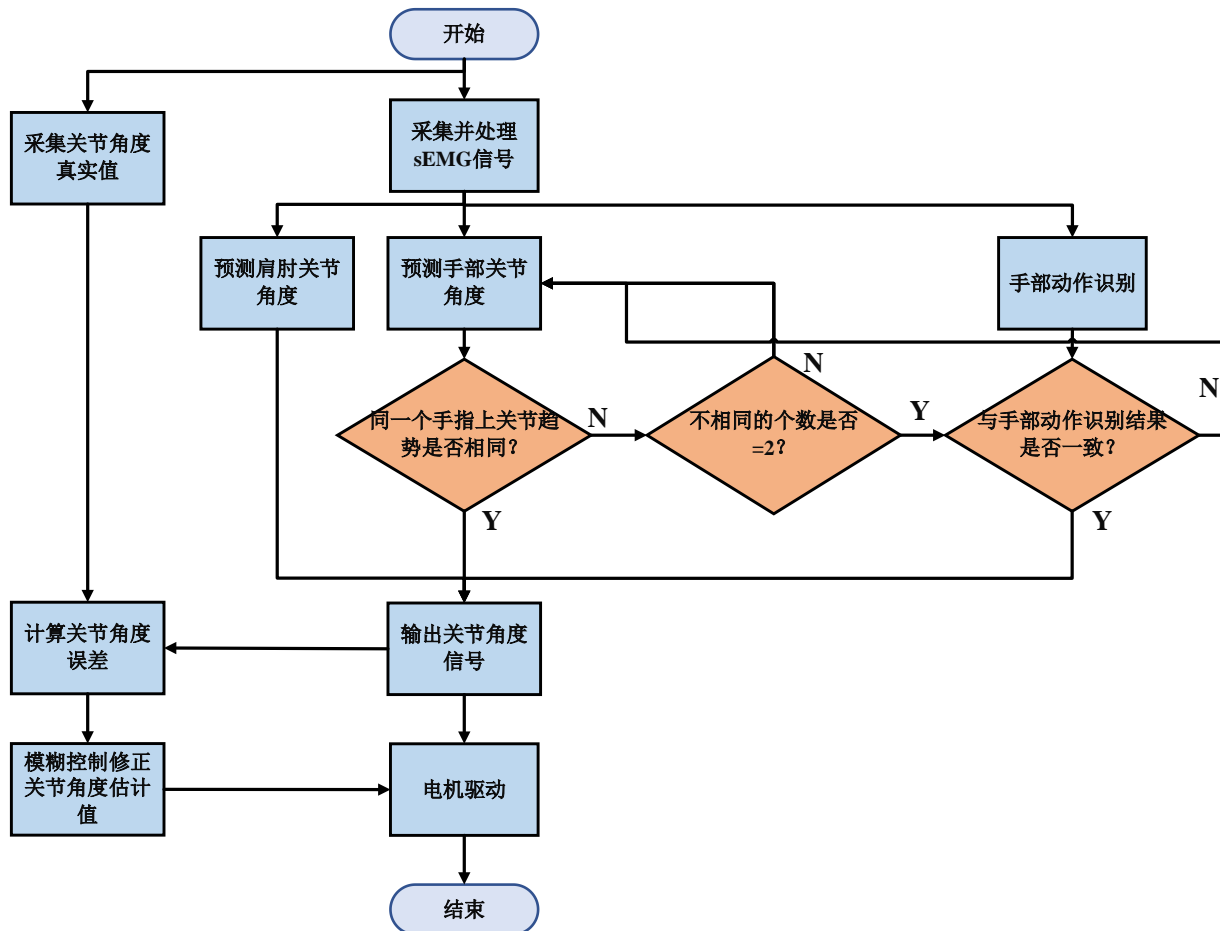


图 5.2 上肢外骨骼控制流程

5.3.2 基于关节角度误差的模糊控制方法

1) 模糊控制方法

现代化的管理技术里，常常会使用模糊控制来处理那些存在缺失模型、非线性与动态变化系统的任务。此种策略利用了实际操作者或者领域专家的专业技能，构建出模糊语句规则，以此确定机器人在其内部输入输出的对应联系，进而增强该系统对于外部环境的适应能力。设计模糊控制的方法主要包含四个部分：模糊化、数据存储、规则集合以及澄清过程。

决策的准确性和效率取决于模糊逻辑系统的执行情况和其有效性的表现形式，反过来也影响着它能否被用于实践环境并产生预期结果的能力。最关键的部分在于构建一套由行业内权威人士根据自身积累的专业知识编写的复杂且全面的管理策略集群——这是实现精准输出的基础条件之一。此外还需要进一步处理这些含糊不清的数据以使之更易理解、可度量的过程来达到我们期望的目标数值。

2) 模糊控制器设计

模糊控制的工作流程如下：

- a) 利用传感器不断监测外骨骼使用者的手指关节角度误差 e 和角度误差变化量 ec 。
- b) 将 e 和 ec 通过量化因子 K_e 和 K_{ec} 转化为精确输入 E 和 EC 。
- c) E 和 EC 通过模糊接口转化为模糊输入 A 和 B 。
- d) 制定关节角度偏差及偏差率和阻抗参数变化量之间的模糊规则，并对 A 和 B 进行模糊推理，得到模糊输出 C 。
- e) 对模糊输出 C 进行去模糊化，得到精确输出 U 。
- f) 过比例因子 K_u 将 U 转化为参数的变化量 u 。

以上内容描述了模糊控制器的一般工作过程。其结构原理图展示了模糊控制器的各个组成部分及其相互作用，如图 5.3 所示。




图 5.3 模糊控制的流程，其中 e 为输入的误差， E 为通过量化因子的精确误差， EC 为通过量化因子的精确误差变化率， U 为精确输出， u 为参数的变化量。

3) 确定模糊语言

模糊控制器在上肢外骨骼应用中的输入主要包括使用者关节角度误差 e 和关节角度误差变化率 ec 。而控制器的输出则是关节角度的修正值。

4) 定义各语言变量的语言值

在模糊控制器中，关节角度误差 e 和关节角度误差变化率 ec 的量化等级分别被设置为 7 和 5，其量化论域范围为 $\{-3, -2, -1, 0, 1, 2, 3\}$ 。对于 e 、 ec 和输出误差 Δe 的模糊子集分别定义为 $\{NB, NM, NS, Z, PS, PM, PB\}$ 和 $\{NB, NS, Z, PS, PB\}$ ，分别对应于 $\{\text{负大, 负中, 负小, 零, 正小, 正中, 正大}\}$ 和 $\{\text{负大, 负小, 零, 正小, 正大}\}$ 。

5) 设计语言变量的论域



所有手指外骨骼关节角度偏差 e 的基本论域为 $[-5, 5]$ 。当 e 小于 -5 时，模糊变量处于最 NB（例如属于‘负大’的类别），而当 e 大于 5 时，模糊变量处于 PB（例如属于‘正大’的类别）。 e 的量化因子设定为 $3/5=0.6$ 。

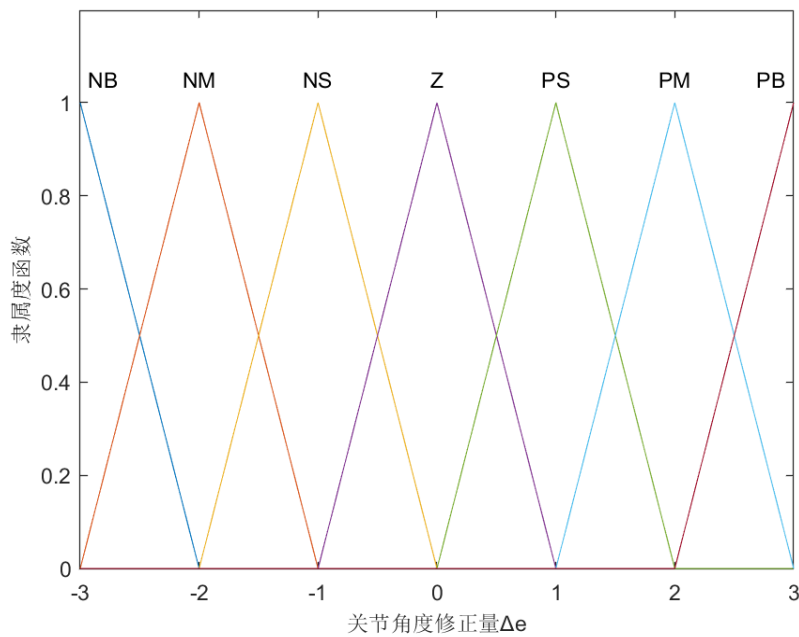
手指外骨骼关节角度偏差率 ec 的基本论域为 $[-2, 2]$ 。当 ec 小于 -2 时，模糊变量处于 NB（例如属于‘负大’的类别），而当 ec 大于 2 时，模糊变量处于 PB（例如属于‘正大’的类别）。 ec 的量化因子设定为 $3/2=1.5$ 。

上肢外骨骼关节角度修正误差 Δe 的输出范围为 $[-3, 3]$ ，输出缩放因子为： $3/3=1$ 。

6) 确定隶属度函数

本研究采用了三角形隶属度函数，并通过模糊控制工具箱直接定义了输入变量和输出变量。输入变量包括机上肢外骨骼关节角度的偏差 e 和上肢外骨骼关节角度偏差的变化率 ec 。输出变量则是关节角度修正量 Δe 。这三个变量的隶属度函数如图 5.4，5.5 和 5.6 所示。

图 5.4 关节角度误差 e 的隶属度曲线图 5.5 关节角度误差变化率 ec 的隶属度曲线

图 5.6 关节角度修正量 Δe

7) 确定模糊控制规则

设计关节角度修正量的模糊控制规则库，并进行模糊推理时选用 Mamdani 控制规则。模糊控制器中模糊控制规则调节表如表 5.1 所示。

表 5.1 隶属度函数表

关节角度误差变化率	关节角度误差						
	NB	NM	NS	Z	PS	PM	PB
NB	PB	PB	PB	PM	PS	Z	NM
NS	PB	PM	PM	PS	Z	NS	NM
Z	PB	PM	PS	Z	NS	NM	NB
PS	PM	PS	Z	NS	NM	NB	NB
PB	PM	Z	NS	NM	NB	NB	NB

8) 清晰化

通过对精准设定变量（即机器人的终端位移误差 S 和其速率变化）进行模糊处理并得出模糊结果之后，我们得到了一种模糊性的阻抗参数变化值。但是，为了获得准确的结果，我们必须对其进行解析。在此过程中，许多解析方式都可以被采用，其中以重心法为最优解。该方法能使隶属于度的函数与其纵轴所形成的图像区域中心随输入信号的变化做出相应的移动。即便输入信号发生微小的波动，也能保证输出的良好反应。利用此种方法进行解析，可有效提升系统的表现能力。

5.4 外骨骼控制性能评价

结束模型的训练后，对关节角度的实测值与控制系统的输出值进行分析。采用的指标为 CC 和 RMSE，可以直观地分析两者之间的差异或是相关性，通过对 6 种动作的分析可以看出引入该控制算法确实对准确性有明显的提升。由于为与第 2 章和第 3 章的方法保持一致采用与第 2 章相同的验证算法。

1) 相关系数（CC）的分析

分别将 5 名受试者的 23 个关节自由度上 6 种动作的 CC 值进行平均，其结果如表 5.2 所示，在不同个体中，引入融合控制方法的 MITCAN 的 CC 值均高于 0.8 且误差分布较集中（均小于 0.02）说明在不同的动作之间该方法能平衡其中的差异。对 5 名受试者的 23 个关节角度预测 CC 值的平均值做了分析，如图 5.7 所示，采用融合控制方法在不同受试者上的表现，均显著高于为采用融合控制方法。分别将 5 名受试者 6 组动作的 23 个关节自由度角度 CC 值进行平均，其结果如表 5.3 所示，引入融合控制方法的 CC 值均高于 0.77 且误差分布较集中（均小于 0.05）说明在不同的关节之间该方法在不同动作中的手指间协调中表现较好。

表 5.2 引入控制方法后不同受试者不同关节的相关系数（23 个关节角度平均）

动作编号	受试者				
	1	2	3	4	5
M1	0.75 ± 0.03	0.83 ± 0.06	0.77 ± 0.04	0.79 ± 0.04	0.91 ± 0.01
M2	0.85 ± 0.05	0.86 ± 0.05	0.81 ± 0.05	0.94 ± 0.07	0.87 ± 0.05
M3	0.88 ± 0.03	0.95 ± 0.04	0.79 ± 0.05	0.86 ± 0.01	0.76 ± 0.05
M4	0.79 ± 0.05	0.84 ± 0.02	0.96 ± 0.02	0.86 ± 0.03	0.86 ± 0.03
M5	0.78 ± 0.04	0.82 ± 0.04	0.88 ± 0.07	0.86 ± 0.02	0.77 ± 0.02
M6	0.84 ± 0.02	0.78 ± 0.05	0.77 ± 0.03	0.78 ± 0.04	0.90 ± 0.02




图 5.7 控制方法的结果对比（按动作和通道平均）

表 5.3 引入控制方法预测关节角度与实际关节角度的相关系数（6 种动作平均）

关节编号	受试者				
	1	2	3	4	5
1	0.82±0.04	0.91 ±0.03	0.86 ±0.11	0.89 ±0.03	0.84 ±0.07
2	0.86±0.02	0.81 ±0.07	0.87 ±0.16	0.85 ±0.11	0.90 ±0.02
3	0.81±0.13	0.95 ±0.05	0.83 ±0.15	0.90 ±0.11	0.89 ±0.18
4	0.83 ±0.11	0.84 ±0.06	0.90 ±0.08	0.82 ±0.08	0.90 ±0.18
5	0.92 ±0.16	0.89 ±0.04	0.91 ±0.16	0.83 ±0.06	0.94 ±0.06
6	0.96 ±0.16	0.93 ±0.17	0.93 ±0.12	0.85 ±0.02	0.97 ±0.14
7	0.81 ±0.07	0.94 ±0.08	0.78 ±0.02	0.84 ±0.11	0.91 ±0.13
8	0.85 ±0.04	0.93 ±0.08	0.87 ±0.07	0.87 ±0.11	0.74 ±0.16
9	0.86 ±0.16	0.90 ±0.17	0.84 ±0.03	0.92 ±0.15	0.89 ±0.05
10	0.89 ±0.14	0.91 ±0.04	0.91 ±0.10	0.95 ±0.16	0.91 ±0.18
11	0.91 ±0.17	0.93 ±0.14	0.90 ±0.11	0.93 ±0.19	0.92 ±0.13
12	0.90 ±0.15	0.81 ±0.13	0.91 ±0.16	0.83 ±0.16	0.93 ±0.06
13	0.92 ±0.15	0.96 ±0.10	0.89 ±0.14	0.96 ±0.04	0.84 ±0.09
14	0.91 ±0.09	0.98 ±0.03	0.81 ±0.15	0.95 ±0.11	0.83 ±0.04
15	0.93 ±0.08	0.78 ±0.03	0.90 ±0.10	0.89 ±0.14	0.88 ±0.05
16	0.94 ±0.15	0.91 ±0.18	0.93 ±0.15	0.90 ±0.09	0.96 ±0.09
17	0.86 ±0.11	0.94 ±0.08	0.91 ±0.14	0.89 ±0.05	0.84 ±0.14
18	0.83 ±0.02	0.96 ±0.04	0.81 ±0.10	0.88 ±0.06	0.80 ±0.02
19	0.84 ±0.11	0.82 ±0.04	0.89 ±0.11	0.81 ±0.17	0.87 ±0.06
20	0.88 ±0.07	0.94 ±0.08	0.80 ±0.10	0.94 ±0.06	0.81 ±0.02
21	0.89 ±0.18	0.92 ±0.17	0.88 ±0.27	0.89 ±0.06	0.89 ±0.31
22	0.88 ±0.22	0.94 ±0.16	0.86 ±0.15	0.81 ±0.37	0.87 ±0.02
23	0.87 ±0.14	0.90 ±0.06	0.85 ±0.17	0.88 ±0.16	0.89 ±0.16

2) 均方根值（RMSE）的分析

同样，实验分析了每种抓握动作中 RMSE 的测量精度，分别将 5 名受试者的 23 个关节自由度上 6 种动作的 RMSE 值进行平均，结果如表 5.4 所示。在不同个体中，引入融合控制方法的 MITCAN 的 RMSE 值均低于 6.6 且误差分布较集中（均小于 1）说明在不同的动作之间该方法能平衡其中的差异。对 5 名受试者的 20 个关节角度预测值的 RMSE 平均值做了分析，如图 5.8 所示，采用融合控制方法在不同受试者上的表现分别为 4.99 ± 0.44 、 5.01 ± 0.71 、 5.11 ± 0.8441 、 5.04 ± 0.82 和 5.02 ± 0.83 ，均显著高于为采用融合控制方法。分别将 5 名受试者 6 组动作的 20 个关节角度 CC 值进行平均，其结果如表 5.5 所示，引入融合控制方法的 RMSE 值均低于 6 且误差分布较集中（均小于 1）这同样说明在不同的关节之间该方法在不同种动作中的手指间协调中表现较好。RMSE 的结果同样表明，采用融合控制策略能降低活动中关节角度范围的差异影响，相比未采用融合控制策略的方法而言，具有更好的稳定性。

表 5.4 引入控制方法后不同受试者不同关节的均方根值（23 个关节角度平均）

动作编号	受试者				
	1	2	3	4	5
M1	4.88±0.84	5.54±0.92	4.80±0.87	4.68±0.89	5.11±0.80
M2	5.07±0.89	4.98±0.89	5.38±0.89	5.52±0.94	5.03±0.90
M3	5.36±0.85	5.17±0.87	4.73±0.90	5.45±0.81	4.40±0.90
M4	3.95±0.90	4.15±0.83	5.26±0.82	5.15±0.85	6.00±0.85
M5	5.74±0.89	5.71±0.87	4.52±0.95	5.16±0.82	4.50±0.83
M6	5.06±0.82	4.40±0.90	5.49±0.84	4.64±0.87	5.09±0.84




图 5.8 控制方法的结果对比（按动作和通道平均）

表 5.5 引入控制方法后不同受试者不同关节的均方根值

关节编号	受试者				
	1	2	3	4	5
1	4.73 ±0.87	4.23 ±0.93	4.97 ±0.83	6.99 ±0.93	4.63 ±0.82
2	4.75 ±0.91	5.11 ±0.99	4.69 ±0.92	5.67 ±0.93	4.59 ±0.99
3	4.53 ±0.98	4.83 ±0.90	4.47 ±1.00	4.90 ±0.91	4.34 ±0.96
4	5.94 ±0.99	5.99 ±0.89	4.88 ±0.91	5.74 ±0.95	4.73 ±0.90
5	4.84 ±0.98	3.80 ±0.92	3.78 ±0.97	3.89 ±0.99	3.73 ±0.90
6	5.50 ±0.95	4.78 ±0.96	4.21 ±0.89	4.66 ±0.96	3.93 ±0.89
7	5.19 ±0.94	5.50 ±0.89	4.24 ±0.99	5.23 ±0.97	4.19 ±0.90
8	4.07 ±0.88	4.79 ±0.88	4.42 ±0.95	4.89 ±0.92	4.60 ±0.92
9	4.93 ±0.94	5.89 ±0.97	5.13 ±0.98	5.90 ±0.92	5.13 ±0.88
10	4.86 ±0.89	4.81 ±0.93	5.44 ±0.94	4.60 ±0.88	5.43 ±0.89
11	5.84 ±0.97	4.80 ±0.90	5.02 ±0.97	4.91 ±0.90	5.14 ±0.99
12	5.51 ±0.96	3.58 ±0.99	5.38 ±0.98	3.43 ±0.97	5.59 ±0.98
13	5.31 ±0.97	4.89 ±0.92	5.17 ±0.97	5.00 ±0.95	5.36 ±0.98
14	4.84 ±0.99	4.23 ±0.93	5.01 ±0.94	3.79 ±0.92	5.13 ±0.98

续表 5.5 引入控制方法后不同受试者不同关节的均方根值

关节编号	受试者				
	1	2	3	4	5
15	4.74 \pm 0.98	4.81 \pm 0.89	4.13 \pm 0.91	4.97 \pm 0.89	4.15 \pm 1.00
16	4.64 \pm 0.96	6.11 \pm 0.88	6.02 \pm 0.94	5.91 \pm 0.92	5.73 \pm 0.95
17	5.15 \pm 0.94	5.59 \pm 0.96	7.35 \pm 0.93	4.50 \pm 0.98	7.13 \pm 0.96
18	4.84 \pm 0.95	6.00 \pm 0.88	6.18 \pm 0.94	5.97 \pm 0.99	5.75 \pm 0.94
19	4.65 \pm 0.99	4.88 \pm 0.94	6.39 \pm 0.89	5.37 \pm 0.92	6.54 \pm 0.96
20	4.96 \pm 0.92	5.63 \pm 0.92	5.24 \pm 0.94	4.49 \pm 0.92	4.71 \pm 0.92
21	4.57 \pm 0.68	4.83 \pm 0.75	5.62 \pm 0.55	4.79 \pm 0.62	4.60 \pm 0.41
22	5.31 \pm 0.43	5.29 \pm 0.53	4.62 \pm 0.11	5.44 \pm 0.95	4.73 \pm 0.90
23	4.17 \pm 0.88	4.62 \pm 0.88	4.71 \pm 0.95	4.42 \pm 0.92	4.63 \pm 0.92

5.5 本章小结

在外骨骼智能化过程中, 手部稳定的操控对于执行诸如抓取和伸展等精细操作至关重要。此部分通过比较并评估 CC 与 RMSE 这两种统计工具的使用效果, 以五名健康人的六种握持方式为对象进行了定量的模拟测试。试验结果显示, 当实施融合控制方案时, 各人预测值的稳健度有所提升。这一系列的研究成果也可以用于虚拟环境互动情境, 例如电子游戏或遥控设备等方面, 以便于实现在多种信号类型下的同步比率调控。然而, 每个参与者必须独立接受培训才能使用这个系统, 这意味着一旦某个特定群体完成了训练, 其他没有经过训练的人群就不能再用它。因此, 我们有必要进一步完善这些算法, 使得它们更具普遍适用性, 可以在不同的个体之间转移学习, 进而达到类似的手势控制的一致性。

6 总结与展望

6.1 总结

本研究提出了一种基于双模型交叉验证的模糊控制方法，增强了上肢外骨骼控制的鲁棒性和准确性。同时在该方法的不同模块上针对相应的问题提出了新的改进方法，提高了关节角度预测和手部动作识别的准确率以及运行效率。结合整个研究过程，本文的主要工作有以下几个方面：

1) 提出一种直接将 sEMG 信号作为输入的肩肘关节角度预测模型，该模型避免了对 sEMG 信号进行繁琐的传统特征提取。将对 sEMG 信号的特征提取任务融合进模型中，同时引入注意力机制使得模型对时序信息更加敏感，这对包含很多时序信息的 sEMG 信号而言能更好地揭示其与肌肉运动有关的信息。针对该模型的验证分别运用了协方差系数 (CC) 和均方根误差 (RMSE) 这两种统计评估手段，量化评估了模型对 10 名健康人士肩膀和肘部三个自由度动态的逼真度。研究成果揭示，在估测不同受试者间的关节动作角度方面，MST 模型因其能长期跟踪关联性能，展现出更超群的一致性。

2) 提出一种基于多输入时间卷积注意力的网络，其能够从时间序列数据中学习时间依赖性，并获得不同时刻的特征贡献，从而有效地将 sEMG 信号映射到肢体的关节角度。同时构建了一种联合训练机制，将 MITCAN 与 KNR 和 SVR 等传统统计算法相结合。这种集成克服了循环神经网络和传统统计算法的固有局限性，有利于减少评估误差，提高预测效果。通过公开数据集对其进行了性能验证，结果表明其性能优于 LSTM 和 BP，这为后续的双模型交叉验证做好了铺垫。

3) 提出一种多流融合的手部动作识别算法，其特点是能有效根据不同动作与不同肌肉之间的相关性构建一种针对某一肌肉群的特征提取模块。并在公开数据集中评估这个架构的多路表示法。结果表明，在不同类型的输入上幅度相位矩阵的表现优于用幅度矩阵单独作为输入的模型，其次在不同滑动窗口宽度的对比实验中 140 ms 的表象更好，最后提出的基于单通道的空间多流表征方法也有更优的表现。

4) 将手部关节角度预测模型作为控制方法的核心，其输出作为控制命令的重要依据。根据手部动作的特点建立一种通过手部动作识别的结果以及各个指关节的预测结果的修正方法，即根据在运动中同一手指上各关节的运动趋势大致相同这一特点，再结合手部动作识别的结果可以对手指关节角度的预测值进行修正。除此之外引入模糊控制进一步提升模型控制的准确性。

6.2 展望

本研究探索了基于深度学习的上肢外骨骼控制方法，但由于时间和精力有限设计构建的控制方法也有需要改进完善的地方。未来可在以下几个方面深入讨论：

（1）多模态信息的融合：单一的输入信号能承载的信息有限，引入其他信号可通过不同角度去分析同一种任务得到的结果是更全面客观的。在上肢外骨骼领域可引入脑电信号等，进而实现更多更复杂的控制指令。

（2）上肢多自由度联合的连续运动估计：在实际应用中往往都是复杂的任务，需要多关节多自由度的协同作用。可考虑在引入多模态信息的同时构建上肢多自由度的相关数据集，为后续的研究奠定基础。

（3）不同个体间迁移学习的模型：本研究的方法需要使用者较长时间配合训练，采集足够的训练数据对模型进行迭代。可以建立一种能识别不同个体中共通的特征，使得模型在不同使用者上都能获得良好的表现。

参考文献

- [1] Ersen M, Oztop E, Sariel S. Cognition-enabled robot manipulation in human environments: requirements, recent work, and open problems[J]. IEEE Robotics & Automation Magazine, 2017, 24(3): 108-122.
- [2] Wong C J, Tay Y L, Wang R, et al. Human-robot partnership: A study on collaborative storytelling[C]//2016 11th ACM/IEEE International Conference on Human-Robot Interaction (HRI). IEEE, 2016: 535-536.
- [3] 董士海. 人机交互的进展及面临的挑战[J]. 计算机辅助设计与图形学学报, 2004, 16(1): 1-13.
- [4] Yang M H, Ahuja N. Extraction and classification of visual motion patterns for hand gesture recognition[C]//Proceedings. 1998 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (Cat. No. 98CB36231). IEEE, 1998: 892-897.
- [5] Cheok M J, Omar Z, Jaward M H. A review of hand gesture and sign language recognition techniques[J]. International Journal of Machine Learning and Cybernetics, 2019, 10: 131-153.
- [6] Förster K, Biasiucci A, Chavarriaga R, et al. On the use of brain decoded signals for online user adaptive gesture recognition systems[C]//Pervasive Computing: 8th International Conference, Pervasive 2010, Helsinki, Finland, May 17-20, 2010. Proceedings 8. Springer Berlin Heidelberg, 2010: 427-444.
- [7] 丁其川, 熊安斌, 赵新刚, 等. 基于表面肌电的运动意图识别方法研究及应用综述[J]. 自动化学报, 2016, 42(1): 13-25.
- [8] Ahsan M R, Ibrahimy M I, Khalifa O O. EMG signal classification for human computer interaction: a review[J]. European Journal of Scientific Research, 2009, 33(3): 480-501.
- [9] Bi L, Guan C. A review on EMG-based motor intention prediction of continuous human upper limb motion for human-robot collaboration[J]. Biomedical Signal Processing and Control, 2019, 51: 113-127.
- [10] Ortiz-Catalan M, Brånemark R, Håkansson B. BioPatRec: A modular research platform for the control of artificial limbs based on pattern recognition algorithms[J]. Source code for biology and medicine, 2013, 8: 1-18.
- [11] Atzori M, Gijsberts A, Castellini C, et al. Electromyography data for non-invasive naturally-controlled robotic hand prostheses[J]. Scientific data, 2014, 1(1): 1-13.
- [12] Pizzolato S, Tagliapietra L, Cognolato M, et al. Comparison of six electromyography acquisition setups on hand movement classification tasks[J]. PloS one, 2017, 12(10): e0186132.
- [13] Palermo F, Cognolato M, Gijsberts A, et al. Repeatability of grasp recognition for robotic hand

- prosthesis control based on sEMG data[C]//2017 International Conference on Rehabilitation Robotics (ICORR). IEEE, 2017: 1154-1159.
- [14] Krasoulis A, Kyranou I, Erden M S, et al. Improved prosthetic hand control with concurrent use of myoelectric and inertial measurements[J]. Journal of neuroengineering and rehabilitation, 2017, 14: 1-14.
- [15] Saponas T S, Tan D S, Morris D, et al. Demonstrating the feasibility of using forearm electromyography for muscle-computer interfaces[C]//Proceedings of the SIGCHI conference on human factors in computing systems. 2008: 515-524.
- [16] Saponas T S, Tan D S, Morris D, et al. Enabling always-available input with muscle-computer interfaces[C]//Proceedings of the 22nd annual ACM symposium on User interface software and technology. 2009: 167-176.
- [17] Kainz O, Jakab F. Approach to hand tracking and gesture recognition based on depth-sensing cameras and EMG monitoring[J]. Acta Informatica Pragensia, 2014, 3(1): 104-112.
- [18] Chu J U, Moon I, Lee Y J, et al. A supervised feature-projection-based real-time EMG pattern recognition for multifunction myoelectric hand control[J]. IEEE/ASME Transactions on mechatronics, 2007, 12(3): 282-290.
- [19] Ding Q, Zhao X, Han J. EMG-based estimation for multi-joint continuous movement of human upper limb[J]. Robot, 2014, 36(4): 469-476.
- [20] Li Zhijun, Wang Baocheng, Sun Fuchun, et al. sEMG-based joint force control for an upper-limb power-assist exoskeleton robot[J]. IEEE journal of biomedical and health informatics, 2013, 18(3): 1043-1050.
- [21] Englehart K, Hudgin B, Parker P A. A wavelet-based continuous classification scheme for multifunction myoelectric control[J]. IEEE Transactions on Biomedical Engineering, 2001, 48(3): 302-311.
- [22] Felzer T, Freisleben B. HaWCoS: the "hands-free" wheelchair control system[C]//Proceedings of the fifth international ACM conference on Assistive technologies. 2002: 127-134.
- [23] Kiguchi K, Tanaka T, Watanabe K, et al. Design and control of an exoskeleton system for human upper-limb motion assist[C]//Proceedings 2003 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM 2003). IEEE, 2003, 2: 926-931.
- [24] Chu J U, Moon I, Lee Y J, et al. A supervised feature-projection-based real-time EMG pattern recognition for multifunction myoelectric hand control[J]. IEEE/ASME Transactions on mechatronics, 2007, 12(3): 282-290.
- [25] 李鹏. 人机协同: 人工智能发展的融合之道[J]. 收藏, 2019, 4.
- [26] Konrad P. The abc of emg[J]. A practical introduction to kinesiological electromyography, 2005, 1(2005): 30-5.

- [27] 赵章琰. 表面肌电信号检测和处理中若干关键技术研究[D]. 合肥: 中国科学技术大学, 2010.
- [28] 蔡春风. 人体表面肌电信号处理及其在人机智能系统中的应用研究[D]. 杭州: 浙江大学, 2006.
- [29] Jung P G, Lim G, Kim S, et al. A wearable gesture recognition device for detecting muscular activities based on air-pressure sensors[J]. IEEE Transactions on Industrial Informatics, 2015, 11(2): 485-494.
- [30] McIntosh J, McNeill C, Fraser M, et al. EMPress: Practical hand gesture classification with wrist-mounted EMG and pressure sensing[C]//Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems. 2016: 2332-2342.
- [31] Itkarkar R R, Nandi A V. A survey of 2D and 3D imaging used in hand gesture recognition for human-computer interaction (HCI)[C]//2016 IEEE International WIE Conference on Electrical and Computer Engineering (WIECON-ECE). IEEE, 2016: 188-193.
- [32] Gijsberts A, Atzori M, Castellini C, et al. Movement error rate for evaluation of machine learning methods for sEMG-based hand movement classification[J]. IEEE transactions on neural systems and rehabilitation engineering, 2014, 22(4): 735-744.
- [33] Zia ur Rehman M, Waris A, Gilani S O, et al. Multiday EMG-based classification of hand motions with deep learning techniques[J]. Sensors, 2018, 18(8): 2497.
- [34] Chu J U, Moon I, Mun M S. A real-time EMG pattern recognition system based on linear-nonlinear feature projection for a multifunction myoelectric hand[J]. IEEE Transactions on biomedical engineering, 2006, 53(11): 2232-2239.
- [35] Oskoei M A, Hu H. Myoelectric control systems—A survey[J]. Biomedical signal processing and control, 2007, 2(4): 275-294.
- [36] Ju P, Kaelbling L P, Singer Y. State-based classification of finger gestures from electromyographic signals[C]//ICML. 2000, 8: 439-446.
- [37] Tsuji T, FUKUDA O, MURAKAMI M, et al. An EMG controlled pointing device using a neural network[J]. Transactions of the Society of Instrument and Control Engineers, 2001, 37(5): 425-431.
- [38] Atzori M, Gijsberts A, Castellini C, et al. Electromyography data for non-invasive naturally-controlled robotic hand prostheses[J]. Scientific data, 2014, 1(1): 1-13.
- [39] Maldonado S, Weber R. A wrapper method for feature selection using support vector machines[J]. Information Sciences, 2009, 179(13): 2208-2217.
- [40] Wenjie M, Zhizeng L. Hand-motion Pattern Recognition of SEMG Based on Hilbert-Huang Transformation and AR-model[C]//2007 International Conference on Mechatronics and Automation. IEEE, 2007: 2150-2154.
- [41] Chu J U, Moon I, Mun M S. A real-time EMG pattern recognition system based on linear-nonlinear feature projection for a multifunction myoelectric hand[J]. IEEE Transactions on biomedical engineering, 2006, 53(11): 2232-2239.
- [42] Fisher R A. The use of multiple measurements in taxonomic problems[J]. Annals of eugenics, 1936,

- 7(2): 179-188.
- [43] Khushaba R N, Al-Timemy A H, Al-Ani A, et al. A framework of temporal-spatial descriptors-based feature extraction for improved myoelectric pattern recognition[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2017, 25(10): 1821-1831.
 - [44] Phinyomark A, Phukpattaranont P, Limsakul C. Feature reduction and selection for EMG signal classification[J]. Expert systems with applications, 2012, 39(8): 7420-7431.
 - [45] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. science, 2006, 313(5786): 504-507.
 - [46] Voulodimos A, Doulamis N, Doulamis A, et al. Deep learning for computer vision: A brief review[J]. Computational intelligence and neuroscience, 2018, 2018(1): 7068349.
 - [47] Graves A, Mohamed A, Hinton G. Speech recognition with deep recurrent neural networks[C]//2013 IEEE international conference on acoustics, speech and signal processing. Ieee, 2013: 6645-6649.
 - [48] Young T, Hazarika D, Poria S, et al. Recent trends in deep learning based natural language processing[J]. ieee Computational intelligence magazine, 2018, 13(3): 55-75.
 - [49] Geng W, Du Y, Jin W, et al. Gesture recognition by instantaneous surface EMG images[J]. Scientific reports, 2016, 6(1): 36571.
 - [50] Xia P, Hu J, Peng Y. EMG-based estimation of limb movement using deep learning with recurrent convolutional neural networks[J]. Artificial organs, 2018, 42(5): E67-E77.
 - [51] Nahid N, Rahman A, Ahad M A R. Deep learning based surface EMG hand gesture classification for low-cost myoelectric prosthetic hand[C]//2020 Joint 9th International Conference on Informatics, Electronics & Vision (ICIEV) and 2020 4th International Conference on Imaging, Vision & Pattern Recognition (icIVPR). IEEE, 2020: 1-8.
 - [52] Sri-Iesaranusorn P, Chaiyaroj A, Buekban C, et al. Classification of 41 hand and wrist movements via surface electromyogram using deep neural network[J]. Frontiers in bioengineering and biotechnology, 2021, 9: 548357.
 - [53] Chen X, Li Y, Hu R, et al. Hand gesture recognition based on surface electromyography using convolutional neural network with transfer learning method[J]. IEEE Journal of Biomedical and Health Informatics, 2020, 25(4): 1292-1304.
 - [54] Lv Z, Xiao F, Wu Z, et al. Hand gestures recognition from surface electromyogram signal based on self-organizing mapping and radial basis function network[J]. Biomedical Signal Processing and Control, 2021, 68: 102629.
 - [55] Yang Y, Duan F, Ren J, et al. Performance comparison of gesture recognition system based on different classifiers[J]. IEEE Transactions on Cognitive and Developmental Systems, 2020, 13(1): 141-150.
 - [56] Rajapriya R, Rajeswari K, Thiruvengadam S J. Deep learning and machine learning techniques to improve hand movement classification in myoelectric control system[J]. Biocybernetics and

- Biomedical Engineering, 2021, 41(2): 554-571.
- [57] Jiang Y, Chen C, Zhang X, et al. Shoulder muscle activation pattern recognition based on sEMG and machine learning algorithms[J]. Computer methods and programs in biomedicine, 2020, 197: 105721.
- [58] Pan L, Sheng X, Zhang D, et al. Simultaneous and proportional estimation of finger joint angles from surface EMG signals during mirrored bilateral movements[C]//Intelligent Robotics and Applications: 6th International Conference, ICIRA 2013, Busan, South Korea, September 25-28, 2013, Proceedings, Part I 6. Springer Berlin Heidelberg, 2013: 493-499.
- [59] Smith R J, Tenore F, Huberdeau D, et al. Continuous decoding of finger position from surface EMG signals for the control of powered prostheses[C]//2008 30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE, 2008: 197-200.
- [60] Aung Y M, Al-Jumaily A. sEMG based ANN for shoulder angle prediction[J]. Procedia Engineering, 2012, 41: 1009-1015.
- [61] Tang Z, Zhang K, Sun S, et al. An upper-limb power-assist exoskeleton using proportional myoelectric control[J]. Sensors, 2014, 14(4): 6677-6694.
- [62] Li X, Huang Q, Zhu J, et al. A novel proportional and simultaneous control method for prosthetic hand[J]. Journal of Mechanics in Medicine and Biology, 2017, 17(08): 1750120.
- [63] Reiter R. Eine neue elektrokunsthand[J]. Grenzgebiete der Medizin, 1948,1(4): 133-135.
- [64] Schmidl H. The inail myoelectric b/e prosthesis[J]. Orthotics and Prosthetics, 1965, 19(4): 298-303.
- [65] Battye C K, Nightingale A, Whillis J. The use of myo-electric currents in the operation of prostheses[J]. The Journal of Bone & Joint Surgery British Volume, 1955, 37(3): 506-510.
- [66] Oskoei M A, Hu H. Myoelectric control systems—A survey[J]. Biomedical signal processing and control, 2007, 2(4): 275-294.
- [67] Bottomley A H. Myo-electric control of powered prostheses[J]. The Journal of Bone & Joint Surgery British Volume, 1965, 47(3): 411-415.
- [68] Jiang N, Rehbaum H, Vujaklija I, et al. Intuitive, online, simultaneous, and proportional myoelectric control over two degrees-of-freedom in upper limb amputees[J]. IEEE transactions on neural systems and rehabilitation engineering, 2013, 22(3): 501-510.
- [69] Farina D, Jiang N, Rehbaum H, et al. The extraction of neural information from the surface EMG for the control of upper-limb prostheses: emerging avenues and challenges[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2014, 22(4): 797-809.
- [70] Hahne J M, Biessmann F, Jiang N, et al. Linear and nonlinear regression techniques for simultaneous and proportional myoelectric control[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2014, 22(2): 269-279.
- [71] Young A J, Smith L H, Rouse E J, et al. A new hierarchical approach for simultaneous control of multi-joint powered prostheses[C]//2012 4th IEEE RAS & EMBS International Conference on Biomedical

- Robotics and Biomechatronics (BioRob). IEEE, 2012: 514-520.
- [72] Zhang S, Zhang X, Cao S, et al. Myoelectric pattern recognition based on muscle synergies for simultaneous control of dexterous finger movements[J]. IEEE Transactions on Human-Machine Systems, 2017, 47(4): 576-582.